

UMONS



Faculté
des Sciences

Automates

Étudiant : Benjamin André
Directrice : Véronique Bruyère
10 juin 2020

Table des matières

1	Introduction	3
2	Langage	3
2.1	Alphabet	3
2.2	Mots	3
2.3	Langage	4
2.4	Expression régulière	4
3	Automate Déterministe Fini	5
3.1	Définition	5
3.2	Graphe d'automate déterministe fini	6
3.3	Chemin	7
3.4	Langage défini par un automate	8
3.5	La relation R_M	8
3.6	Automate et problème de décision	9
4	Automate Non-déterministe Fini	9
4.1	Définition	9
4.2	Fermeture sur ϵ	10
4.3	Chemin	11
4.4	Transformation d'ANF à ADF	11
5	Opérations sur un automate	14
5.1	Équivalence avec une expression régulière	14
5.2	Équivalence d'états	19
5.2.1	Complexité	20
5.3	Équivalence d'automates	21
5.4	Minimisation d'automate	22
5.5	Construction d'automate depuis un langage	23
6	Théorème de Myhill-Nérode	24
6.1	Relation de Myhill-Nérode	24
6.2	Théorème de Myhill-Nerode	25
7	Algorithme d'Angluin	26
7.1	Table d'observation	26
7.2	Relation R_O	26
7.3	Fermeture	26
7.4	Cohérence	27
7.5	Exemple	27
7.5.1	Première itération	27
7.5.2	Seconde itération	28
7.5.3	Troisième itération	29

7.6	Algorithme	30
7.7	Preuve	30
7.8	Complexité	30

1 Introduction

Deuxième version du document. *TODO : rédiger une introduction*

2 Langage

Cette section pose différents concepts et notations pour arriver à la notion de langage. Celle-ci reprennent les notations proposées par Hopcroft et al. [1].

2.1 Alphabet

Un *alphabet*, nommé Σ par convention, est un ensemble fini et non vide de *symbols*.

Exemple 2.1 Voici trois alphabets :

- $\Sigma = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$, l'alphabet des chiffres
- $\Sigma = \{a, b, c, \dots, z, A, B, C, \dots, Z\}$, l'alphabet latin
- $\Sigma = \{0, 1\}$, l'alphabet binaire

2.2 Mots

Soit l'alphabet Σ et un entier naturel k . Un *mot* sur Σ est une suite finie de k éléments de Σ notée $w = a_1 \dots a_k$.

L'entier k est la *longueur* de ce mot aussi notée $|w| = k$.

Exemple 2.2 $w = 01110010$ est un mot sur $\Sigma = \{0, 1\}$

Le *mot vide* est un mot de taille $k = 0$, noté $w = \epsilon$.

Σ^k est l'ensemble des mots sur Σ de longueur k .

L'ensemble de tous les mots possibles sur Σ est noté $\Sigma^* = \bigcup_{k=0}^{\infty} \Sigma^k$.

La *concaténation* de deux mots $w = a_1 \dots a_k$ et $x = b_1 \dots b_j$ est l'opération consistant à créer un nouveau mot wx , mot de taille $i = k + j$ s'écrivant $wx = a_1 \dots a_k b_1 \dots b_j$.

Exemple 2.3 Soient les mots $x = 41$ et $y = 31$. Alors $xy = 4131$ et $yx = 3141$.

Lemme 2.4 ϵ est l'identité pour la concaténation, à savoir pour tout mot w , $w\epsilon = \epsilon w = w$. Par définition de la concaténation, tout mot concaténé avec ϵ retourne le même mot. \square

L'*exponentiation* d'un symbole a à la puissance k , notée a^k , retourne un mot de longueur k obtenu par la concaténation de copies du symbole a . Noter que $a^0 = \epsilon$.

2.3 Langage

Un ensemble de mots sur Σ est un *langage* [1], noté L . Alternativement, $L \subseteq \Sigma^*$. Étant donné que Σ^* est infini, L peut l'être également.

Exemple 2.5 Voici des exemples, utilisant plusieurs modes de définition. Σ y est implicite, mais il peut être donné explicitement.

- $L = \{12, 35, 42, 7, 0\}$, un ensemble défini explicitement
- $L = \{0^k 1^j \mid k + j = 7\}$, les mots de 7 symboles sur $\Sigma = \{0, 1\}$ ne contenant pas 10. Ici, L est donné par notation ensembliste
- L est donné par "Tous les noms de villes belges.". Ici L est défini en français.
- \emptyset est un langage sur tout alphabet.
- $L = \{\epsilon\}$ ne contient que le mot vide, et est un langage sur tout alphabet.

Opérations sur les langages

Soient L et M deux langages. $L \cup M = \{w \mid w \in L \vee w \in M\}$ est l'*union* de ces deux langages et en donne un nouveau. Ce langage est composé des mots venant d'un des deux langages.

Le langage composé de tous les mots produit par la concaténation d'un mot de L avec un mot de M est une *concaténation* de ces deux langages et s'écrit LM .

La *fermeture* de L est notée L^* et donne un langage constitué de tous les mots qui peuvent être construits par une concaténation d'un nombre arbitraire de mots de L .

2.4 Expression régulière

Certains langages peuvent être exprimés par une *expression régulière*. Un exemple de celles-ci est 01^*0 qui décrit la langage constitué de tous les mots commençant et finissant par 0 avec uniquement des 1 entre les deux.

Les expressions régulières suivent un algèbre avec ses opérations et leur priorités. Le langage décrit par une expression est construit de façon inductive par ces différentes opérations. Pour une expression régulière E , le langage exprimé est noté $L(E)$. Un langage qui peut être exprimé par une expression régulière est dit *langage régulier*.

Cas de base Certains langages peuvent être construits directement sans passer par l'induction :

- ϵ est une expression régulière. Elle exprime le langage $L(\epsilon) = \{\epsilon\}$
- \emptyset est une expression régulière décrivant $L(\emptyset) = \emptyset$
- Si a est un symbole, alors **a** est une expression régulière composée uniquement de a . $L(a) = \{a\}$.
- Une variable, souvent en majuscule et italique, représente un langage quelconque, par exemple L .

Induction Les autres langages réguliers sont construits suivant différentes règles d'induction présentées par ordre décroissant de priorité :

- Si E est une expression régulière, (E) est une expression régulière et $L((E)) = L(E)$.
- Si E est une expression régulière, E^* est une expression régulière représentant la fermeture de $L(E)$, à savoir $L(E^*) = L(E)^*$.

- Si E et F sont des expressions régulières, EF est une expression régulière décrivant la concaténation des deux langages représentés, à savoir $L(EF) = L(E)L(F)$. La concaténation étant commutative, l'ordre de groupement n'est pas important, mais par convention, la priorité est à gauche.
- Si E et F sont des expressions régulières, $E + F$ est une expression régulière donnant l'union des deux langages représentés, à savoir $L(E + F) = L(E) \cup L(F)$. Ici encore, l'opération est commutative et la priorité est à gauche.

Exemple 2.6 Soit l'expression $E = (b + ab)b^*a(a + b)^*$ qui représente le langage L .

- **ba fait partie de L .** En effet, en développant E avec des choix sur les unions et le degré d'une fermeture, on obtient $E = (b)b^0a(a + b)^0 = b\epsilon a\epsilon = ba$.
- **$ababbab$ fait partie de L .** En développant à nouveau E en posant des choix sur les unions et fermetures, on obtient $E = (ab)b^0a(a + b)^4 = ab\epsilon a(a + b)(a + b)(a + b)(a + b) = ababbab$.
- **aa ne fait pas partie de L .** Supposons par l'absurde que $aa \in L$. Alors il existerait une façon de décomposer E en aa . Or, les premiers symboles doivent être soit b , soit ab . Il y a contradiction : E ne peut pas être décomposé. Comme aa ne peut pas être construit par E , $aa \notin L$.

3 Automate Déterministe Fini

3.1 Définition

Un automate déterministe fini (ADF) $A = (Q, \Sigma, q_0, \delta, F)$ est défini comme suit :

- Q est un ensemble fini d'états
- Σ est un alphabet
- $q_0 \in Q$ est l'état initial
- $\delta : Q \times \Sigma \rightarrow Q$ est la fonction de transition. A partir d'un état q de Q , en fonction d'un symbole a , elle retourne un état de Q : $\delta(q, a)$. Cette transition est dite *transition sur a* .
- $F \subseteq Q$ est un ensemble d'états acceptants.

Exemple 3.1 On considère l'automate $A = (Q, \Sigma, q_0, \delta, F)$ défini comme suit :

- $Q = \{q_0, q_1, q_2, q_3, q_4, q_5, q_6\}$
- $\Sigma = \{0, 1\}$
- q_0 est l'état du même nom
- La fonction de transition δ est décrite par la table 1. L'intersection d'une ligne reprenant un élément $q \in Q$ et d'une colonne $a \in \Sigma$ donne l'état $\delta(q, a)$.
- $F = \{q_d\}$

	a	b
$\rightarrow q_0$	q_2	q_1
q_1	q_3	q_5
q_2	q_4	q_5
q_3^*	q_3	q_3
q_4	q_4	q_4
q_5	q_3	q_1
q_6	q_4	q_5

FIGURE 1: La table de transitions δ

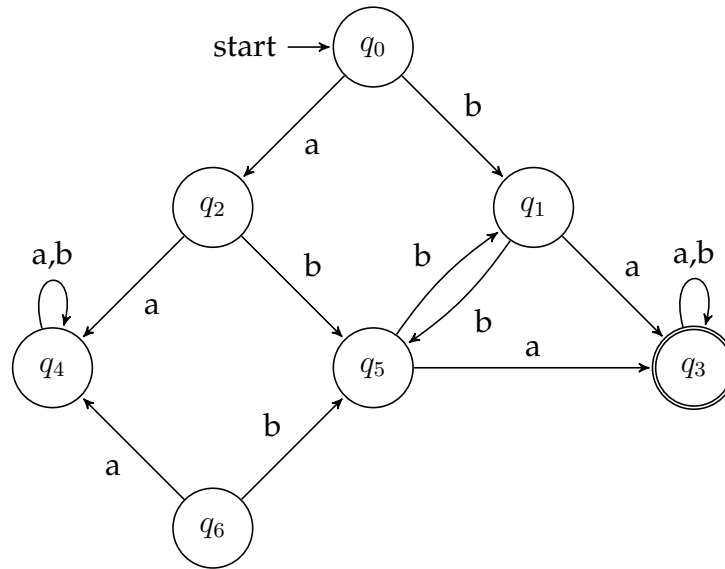
Via cette notation, Q et Σ sont explicites. En dénotant l'état initial par \rightarrow et les états acceptants par $*$ en exposant, on obtient une définition complète d'un automate : $(Q, \Sigma, q_0, \delta, F)$.

3.2 Graphe d'automate déterministe fini

Le *graphe d'un automate déterministe fini* $A = (Q, \Sigma, q_0, \delta, F)$ est un graphe dirigé construit comme suit :

- Chaque nœud du graphe correspond à un état de Q
- Chaque arc a un symbole de Σ comme étiquette. Un arc relie un état q_0 à un état q_1 . Cet arc définit $\delta(q_0, a) = q_1$, une transition de la fonction de transition. Si plusieurs symboles causent une même transition de q_0 à q_1 , il n'y a qu'une seule étiquette sur l'arc, listant ces différents symboles.
- L'état initial est mis en évidence par une flèche entrante.
- Les états acceptants sont représentés par un double cercle, en opposition au simple cercle des autres nœuds.

Exemple 3.2 Voici le graphe représentant l'automate défini par la table 1

FIGURE 2: Automate A_1

Cette représentation d'un automate peut sembler plus naturelle pour un humain alors que la table de transitions est plus proche d'un langage informatique. De plus, dans la représentation par graphe, les ensembles Q et Σ sont implicites et doivent être définis ou déduits à part.

3.3 Chemin

La fonction de transition étendue

$$\hat{\delta} : Q \times \Sigma^* \rightarrow Q$$

prend en entrée un état de Q et un mot w sur Σ et retourne un état de Q .

$\hat{\delta}$ est définie de façon récursive par sur w :

Cas de base Il y a deux cas de base :

- w est un mot vide : $\hat{\delta}(q, \epsilon) = q$
- w est un symbole : $\hat{\delta}(q, w)$ avec $w = a \in \Sigma$. Alors, le chemin utilise la fonction de transition : $\hat{\delta}(q, a) = \delta(q, a)$.

Pas de récurrence Si $|w| > 1$, alors $w = xa$ avec x un mot sur Σ et a un symbole de Σ . Les chemins sur des mots de longueur strictement supérieure à 1 sont définis comme $\hat{\delta}(q, w) = \hat{\delta}(q, xa) = \delta(\hat{\delta}(q, x), a)$.

Il se peut que δ ne soit pas définie pour une paire d'arguments. Auquel cas, $\hat{\delta}$ ne l'est pas non plus.

Un *chemin* est une application de cette fonction sur un état et un mot.

Exemple 3.3 Considérons l'automate A de la figure 2. Il existe un chemin de q_0 à q_5 : $\hat{\delta}(q_0, ab) = \delta(\hat{\delta}(q_0, a), b) = \delta(\delta(q_0, a), b) = \delta(q_2, b) = q_5$.

3.4 Langage défini par un automate

Le langage représenté par un automate $A = (Q, \Sigma, q_0, \delta, F)$ peut alors se définir comme les mots qui, par l'application de $\hat{\delta}$ sur l'état initial, donnent un état acceptant :

$$L(A) = \{w \in \Sigma^* \mid \hat{\delta}(q_0, w) \in F\}$$

Ainsi, un mot w appartient à un langage L défini par l'automate A si $\hat{\delta}(q_0, w) \in F$.

3.5 La relation R_M

Soit un automate $A = (Q, \Sigma, q_0, \delta, F)$. Définissons la relation R_M entre deux états :

$$xR_My \iff (\forall w \in \Sigma^*, \hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F)$$

Intuitivement, ces deux états sont en relation si tout mot lu à partir de celui-ci mène à des états étant simultanément acceptants ou non.

Proposition 3.4 R_M est une relation d'équivalence.

Preuve 3.4.1 Montrer que R_M est une relation d'équivalence revient à montrer qu'elle est réflexive, transitive et symétrique.

- **Réflexive** : Soient un état $x \in Q_M$ et $w \in \Sigma^*$. Alors, $\hat{\delta}(x, w) \in F \iff \hat{\delta}(x, w) \in F$ et par définition, xR_Mx .
- **Transitive** : Soient les états $x, y, z \in Q_M$ tels que xR_My et yR_Mz ainsi que $w \in \Sigma^*$. Par hypothèse, $\hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$ et $\hat{\delta}(y, w) \in F \iff \hat{\delta}(z, w) \in F$. Par transitivité de l'implication, on obtient $\hat{\delta}(x, w) \in F \iff \hat{\delta}(z, w) \in F$. On a donc xR_Mz .
- **Symétrique** : Soient les états $x, y \in Q_M$ tels que xR_My et un mot $w \in \Sigma^*$. Par hypothèse, $\hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$. En lisant la double implication depuis la droite, on a bien $\hat{\delta}(y, w) \in F \iff \hat{\delta}(x, w) \in F$ et donc yR_Mx .

Corrolaire 3.4.2 R_M sépare les états de Q en classes d'équivalence.

La classe d'équivalence de tous les états en relation R_M avec q (qui sert alors de représentant) se note $[[q]]$ ou par une lettre majuscule, typiquement S ou T .

La congruence à droite d'une relation R entre des mots sur un alphabet Σ est définie comme :

$$\forall x, y \in \Sigma^*, xRy \Rightarrow \forall a \in \Sigma, xaRya$$

Proposition 3.5 R_M est congruente à droite.

Preuve 3.5.1 Si la relation est vraie pour deux état, elle reste valable pour les états atteints par la lecture d'un symbole quelconque. Soient les états $x, y \in Q_M$ tels que xR_My . Soit un symbole $a \in \Sigma$. Par hypothèse,

$$\forall w \in \Sigma^*, \hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$$

C'est donc vrai en particulier pour $w = au, u \in \Sigma^*$. Dès lors,

$$\begin{aligned}\hat{\delta}(x, au) \in F &\iff \hat{\delta}(y, au) \in F \\ \hat{\delta}(\delta(x, a), u) \in F &\iff \hat{\delta}(\delta(y, a), u) \in F \\ \hat{\delta}(p, u) \in F &\iff \hat{\delta}(q, u) \in F\end{aligned}$$

Corrolaire 3.5.2 *Pour chaque symbole, toutes les transitions sortant d'une classe d'équivalence mènent à une même classe d'équivalence : $\forall a \in \Sigma, \exists T, \forall q \in S, \delta(q, a) \in T$ avec T une classe d'équivalence.*

3.6 Automate et problème de décision

Une notion liée aux langages est celle de *problème*. Une forme de problème est celle dite de *décision* : une question à laquelle la réponse est oui ou non.

Ces problèmes de décision peuvent être exprimés en terme d'appartenance d'un mot à un langage.

Par exemple, prenons l'alphabet des chiffres $\Sigma = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Considérons ensuite le langage $L = \{w \mid \text{le nombre représenté par } w \text{ est pair}\}$.

Demander si un nombre est pair peut alors être traduit par l'appartenance d'un mot le représentant à L . Si le langage peut être représenté par un automate déterministe fini, la réponse peut être trouvée par l'exécution de celui-ci.

4 Automate Non-déterministe Fini

4.1 Définition

Une automate non-déterministe fini est une variété d'automate similaire aux ADF, moyennant quelques modifications. Un automate non-déterministe fini s'écrit également :

$$A = (Q, \Sigma, \delta, q_0, F)$$

mais avec :

- Q un ensemble fini d'états
- Σ un alphabet
- q_0 l'état initial
- $F \subseteq Q$ l'ensemble des états acceptants
- $\delta : Q \times \Sigma \cup \{\epsilon\} \rightarrow 2^Q$ où 2^Q est l'ensemble des parties de Q . Cela signifie que la fonction δ retourne un ensemble d'états de Q

Dans la littérature [?] les automates non-déterministes finis sont divisés en deux groupes :

1. Ceux pour lequel au moins une transition de δ est définie pour ϵ .
2. Ceux pour lequel aucune transition n'est définie pour ϵ . En pratique, la définition de delta devient $\delta : Q \times \Sigma \rightarrow 2^Q$.

N'étant pas le sujet de ce document, ces deux ne reçoivent aucune distinction et sont tous deux notés ANF pour automate non-déterministe fini. Une transition sur ϵ est susceptible d'être définie pour tout ANF.

Exemple 4.1 De la même façon que pour l'exemple 3.1 de la section 3.1, considérons un automate $A = (Q, \Sigma, q_0, \delta, F)$ défini comme suit :


- $Q = \{q_0, q_1, q_2\}$
- $\Sigma = \{a, b, c\}$
- q_0 est l'état du même nom
- δ est donnée par la table 3.
- $F = \{q_2\}$

A est un ANF ; une colonne supplémentaire sert à représenter la transition sur ϵ .

	ϵ	a	b	c
$\rightarrow q_0$	$\{q_1, q_2\}$	\emptyset	$\{q_1\}$	$\{q_2\}$
q_1	\emptyset	$\{q_0\}$	$\{q_2\}$	$\{q_0, q_1\}$
q_2^*	\emptyset	\emptyset	\emptyset	\emptyset

FIGURE 3: δ

De plus, A peut être représenté par un graphe suivant la même méthodologie que dans la sous-section 3.2 pour les ADF. Additionnellement, ϵ peut servir d'étiquette même s'il n'appartient pas à Σ .

FIGURE 4: Automate A

4.2 Fermeture sur ϵ

Pour chaque état q d'un ANF, un ensemble d'états peut être atteint sans lire de symbole. Il s'agit de l'état en question et de tous ceux pouvant être atteint uniquement par des transitions sur ϵ . Cet ensemble s'appelle la *fermeture sur epsilon* : $ECLOSE(q)$. Il peut être construit récursivement.

Soit un automate $A = (Q, \Sigma, q_0, \delta, F)$. Soit q un état dans Q .

Cas de base q est dans $ECLOSE(q)$

Pas de récurrence Si p est dans $\text{ECLOSE}(q)$ et qu'il existe un état r tel quel $r \in \delta(p, \epsilon)$, alors r est dans $\text{ECLOSE}(q)$

Exemple 4.2 Considérons l'automate A de l'exemple 4.1. Les différentes fermetures peuvent être calculées :

- $\text{ECLOSE}(q_0) = \{q_0, q_1, q_2\}$. En effet, q_0 appartient à sa fermeture, selon le cas de base. Aussi, $q_1, q_2 \in \delta(q_0, \epsilon)$
- $\text{ECLOSE}(q_1) = \{q_1\}$ par le cas de base.
- $\text{ECLOSE}(q_2) = \{q_2\}$ par le cas de base.

4.3 Chemin

La notion de fermeture permet de faciliter l'expression d'une fonction de transition étendue pour un ANF, ce qui permet d'exprimer des chemins et donc le langage.

Soit un ANF $A = (Q, \Sigma, q_0, \delta, F)$. La fonction de transition étendue $\hat{\delta}$ retourne un ensemble d'états atteints par la lecture d'un mot depuis un état : $\hat{\delta}(q, w)$ est un ensemble d'états atteignables par un chemin formant le mot w , avec éventuellement des transitions sur ϵ .

$\hat{\delta}$ vaut, de façon récursive sur le mot w pour un état q :

Cas de base $\hat{\delta}(q, \epsilon) = \text{ECLOSE}(q)$. ECLOSE permet de calculer l'ensemble des états atteints uniquement par des transitions sur ϵ , ce qui correspond à ce cas de base

Pas de récurrence Supposons que $w = xa$. a est le dernier symbole de w et $\hat{\delta}(q, x)$ est défini par récurrence. Alors, pour obtenir $\hat{\delta}(q, w)$:

1. Posons $\{p_1, p_2, \dots, p_k\} = \hat{\delta}(q, x)$. Ce sont les états atteints par la lecture de x , certains ont potentiellement été atteints par des transitions sur ϵ .
2. Posons $\{r_1, r_2, \dots, r_m\} = \bigcup_{i=1}^k \delta(p_i, a)$. Ce sont les nouveaux états atteints par la lecture de a . Comme δ retourne un ensemble, l'union permet de regrouper les états en un seul ensemble.
3. Finalement, $\hat{\delta}(q, w) = \bigcup_{j=1}^m \text{ECLOSE}(r_j)$. Cette étape de fermeture permet d'ajouter les états décrivant la lecture de w suivie de transition sur ϵ , ce qui exprime toujours le mot w .

Le langage exprimé par un ANF $A = (Q, \Sigma, q_0, \delta, F)$ est alors défini par :

$$L(A) = \{w \in \Sigma^* \mid \hat{\delta}(q_0, w) \cap F \neq \emptyset\}$$

4.4 Transformation d'ANF à ADF

Cette section présente une méthode permettant de créer un ADF à partir d'un ANF.

Soit un ANF $A = (Q, \Sigma, q_0, \delta, F)$. Alors l'ADF équivalent

$$D = (Q_D, \Sigma, \delta_D, q_D, F_D)$$

est défini par :

- $Q_D = \{S \mid S \subseteq Q \text{ et } S \text{ est fermé sur } \epsilon\}$. Concrètement, Q_D est l'ensemble des parties des Q fermées sur ϵ . Cette fermeture s'écrit $S = \text{ECLOSE}(S)$, ce qui signifie que chaque transition sur ϵ depuis un état de S mène à un état également dans S . L'ensemble \emptyset est fermé sur ϵ .
- $q_D = \text{ECLOSE}(q_0)$. L'état initial de D est l'ensemble des états dans la fermeture sur ϵ des états de A .
- $F_D = \{S \mid S \in Q_D \text{ et } S \cap F \neq \emptyset\}$ contient les ensembles dont au moins un état est acceptant pour A .
- $\delta_D(S, a)$ est construit, $\forall a \in \Sigma, \forall S \in Q_D$ par :
 1. Soit $S = \{p_1, p_2, \dots, p_k\}$.
 2. Calculer $\bigcup_{i=1}^k \delta(p_i, a)$. Renommer cet ensemble en $\{r_1, r_2, \dots, r_m\}$.
 3. Alors $\delta_D(S, a) = \bigcup_{j=1}^m \text{ECLOSE}(r_j)$.

Exemple 4.3 Considérons l'automate $A = (Q, \Sigma, q_0, \delta, F)$ de l'exemple 4.1 et les fermetures calculées dans l'exemple 4.2.

Alors, l'automate $D = (Q_D, \Sigma, \delta_D, q_D, F_D)$ est donné par :

- $Q_D = \{\emptyset, \{q_1\}, \{q_2\}, \{q_1, q_2\}, \{q_0, q_1, q_2\}\}$. Les ensembles $\{q_0, q_1\}$ et $\{q_0, q_2\}$ sont des sous-ensembles de Q mais ne sont pas fermés sur ϵ .
- $q_D = \{q_0, q_1, q_2\} = \text{ECLOSE}(q_0)$.
- $F_D = \{\{q_2\}, \{q_1, q_2\}, \{q_0, q_1, q_2\}\}$, les ensembles contenant q_2 , étant acceptants de A .
- δ_D est exprimé sur le graphe de la figure 5.




FIGURE 5: Automate D . De par la construction par les parties de Q , le nombre de partie est exprimé en exponentiel, d'où la complexité du graphe. Ici, $\{q_0, q_2\}$ n'est pas atteignable et peut être supprimé.

Théorème 4.4 *Un langage L peut être représenté par un ANF si et seulement si il peut l'être par un ADF.*

Preuve 4.4.1 *Soit L un langage. Cette preuve étant une double implication, chacune peut être prouvée séparément.*

(\Leftarrow) *L peut être représenté par un ADF $\implies L$ peut être représenté par un ANF. Supposons qu'un automate $D = (Q_D, \Sigma, \delta_D, q_D, F_D)$ représente $L : L(D) = L$. L'ANF $A = (Q, \Sigma, q_0, \delta, F)$ correspondant est construit comme suit :*

- $Q = \{\{q\} | q \in Q_D\}$
- δ contient les transitions de D modifiées. Les objets retournés deviennent des ensembles d'états. C'est-à-dire, si $\delta_D(q, a) = p$ alors $\delta(q, a) = \{p\}$. De plus, pour chaque état $q \in Q_D$, $\delta(q, \epsilon) = \emptyset$.
- $q_0 = \{q_D\}$
- $F = \{\{q\} | q \in F_D\}$

Dès lors, les transitions sont les mêmes entre D et A , mais A précise explicitement qu'il n'y a pas de transition sur ϵ . Comme A représente le même langage, un ANF représente L .

(\Rightarrow) L peut être représenté par un ANF $\implies L$ peut être représenté par un ADF. Soit l'automate $A = (Q, \Sigma, q_0, \delta, F)$. Supposons qu'il représente L ($L = L(A)$). Considérons l'automate obtenu par la transformation détaillée à la section précédente 4.4 :

$$D = (Q_D, \Sigma, \delta_D, q_D, F_D)$$

Montrons que $L(D) = L(A)$. Pour ce faire, montrons que les fonctions de transition étendues sont équivalentes. Auquel cas, les chemins sont équivalents et donc les langages également. Montrons que $\hat{\delta}(q_0, w) = \hat{\delta}_D(q_D, w)$ pour tout mot w , par récurrence sur w .

Cas de base Si $|w| = 0$, $w = \epsilon$. $\hat{\delta}(q_0, \epsilon) = \text{ECLOSE}(q)$, par définition de la fonction de transition étendue. $q_D = \text{ECLOSE}(q_0)$ par la construction de q_D . Finalement, pour un ADF (ici, D), $\hat{\delta}(p, \epsilon) = p$, pour tout état p . Par conséquent, $\hat{\delta}_D(q_D, \epsilon) = q_D = \text{ECLOSE}(q_0) = \hat{\delta}(q_0, \epsilon)$.

Pas de récurrence Supposons $w = xa$ avec a le dernier symbole de w . Notre hypothèse de récurrence est que $\hat{\delta}_D(q_D, x) = \hat{\delta}(q_0, x)$. Notons cet ensemble comme $\{p_1, p_2, \dots, p_k\}$. Par définition de $\hat{\delta}$ pour un ANF, $\hat{\delta}(q_0, w)$ est obtenu en :

1. Soit $\{r_1, r_2, \dots, r_m\}$ donné par $\bigcup_{i=1}^k \delta(p_i, a)$, les états obtenus par la lecture du symbole a à partir de $\{p_1, p_2, \dots, p_k\}$.
2. Alors $\hat{\delta}(q_0, w) = \bigcup_{j=1}^m \text{ECLOSE}(r_j)$. Un état atteint par la lecture de a l'est aussi par $a\epsilon$.

D a été construit avec ces deux mêmes étapes pour $\delta_D(\{p_1, p_2, \dots, p_k\}, a)$. Dès lors, $\hat{\delta}_D(q_D, w) = \delta_D(\{p_1, p_2, \dots, p_k\}, a) = \hat{\delta}(q_0, w)$.

5 Opérations sur un automate

5.1 Équivalence avec une expression régulière

Proposition 5.1 Un langage peut être exprimé par un automate déterministe fini si et seulement si il peut être exprimé par une expression régulière.

Cette proposition étant une double implication, elle est vraie si les deux implications le sont. Soit un langage L .

Théorème 5.2 Il existe un automate déterministe A tel que $L(A) = L \implies$ il existe une expression régulière E telle que $L(E) = L$.

Preuve 5.2.1 Supposons qu'il existe un ADF $A = (Q, \Sigma, q_0, \delta, F)$ tel que $L(A) = L$. Q étant un ensemble fini, on peut définir sa cardinalité : $|Q| = n$. Supposons que ses états soient nommés $\{1, 2, \dots, n\}$. Il est possible de construire des expressions régulières par induction sur le nombre d'états considérés.

Posons E_{ij}^k l'expression régulière exprimant un langage constitué des mots w tels que $\delta(i, w) = j$ et qu'aucun état intermédiaire n'ait un nombre supérieur à k . Il n'y a pas de contrainte sur i et j .




FIGURE 6: Exemple : automate mettant $E_{1,3}^3$ en évidence

L'exemple ci-dessus illustre ce fait qu'aucun état supérieur à k ne peut faire partie des intermédiaires. Dans cet exemple, $E_{5,4}^3$ tolère la transition de 5 à 4 bien que supérieure à k : ce ne sont pas des intermédiaires. Construisons le langage par induction sur les états autorisés.

Cas de base $k = 0$. Comme tout état est numéroté 1 ou plus, aucun intermédiaire n'est accepté. La première possibilité est $i = j$ et indique un chemin de longueur 0. Auquel cas l'expression régulière représentant un chemin sans symbole est ϵ . Ce chemin doit être ajouté aux possibilités si $i = j$. La deuxième possibilité est $i \neq j$. Alors les chemins possibles ne se composent que d'un arc allant directement de i à j . Pour les construire :

Pour chaque paire i, j :

- Il n'existe pas de symbole a tel que $\delta(i, a) = j$. Alors, $R_{ij}^0 = \emptyset(+\epsilon)$
- Il existe un unique symbole a tel que $\delta(i, a) = j$. Alors, $R_{ij}^0 = a(+\epsilon)$
- Il existe des symboles a_1, a_2, \dots, a_k tels que $\forall l \in \{1, \dots, k\}, \delta(i, a_l) = j$. Alors, $R_{ij}^0 = a_1 + a_2 + \dots + a_k(+\epsilon)$

Pas de récurrence Supposons qu'il existe un chemin allant de i à j ne passant par aucun état ayant un numéro supérieur à k . La première possibilité est que le-dit chemin ne passe pas par k . Alors, le mot représenté par ce chemin fait partie du langage de E_{ij}^{k-1} . Seconde possibilité, le chemin passe par k une ou plusieurs fois comme représenté à la figure 7.




FIGURE 7: Un chemin de i à j peut être découpé en différent segment en fonction de k

Auquel cas, ces chemins sont composés d'une sous-chemin donnant un mot dans E_{ik}^{k-1} , suivi d'un sous-chemin donnant un ou plusieurs mots dans E_{kk}^{k-1} et finalement un mot dans E_{kj}^{k-1} .

En combinant les expressions des deux types, on obtient :

$$E_{ij}^k = E_{ij}^{k-1} + E_{ik}^{k-1}(E_{kk}^{k-1})^* E_{kj}^{k-1}$$

En commençant cette construction sur E_{ij}^n , comme l'appel se fait toujours à des chaînes plus courtes, éventuellement on retombe sur le cas de base. Si l'état initial est numéroté 1, alors l'expression régulière E exprimant L est l'union (+) des E_{1j}^n tel que j est un état acceptant.

Exemple 5.3 Construction d'une expression régulière à partir de l'automate de la figure suivante :




FIGURE 8: Un automate acceptant tout mot ayant un nombre impair de 0

La construction par récurrence commençant avec $k = 0$ le processus peut être représenté par des tableaux correspondant à différents k de façon croissante.

Première itération Dans la première itération, chaque expression se résume à un des trois cas de base, avec éventuellement ϵ si $i = j$ pour l'expression analysée.

	Cas de base
E_{11}^0	$1 + \epsilon$
E_{12}^0	0
E_{21}^0	0
E_{22}^0	$1 + \epsilon$

Seconde itération Ensuite, l'état 1 est autorisé comme état intermédiaire : $k = 1$. Ayant potentiellement un état intermédiaire, la formule de récurrence est utilisée.

	Formule de récurrence	Détail	Simplification
E_{11}^1	$E_{11}^0 + E_{11}^0(E_{11}^0)^*E_{11}^0$	$(1 + \epsilon) + (1 + \epsilon)(1 + \epsilon)^*(1 + \epsilon)$	1^*
E_{12}^1	$E_{12}^0 + E_{11}^0(E_{11}^0)^*E_{12}^0$	$0 + (1 + \epsilon)(1 + \epsilon)^*0$	1^*0
E_{21}^1	$E_{21}^0 + E_{21}^0(E_{11}^0)^*E_{11}^0$	$0 + 0(1 + \epsilon)^*(1 + \epsilon)$	01^*
E_{22}^1	$E_{22}^0 + E_{21}^0(E_{11}^0)^*E_{12}^0$	$(1 + \epsilon) + 0(1 + \epsilon)^*0$	$1 + 01^*0$

Troisième itération A la troisième itération, l'état 2 est autorisé comme état intermédiaire.

	Formule de récurrence	Détail	Simplification
E_{11}^2	$E_{11}^1 + E_{12}^1(E_{22}^1)^*E_{21}^1$	$1^* + 1^*0(1 + 01^*0)^*01^*$	$1^* + 1^*0(1 + 01^*0)^*01^*$
E_{12}^2	$E_{12}^1 + E_{12}^1(E_{22}^1)^*E_{22}^1$	$1^*0 + 1^*0(1 + 01^*0)^*(1 + 01^*0)$	$1^*0(1 + 01^*0)^*$
E_{21}^2	$E_{21}^1 + E_{22}^1(E_{22}^1)^*E_{21}^1$	$01^* + (1 + 01^*0)(1 + 01^*0)^*01^*$	$(1 + 01^*0)^*01^*$
E_{22}^2	$E_{22}^1 + E_{22}^1(E_{22}^1)^*E_{22}^1$	$(1 + 01^*0) + (1 + 01^*0)(1 + 01^*0)^*(1 + 01^*0)$	$(1 + 01^*0)^*$

Pour obtenir une expression régulière correspondant à l'automate, on s'intéresse à celle qui décrit un chemin entre l'état initial (1) et les états acceptants (uniquement 2 ici). Dès lors, $L(1^*0(1 + 01^*0)^*) = L$.

Cette expression régulière $1^*0(1 + 01^*0)^*$ décrit bien un nombre impair de 0. Il en faut absolument un, et tout ajout supplémentaire de se fait par paire. Cela correspond bien à un nombre impair.

Théorème 5.4 (\Leftrightarrow) Il existe une expression régulière E telle que $L(E) = L \implies$ il existe un automate déterministe A tel que $L(A) = L$.

Preuve 5.4.1 Comme tout ANF a un ADF équivalent (théorème 4.4), montrer qu'une expression régulière E a un ANF équivalent est suffisant pour obtenir cet ADF.

Soit L . Soit E une expression régulière telle que $L(E) = L$. On peut construire l'automate récursivement sur la définition des expressions régulières à la section 2.4. Cette preuve par récurrence repose sur trois invariants portant sur chaque ANF construit :

1. Il y a un unique état acceptant
2. Aucune transition ne mène à l'état initial
3. Aucune transition ne part de l'état acceptant

Cas de base Les ANF de la figure 9 représentent les automates correspondant aux trois cas de base.




FIGURE 9: Blocs de base pour la construction d'un automate à partir d'une expression régulière

En effet, l'automate (a) correspond à l'expression ϵ : le seul arc de l'état initial à un état final est ϵ . L'automate (b) ne propose pas d'arc atteignant l'état final. Aucun mot n'appartient au langage d'où la construction de \emptyset . Finalement, (c) propose un arc pour a , donnant le seul mot a comme faisant partie du langage, faisant de a une expression régulière équivalente. De plus, ces automates respectent bien l'invariant de récurrence proposé.

Pas de récurrence Les ANF abstraits de la figure 10 représentent la façon dont un automate peut être construit récursivement en fonction des règles de récurrence des expressions régulières. Ces ANF sont abstraits car le contenu d'un bloc R ou S n'est pas représenté explicitement. Cependant, celui-ci respecte les invariants de récurrence.




(a) $L = L(E)^*$ (b) $L = L(E)L(F)$ (c) $L = L(E) + L(F)$

FIGURE 10: Enchaînement de blocs pour une construction récursive

Les quatre règles de récurrence sur une expression régulière permettent de construire les automates :

- Pour une expression régulière de forme (E) , le langage $L(E)$ étant équivalent à $L((E))$, l'automate construit pour E reste valable.
- L'expression régulière est de forme E^* . Par induction, il existe un automate exprimant le même langage que E . L'automate pour E^* est construit comme en (a). Cet automate comprend un arc ϵ de l'état initial à l'état acceptant pour représenter le cas E^0 . Ensuite, un arc ϵ permet de concaténer plus chemins dans E , donnant des mots représentés par E^1, E^2, E^3, \dots . Le tout complétant l'ensemble des mots possibles des $L(E)^*$. On a bien $L(E^*) = L(E)^*$.
- L'expression régulière est de forme EF . Par induction, il existe des automates représentant les mêmes langages que E et F et respectant notre invariant. L'automate abstrait (b) représente cette concaténation. En effet, un mot de cet automate doit se composer d'un mot $v \in L(E)$ et d'un mot $w \in L(F)$. Les mots possibles sont alors de la forme vw . Donc (b) représente bien, selon la définition d'une expression régulière $L(EF) = L(E)L(F)$.
- L'expression régulière est de forme $E + F$. Alors, comme mis en évidence par l'automate abstrait (c), il existe des automates correspondants aux expressions E et F . Par cette construction, en particulier les transitions sur ϵ , permettent à c de représenter tout mot de $L(E)$ ou $L(F)$. Le langage est alors, en concordance avec la définition d'une expression régulière $L(E + F) = L(E) \cup L(F)$.

Les automates (a), (b) et (c) respectent bien l'invariant de récurrence : pas de transition vers l'état

initial, un seul état acceptant n'ayant pas de transition sortante. Chaque automate abstrait pour E ou F peut lui même être construit récursivement jusqu'au cas de base.

5.2 Équivalence d'états

Certains états d'un automate peuvent être *équivalents* selon la relation R_M . Celui-ci peut alors être simplifié. Une façon de détecter ces équivalences est de construire un tableau via l'*algorithme de remplissage de tableau*.

Celui-ci détecte les paires *différenciables*, récursivement sur un automate $A = (Q, \Sigma, q_0, \delta, F)$. Une paire $\{p, q\}$ est différenciable s'il existe un mot w tel qu'un chemin $\hat{\delta}(p, w)$ mène à un état acceptant et $\hat{\delta}(q, w)$ mène à un état non-acceptant ou vice-versa. w sert alors de *mot témoin*.

TODO : Environnement algorithmicx ?

Cas de base : Si p est un état acceptant et que q ne l'est pas, alors la paire $\{p, q\}$ est différenciable. Le mot témoin est ϵ .

Pas de récurrence : Soient p, q des états de Q et un symbole $a \in \Sigma$ tel que $\delta(p, a) = r$ et $\delta(q, a) = s$. Si r et s sont différenciables, alors p et q le sont aussi. En effet, il existe un mot *témoin* w qui permet de différencier r et s . Alors le mot aw est le mot témoin qui permet de différencier p et q .

Théorème 5.5 *Si deux états ne sont pas distingués par l'algorithme de remplissage de tableau, les états sont équivalents (ils respectent la relation R_M).*

Preuve 5.5.1 *Considérons un automate déterministe fini quelconque $A = (Q, \Sigma, q_0, \delta, F)$. Supposons par l'absurde qu'il existe une paire d'états $\{p, q\}$ tels que :*

1. p et q ne sont pas distingués par l'algorithme de remplissage de table.
2. Les états ne sont pas équivalents, $\not\models R_M q$. Par extension, il existe un mot témoin w différenciant p et q .

Une telle paire est une *mauvaise paire*. Si il y a des mauvaises paires, chacune distinguée par un mot témoin, il doit exister un paire distinguée par le mot témoin le plus court. Posons $\{p, q\}$ comme étant cette paire et $w = a_1 a_2 \dots a_n$ le mot témoin le plus court qui les distingue. Dès lors, soit $\hat{\delta}(p, w)$ est acceptant, soit $\hat{\delta}(q, w)$ l'est, mais pas les deux.

Ce mot w ne peut pas être ϵ . Auquel cas, la table aurait été remplie dès l'étape d'induction de l'algorithme. La paire $\{p, q\}$ ne serait pas une mauvaise paire, ne respectant pas l'hypothèse 1.


w n'étant pas ϵ , $|w| \geq 1$. Considérons les états $r = \delta(p, a_1)$ et $s = \delta(q, a_1)$. Ces états sont différenciés par $a_2 a_3 \dots a_n$ car $\hat{\delta}(p, w) = \hat{\delta}(r, a_2 a_3 \dots a_n)$ et $\hat{\delta}(q, w) = \hat{\delta}(s, a_2 a_3 \dots a_n)$ et p et q sont différenciables.

Cela signifie qu'il existe un mot plus petit que w qui différencie deux états : le mot $a_2 a_3 \dots a_n$. Comme on a supposé que w est le mot le plus petit qui différencie une mauvaise paire, r et s ne peuvent pas être une mauvaise paire. Donc, l'algorithme a du découvrir qu'ils sont différenciables.

Cependant, le pas de récurrence impose que $\delta(p, a_1)$ et $\delta(q, a_1)$ mènent à deux états différenciables implique que p et q le sont aussi. On a une contradiction de notre hypothèse : $\{p, q\}$ n'est pas une mauvaise paire.

Ainsi, s'il n'existe pas de mauvaise paire, c'est que chaque paire différenciable est reconnue par l'algorithme.

Exemple 5.6 Voici une application de cet algorithme sur l'automate A_2 , version réduite de l'automate A_1 de la figure 2.

FIGURE 11: Automate A_2

La première étape est de remplir la table avec l'algorithme précédant. Tout état est distinguable de q_3 : il est le seul état acceptant. 5 cases peuvent déjà être cochées. Le reste de la table est rempli par induction.

q_1	X				
q_2	X	X			
q_3	X	X	X		
q_4	X	X	X	X	
q_5	X		X	X	X
	q_0	q_1	q_2	q_3	q_4

FIGURE 12: Table filling pour A_2 , décelant des équivalences d'états

5.2.1 Complexité

Considérons n le nombre d'états d'un automate, et k la taille de l'alphabet Σ supporté.

Si il y a n états, il y a $\binom{n}{2}$ soit $\frac{n(n-1)}{2}$ paires d'états. A chaque itération (sur l'ensemble de la table), il faut considérer chaque paire, et vérifier si un de leur successeurs est différentiable. Cette étape prend au plus $O(k)$ pour tester chaque successeurs potentiel (en fonction du symbole lu). Ainsi, une itération sur la table se fait en $O(kn^2)$. Si une itération ne découvre pas de nouveaux état différentiable s'arrête. Comme la table a une taille en $O(n^2)$ et qu'à chaque étape un élément au minimum doit y être coché, la complexité totale de l'algorithme est en $O(kn^4)$.

Cependant, il existe des pistes d'amélioration. La première est d'avoir, pour chaque paire $\{r, s\}$ une liste des paire $\{p, q\}$ qui, pour un même symbole, mènent à $\{r, s\}$. On dit de ces paires qu'elles sont dépendantes. Si la paire $\{r, s\}$ est marquée comme différenciable, leurs paires dépendantes seront de facto différenciables.

Cette liste peut être construite en considérant chaque symbole $a \in \Sigma$ et ajoutant les paires $\{p, q\}$ à chacune de leur dépendance $\{\delta(p, a), \delta(q, a)\}$. Cette étape prend au plus $k.O(n^2) = O(kn^2)$. (Le nombre de symboles multiplié par le nombre de paires à considérer).

Ensuite, il suffit de partir des cas initiaux (se reposant sur le cas de base de l'algorithme), et de marquer tous leurs états dépendants comme différentiables, tout en ajoutant leur propre liste à chaque fois. La complexité de cette exploration est bornée par le nombre d'éléments dans une liste et le nombre de listes. Respectivement, k et $O(n^2)$, ce qui donne $O(kn^2)$ pour cette exploration.

La complexité totale revient à $O(kn^2)$.

5.3 Équivalence d'automates

Considérons les automates A_H et A_I donnés dans les figures 13 et 14




FIGURE 13: Automate A_H , du livre d'Hopcraft et al. de 1979[2] (Fig3.2)

Il est possible de remplir un tableau via l'algorithme éponyme. Pour ce faire, les deux automates sont considérés comme un seul dont les états sont disjoints.




FIGURE 14: Automate A_I , provenant également de [2]. Les états ont été renommés.

q_1								
q_2	x	x						
q_3	x	x						
q_4	x	x						
q_5	x	x	x	x	x			
q_6			x	x	x	x		
q_7	x	x				x	x	
q_8	x	x	x	x	x		x	x
	q_0	q_1	q_2	q_3	q_4	q_5	q_6	q_7

FIGURE 15: Tableau généré par l'application de l'algorithme sur A_H et A_I

De cette table, toujours grâce aux conclusions précédentes, il est possible d'extraire des classes d'équivalences :

- $C_0 = \{q_0, q_1, q_6\}$
- $C_1 = \{q_2, q_3, q_4, q_7\}$
- $C_2 = \{q_5, q_8\}$

En particulier, la classe C_0 souligne que les états initiaux sont équivalents. Cela signifie, par définition, que tout mot w lu en partant d'un de ces états sera soit accepté dans les deux automates, soit refusé dans les deux. A_H et A_I définissent donc le même langage.

5.4 Minimisation d'automate

La minimisation d'automate se fait en deux étapes :

1. Se débarrasser de tous les états injoignables : ils ne participent pas à la construction du langage représenté
2. Grâce aux équivalences d'états trouvées grâce à l'algorithme de remplissage de tableau défini au point 5.2, construire un nouvel automate.


Ces étapes vont être accompagnées d'un exemple, à savoir l'automate A_1 représenté à la figure 2.

L'état q_6 n'est pas atteignable : il peut être simplement supprimé. On obtient ainsi l'automate A_2 qui a servi d'exemple pour l'algorithme de remplissage de tableau, représenté à la figure 11.

Pour minimiser cet automate $A_2 = (Q, \Sigma, \delta, q_0, F)$, il faut :

1. Générer la table de différenciation (qui, pour cet exemple, est à la figure 12)
2. Séparer Q en classes d'équivalences
3. Construire l'automate canonique A_3 :
 - Soit S une des classes d'équivalence
 - Soit γ la fonction de transition sur S . Pour un symbole $a \in \Sigma$, alors il doit exister une classe d'équivalence T tel que pour chaque état q dans S , $\delta(q, a) \in T$. Sinon, c'est que deux états p et q dans S menant à différentes classes d'équivalences. Ces deux états sont différenciables, et ne pourraient pas appartenir tous deux à S par construction. On peut écrire $\gamma(S, a) = T$.
4. L'état initial de A_3 est la classe d'équivalence contenant l'état initial de A_2 (dans notre exemple, l'état s'y trouve seul)
5. Les états acceptants (F) de A_3 sont les classes d'équivalences qui contenaient des états acceptants de A_2 .

La table de la figure 12. Peut servir de base à la construction du nouvel automate suivant cet algorithme.

FIGURE 16: Automate A_3

Une expression régulière $((b + ab)b^*a(a + b)^*)$ peut être déduite pour L grâce à cet automate. Cette expression régulière est celle de l'exemple 2.6

TODO : Proof : cet automate est LE automate minimal

5.5 Construction d'automate depuis un langage

Soit le langage $A_N = \{w | w \text{ fini par } b \text{ et ne contient pas } bb\}$ défini sur $\Sigma_N = a, b$.

On peut diviser les mots en 3 ensembles :

- W_0 le sous-ensemble des mots ne finissant pas le symbole b
- W_1 celui des mots finissant par le symbole b mais ne contenant pas bb
- W_2 celui des mots contenant au moins bb

Il y a d'autres façons de construire des sous-ensembles, mais celle-ci à l'avantage de rendre la question de l'appartenance à L_N triviale : un mot appartient au second ensemble si et seulement si il fait partie du langage, par définition.

De plus, tous les éléments d'un sous-ensemble respectent la relation R_L entre eux. ($R_L : xR_Ly \Leftrightarrow \forall z \in \Sigma^*, xz \in L \Leftrightarrow yz \in L$). Cela en fait des classes d'équivalence sur cette relation.

Cela peut être démontré pour chaque sous-ensemble :

- Soient $x, y \in W_0$. Soit $z \in \Sigma^*$. Dès lors, si $xz \in L_N$, c'est que z fini par b mais ne contient pas bb , et donc $yz \in L_N$. Si $yz \in L_N$, le même argument peut être appliqué.
- Soient $x, y \in W_1$. Soit $z \in \Sigma^*$. Dès lors, si $xz \in L_N$, c'est que z ne commençait pas le symbole b et ne contenait pas bb , yz ne contiendra donc pas bb , puisque cette chaîne n'est ni dans z ni dans y , ni a cheval sur les deux, z ne commençant pas par b . Ainsi, $yz \in L_N$. Si $yz \in L_N$, le même argument peut être appliqué.
- Soient $x, y \in W_2$. Soit $z \in \Sigma^*$. Comme x contient déjà bb , $x \notin L_N$ et, a fortiori, $xz \notin L_N$. Comme la prémisse est fausse, l'implication $xz \in L \Rightarrow yz \in L$ est vraie. La même logique peut être appliquée à partir de y pour justifier l'implication inverse.

De plus, ces sous-ensembles sont disjoints. Cela peut se prouver en invalidant la relation pour certains éléments entre eux, mais dans ce cas-ci, la propriété est assurée par définition.

Ceci revient à démontrer que W_0, W_1, W_2 sont des classes d'équivalence. De plus, R_L respecte la congruence à droite, comme démontré dans la preuve du théorème de Myhill-Nérode.

Ce même théorème donne une méthode pour construire un automate : prendre un représentant pour chaque classe et en faire un état.

- $\Sigma = \{a, b\}$ est connu.
- $Q = \{[[\epsilon]], [[b]], [[bb]]\} = \{q_\epsilon, q_b, q_{bb}\}$
- $q_0 = q_\epsilon$
- $F = \{q_b\}$ l'union des classes acceptant
- δ défini en utilisant des exemples tirés des classes d'équivalence.

Ce qui donne l'automate de la figure 17




FIGURE 17: Automate A_N , exemple d'une thèse[3]

Cet automate est bien une représentation du langage L_N . Seul un mot finissant par b mais ne contenant pas bb se termine à l'état q_b .

6 Théorème de Myhill-Nérode

Cette section apporte le détail sur la relation de Myhill-Nérode, en prouve les propriétés avant d'en faire l'usage dans le théorème du même nom.

6.1 Relation de Myhill-Nérode

Soit un langage L sur un alphabet Σ .

Soit la relation R_L portant sur deux mots (ne faisant pas nécessairement partie de L). Deux mots x et y respectent la relation de Myhill-Nérode R_L si

$$\forall z \in \Sigma^*, xz \in L \Leftrightarrow yz \in L$$

Intuitivement, deux mots sont en relation si pour tout mot qu'on leur concatène, les deux mots résultants sont tous deux dans le langage ou non.

Lemme 6.1 *Cette relation est une relation d'équivalence. De plus, elle respecte la congruence à droite. C'est à dire que si $xR_L y$, alors pour tout symbole $a \in \Sigma$, $xaR_L ya$*

Preuve 6.1.1 (Equivalence et Congruence à droite) *Dire d'une relation qu'elle décrit une équivalence, revient à dire qu'elle est réflexive, transitive et symétrique*

- R_L est réflexive. Soit $x \in \Sigma^*$. Soit $z \in \Sigma^*$. Montrer que $xR_L x$ est vrai revient à montrer que $xz \in L \Leftrightarrow xz \in L$ est vrai. R_L est donc réflexive.

- R_L est symétrique. Soient $x, y \in \Sigma^*$ tels que xR_Ly . Soit $w \in \Sigma^*$. Montrer que yR_Lx revient à montrer que $yw \in L \Leftrightarrow xw \in L$. Or, par hypothèse, $xz \in L \Leftrightarrow yz \in L$, qui peut s'écrire aussi $yz \in L \Leftrightarrow xz \in L$ pour tout $z \in \Sigma^*$, et en particulier $z = w$.
- R_L est transitive. Soient $x, y, u \in \Sigma^*$ tels que xR_Ly et yR_Lz . Soit $w \in \Sigma^*$. Comme $xz \in L \Leftrightarrow yz \in L$ et $yz \in L \Leftrightarrow uz \in L$ pour tout $z \in \Sigma^*$ (par hypothèse), c'est vrai en particulier pour $z = w$. Dès lors, $xw \in L \Leftrightarrow yw \in L$ et $yw \in L \Leftrightarrow uw \in L$. Par transitivité de l'implication, on obtient $xw \in L \Leftrightarrow uw \in L$, à savoir xR_Lu .
- R_L est congruente à droite. Soient $x, y \in \Sigma^*$ tels que xR_Ly . Soit $a \in \Sigma$. Par hypothèse, $xz \in L \Leftrightarrow yz \in L$ pour tout $z \in \Sigma^*$. Cela doit donc être vrai en particulier pour le mot $z = aw$ avec w quelconque. En remplaçant dans l'hypothèse, on obtient $xaw \in L \Leftrightarrow yaw \in L$. Ce qui montre que xaR_Lya .

6.2 Théorème de Myhill-Nerode

Théorème 6.2 Les 3 énoncés suivants sont équivalents :

1. Un langage $L \subseteq \Sigma^*$ est accepté par un DFA
2. L est l'union de certaines classes d'équivalence d'index fini respectant une relation d'équivalence et de congruence à droite
3. Soit la relation d'équivalence $R_L : xR_Ly \Leftrightarrow \forall z \in \Sigma^*, xz \in L \Leftrightarrow yz \in L$ (la relation de Myhill-Nérode définie précédemment). R_L est d'index fini.

Preuve 6.2.1 La preuve d'équivalence se fait en prouvant chaque implication de façon cyclique :

(1) \rightarrow (2) Supposons que (1) soit vrai, c'est à dire que le langage L est accepté par un automate déterministe fini A . Considérons la relation d'équivalence R_M étant vraie pour les mots x, y si $\hat{\delta}(q_0, x) \in F \iff \hat{\delta}(q_0, y) \in F$. Elle a été définie en 3.5. Il y est prouvé qu'elle est congruente à droite. Comme il y a au plus une classe d'équivalence pour R_M par état de A . Comme ce nombre d'états est fini, R_M est d'index fini. De plus, L est l'union de classes contenant un mot w tel que $\hat{\delta}(q_0, w) \in F$, (or, ce chemin retourne un état. Il s'agit donc d'une union des classes correspondant aux états acceptants).

(2) \rightarrow (3) Montrons que pour toute relation E satisfaisant (2), chaque classe est intégralement contenue dans une seule classe de R_L . Ces classes étant d'index fini, c'est un argument suffisant pour déduire que R_L est d'index fini. Considérons x, y tels que xEy . Comme E est congruente à droite, pour tout mot $z \in \Sigma^*$, on sait que $xzEyz$. Comme L est un union de ces classes d'équivalence, $xzEyz$ implique que $xz \in L \Leftrightarrow yz \in L$, ce qui revient à xR_Ly . Cela signifie que tout mot dans la classe d'équivalence de x définie par E se retrouve dans la même classe d'équivalence que x par R_L . Ce qui permet de conclure que chaque classe d'équivalence de E est contenue dans une classe d'équivalence de R_L .

(3) \rightarrow (1) Considérons la relation R_L définie précédemment, et déduisons-en Q' les classes d'équivalence sur L et $[[x]]$ l'élément (la classe) de Q' qui contient x . Puisque R_L a été démontré comme congruent à droite, on peut définir des transitions : $\delta'([x], a) = [[xa]]$. En choisissant un élément y dans $[[x]]$ (ce qui signifie que xR_Ly), on obtient $\delta'([x], a) = [[ya]]$. Sauf que par définition, xR_Ly signifie qu'en y ajoutant n'importe quel mot z , xz et yz appartiennent tous deux ou non à L . C'est vrai en particulier pour $z = az'$. Ainsi, xaz' et yaz' appartiennent tous deux à L ou non. Ce qui signifie que xaR_Lya et donc $[[xa]] = [[ya]]$. Posons $q'_0 = [[\epsilon]]$ et $F' = \{[[x]] \mid x \in L\}$. Tous ces éléments forment l'automate

$M' = (Q', \Sigma, \delta', q'_0, F')$. Il est déterministe par la définition de δ' , fini car Q' est fini par construction (le nombre de classes d'équivalence est fini). De plus, il accepte L puisque $\delta'(q'_0, x) = [[x]]$, ce qui signifie que $x \in L(M')$ si et seulement si $[[x]] \in F'$, qui a été défini comme tel.

Corrolaire 6.2.2 Grâce à la preuve du théorème de Myhill-Néode, en particulier la justification partant de la relation d'équivalence R_L pour montrer que la langage $L \subseteq \Sigma^*$ est accepté par un DFA, on a une méthode pour construire un automate à partir d'un langage.

7 Algorithme d'Angluin

L'algorithme d'Angluin repose, en plus des éléments précédents sur quatre concepts :

- Une table d'observation
- La relation R_O , se basant sur la table d'observation et semblable à la relation R_L
- La propriété de fermeture (closure en anglais)
- La propriété de cohérence (consistence en anglais)

Cette section commence par décrire cette table en 7.1, la relation R_O en 7.2, la fermeture en 7.3, la cohérence en 7.4.

Une fois toutes ces bases posées, une exécution de l'algorithme sur un exemple est proposée en 7.5, suivie du fonctionnement formel de l'algorithme et des preuves sur son exactitude et sa complexité en 7.6, 7.7 et 7.8.

7.1 Table d'observation

7.2 Relation R_O

7.3 Fermeture

La propriété de fermeture (closure) s'exprime mathématiquement par

$$\forall u \in R, \forall a \in \Sigma, \exists v \in R, uaR_O v$$

En pratique, pour vérifier cette propriété, il suffit de suivre cet algorithme, expliqué de façon visuelle sur la table O :

Algorithme 1 Vérification de la fermeture**Promet:** si la fermeture est respectée ou non

```

1: pour chaque élément  $w$  de la section  $R$  faire
2:   pour chaque symbole  $a$  dans  $\Sigma$  faire
3:     si  $wa$  est dans  $R$  alors
4:       continuer
5:     sinon
6:        $\{wa \text{ est dans } R.\Sigma \text{ par construction}\}$ 
7:       si La ligne de  $wa$  dans  $T$  est différente de celle de  $w$  alors
8:         retourner Faux
9:       fin si
10:    fin si
11:  fin pour
12: fin pour
13: retourner Vrai

```

7.4 Cohérence

La propriété de cohérence (consistence) se définit mathématiquement comme

$$\forall u, v \in R, uR_O v \Rightarrow \forall a \in \Sigma, uaR_O va$$

Concrètement, il s'agit de prendre deux mots (u, v) dans R ayant la même ligne dans T et vérifier, pour chaque symbole (a) , s'ils (ua, va) ont la même ligne dans T .

7.5 Exemple


Considérons l'automate A_3 de la figure 16 construit à la section 5.4 sur la minimisation.

TODO : Marquer la différence entre R_L et R_O

7.5.1 Première itération

L'algorithme d'Angluin précise, pour son cas de base, une initialisation de la table T avec les ensembles R et S contenant uniquement ϵ . Le champ $R.\{a, b\}$ ($R.\Sigma$) est rempli via des requête d'appartenance sur les mots a et b .

O_0	ϵ
ϵ	0
a	0
b	0

Automate O_0

L'étape suivante consiste à vérifier la *closure* de la table d'observation O_0 . Mathématiquement :

$$\forall u \in R, \forall a \in \Sigma, \exists v \in R, uaR_Lv$$

Intuitivement, pour chaque symbole (ici, $\{a, b\}$, et ce sera vrai jusqu'à la dernière itération), tout mot candidat (dans R , la partie supérieure de la table) doit se retrouver, complété de ce symbole, dans une classe d'équivalence d'un autre candidat de R . Ici, de toute évidence, les mots a et b sont dans la même classe d'équivalence que ϵ . Dès lors, la propriété de *closure* est respectée.

Si la *closure* est respectée, alors la question de la *consistence* (cohérence) se pose. Mathématiquement :

$$\forall u, v \in R, uR_Lv \Rightarrow \forall a \in \Sigma, uaR_Lva$$

Intuitivement, si deux candidats semblent être dans la même classe d'équivalence (leur lignes dans la table supérieure sont identiques), alors pour n'importe quel symbole, les deux nouveaux mots sont également dans une même classe d'équivalence (leur lignes, potentiellement dans la partie inférieure de la table, sont identiques). N'ayant qu'un seul candidat, cette propriété est forcément respectée (R_L est réflexive).

Les deux propriétés étant respectées, les classes d'équivalences sont calculées (trivialement ici), et un automate O_0 est proposé à l'enseignant pour vérification.


Sur cette itération, un automate initial a été proposé, et aucun état final ne pouvant être atteint avec un seul symbole, la version est minime.

7.5.2 Seconde itération

L'enseignant répond que non, les automates ne sont pas équivalents. Il fournit le contre-exemple ba . Comme il est rejeté par O_0 , cela signifie qu'il est accepté par A_4 . Une nouvelle table est alors construite, en ajoutant ba et ses préfixes (ici, juste b) à R . $R.\Sigma$ est calculé et les mots n'ayant pas encore reçu une valeur dans T sont soumis à l'enseignant pour un test d'appartenance.

O_1	ϵ
ϵ	0
b	0
ba	1
a	0
bb	0
baa	1
bab	1

O_2	ϵ	a
ϵ	0	0
b	0	1
ba	1	1
a	0	0
bb	0	1
baa	1	1
bab	1	1



Comme pour la première itération, la *fermeture* est testée, suivie de la *cohérence*. Celle-ci n'est pas respectée : si on considère les mots ϵ et b , qui ont la même ligne dans la table T ($\epsilon R_O b$), le

symbole a , on obtient les mots a et ba qui n'ont pas la même ligne : ($\neq R_O ba$). Le symbole a est alors ajouté à S et une nouvelle table O_2 est calculée.

La fermeture étant déjà vérifiée, la question de la cohérence est reposée, et cette fois-ci elle est vérifiée; l'automate est construit et proposé à l'enseignant.

Sur cette itération, l'algorithme a reçu le mot ba comme étant accepté. Il a du ajouter a à S pour permettre de différencier certains états. L'automate se voit ajouter les états $[[b]]$ et $[[ba]]$.

7.5.3 Troisième itération


Suivant toujours l'algorithme de comparaison d'automates détaillé dans la section ??, l'enseignant découvre qu'ils sont différents.

Il sort le contre-exemple $aaba$. Si c'est un contre-exemple et qu'il est accepté par O_2 , c'est qu'il ne l'est pas (0) par A_4 . Une nouvelle table O_3 doit être construite.

O_3	ϵ	a
ϵ	0	0
a	0	0
b	0	1
aa	0	0
ba	1	1
aab	0	0
$aaba$	0	0
ab	0	1
bb	0	1
aaa	0	0
baa	1	1
bab	1	1
$aabb$	0	0
$aabaa$	0	0
$aabab$	0	0

O_4	ϵ	a
ϵ	0	0
a	0	0
b	0	1
aa	0	0
ab	0	1
ba	1	1
aab	0	0
$aaba$	0	0
bb	0	1
aaa	0	0
aba	1	1
abb	0	1
baa	1	1
bab	1	1
$aabb$	0	0
$aabaa$	0	0
$aabab$	0	0

O_5	ϵ	a
ϵ	0	0
a	0	0
b	0	1
aa	0	0
ab	0	1
ba	1	1
aab	0	0
aba	1	1
$aaba$	0	0
bb	0	1
aaa	0	0
abb	0	1
baa	1	1
bab	1	1
$aabb$	0	0
$abaa$	1	1
$abab$	1	1
$aabaa$	0	0
$aabab$	0	0

Automate O_5

Ayant reçu $aaba$, ce mot et tous ses préfixes sont ajoutés à la table. L'extension $R.\Sigma$ est recalculée et la table O_3 est construite.

Ensuite, la question de la *fermeture* est posée. Un manquement est détecté : le mot a . En effet, en lui ajoutant le symbole b , on obtient ab qui n'est ni dans R ni en relation R_O avec a . ab est alors ajouté à R , et $R.\Sigma$ est étendu. La nouvelle table, O_4 est de nouveau testée.

O_4 ne respecte pas la fermeture : le mot ab , agrémenté du symbole a donne le mot aba , qui n'est ni dans R ni en relation avec ab . Le mot est ajouté à R , et la table est étendue. La nouvelle table, O_5 est à la fois fermée et cohérente.

L'automate O_5 est alors proposé à l'enseignant pour vérification. Celui-ci est accepté (isomorphe à A_4). L'algorithme s'arrête et un automate minimal pour le langage a été construit.

7.6 Algorithme

7.7 Preuve

7.8 Complexité

Références

- [1] J. E. HOPCROFT, *Introduction to Automata Theory, Languages, and Computation (2nd Edition)*, Addison Wesley, nov 2000.
- [2] J. E. HOPCROFT AND J. D. ULLMAN, *Introduction to automata theory, languages and computation. adison-wesley*, Reading, Mass, (1979).
- [3] D. NEIDER, *Applications of automata learning in verification and synthesis*, PhD thesis, Hochschulbibliothek der Rheinisch-Westfälischen Technischen Hochschule Aachen, 2014.