

# UMONS



Faculté  
des Sciences

## Vérification de la sécurité d'automates à file par apprentissage actif

**Étudiant :** Benjamin André  
**Directrice :** Véronique Bruyère  
10 novembre 2020

# Table des matières

<b>1</b>	<b>Introduction</b>	<b>5</b>
<b>2</b>	<b>Bases théoriques</b>	<b>6</b>
2.1	Langage . . . . .	6
2.1.1	Définitions . . . . .	6
2.1.2	Opérations sur les langages . . . . .	7
2.1.3	Expressions régulières . . . . .	7
2.2	Automate Fini . . . . .	8
2.2.1	Définitions . . . . .	8
2.2.2	Représentation graphique . . . . .	10
2.2.3	ECLOSE . . . . .	11
2.2.4	Langage . . . . .	11
2.2.5	Équivalence entre expression régulière et automate . . . . .	14
2.2.6	Équivalence entre un automate déterministe fini et un automate non-déterministe fini . . . . .	20
2.3	Table Filling Algorithm . . . . .	23
2.3.1	Relation $R_E$ . . . . .	23
2.3.2	Algorithme . . . . .	25
2.3.3	Appartenance et équivalence . . . . .	27
2.3.4	Minimisation . . . . .	29
2.4	Algorithme d'Angluin . . . . .	31
2.4.1	La relation $R_L$ . . . . .	32
2.4.2	Théorème de Myhill-Nerode . . . . .	33
2.4.3	La table d'observation . . . . .	34
2.4.4	Fermeture et cohérence . . . . .	35
2.4.5	L'algorithme . . . . .	36
<b>3</b>	<b>Notions spécifiques à LeVer</b>	<b>41</b>
3.1	Problème . . . . .	41
3.2	Automate FIFO . . . . .	42
3.2.1	Définitions . . . . .	42
3.2.2	Produit cartésien . . . . .	44
3.3	Trace d'automate . . . . .	45
3.3.1	Langage tracé . . . . .	45

3.3.2	Alphabet d'annotation . . . . .	46
3.3.3	Trace annotée . . . . .	47
3.3.4	Fonction d'extension de trace . . . . .	47
3.4	Sécurité d'un automate FIFO . . . . .	49
3.4.1	Définitions . . . . .	49
3.4.2	Traces annotées menant à des états n'étant pas sûrs . . . . .	49
<b>4</b>	<b>LeVer</b> . . . . .	<b>51</b>
4.1	Appartenance . . . . .	52
4.2	Équivalence . . . . .	52
4.3	Vue d'ensemble . . . . .	52
<b>5</b>	<b>Implémentation</b> . . . . .	<b>53</b>
5.1	Choix . . . . .	53
5.2	Résultats . . . . .	53
<b>6</b>	<b>Conclusion</b> . . . . .	<b>54</b>
<b>7</b>	<b>Brouillon</b> . . . . .	<b>55</b>
7.1	Lost . . . . .	55
7.1.1	Construction d'un automate depuis un langage régulier . . . . .	55
7.1.2	Alternating Bit Protocol . . . . .	56
7.2	Algorithme de membership . . . . .	57

## Environnements théoriques

Proposition 2.1.1 $\epsilon$ et la concaténation . . . . .	6
Théorème 2.2.1 ADF et expression régulière . . . . .	14
Théorème 2.2.2 ADF $\implies$ expression régulière . . . . .	14
Preuve 2.2.2.1 . . . . .	15
Théorème 2.2.3 Expression régulière $\implies$ ADF . . . . .	17
Preuve 2.2.3.1 . . . . .	17
Théorème 2.2.4 ANF $\Leftrightarrow$ ADF . . . . .	21
Preuve 2.2.4.1 . . . . .	21
Proposition 2.3.1 $R_E$ . . . . .	23
Preuve 2.3.1. $R_E$ est une relation d'équivalence . . . . .	24
Proposition 2.3.2 Congruence de $R_E$ . . . . .	24
Preuve 2.3.2. Congruence de $R_E$ . . . . .	24
Théorème 2.3.3 Table de différenciation . . . . .	25
Preuve 2.3.3.1 . . . . .	26
Théorème 2.3.4 Minimalité de l'automate réduit . . . . .	30
Preuve 2.3.4.1 . . . . .	30
Preuve 2.3.4.2 . . . . .	31
Théorème 2.4.1 . . . . .	32
Lemme 2.4.2 . . . . .	32
Preuve 2.4.2. Equivalence et Congruence à droite . . . . .	32
Lemme 2.4.3 . . . . .	33
Preuve 2.4.3.1 . . . . .	33
Théorème 2.4.4 . . . . .	33
Preuve 2.4.4.1 . . . . .	33
Proposition 2.4.5 . . . . .	34
Preuve 2.4.5.1 . . . . .	34
Théorème 3.3.1 . . . . .	48
Théorème 3.4.1 . . . . .	50

## Exemples

Exemple 1	Définition d'un langage . . . . .	7
Exemple 2	Expression régulière . . . . .	8
Exemple 3	Automate déterministe fini . . . . .	9
Exemple 4	Automate non-déterministe fini avec transitions sur $\epsilon$ . . . . .	9
Exemple 5	Graphe d'automate . . . . .	10
Exemple 6	ECLOSE . . . . .	11
Exemple 7	Chemin . . . . .	12
Exemple 8	. . . . .	12
Exemple 9	. . . . .	13
Exemple 10	Construction d'une expression régulière . . . . .	16

Exemple 11	Transformation ANF vers ADF . . . . .	21
Exemple 12	Table de différenciation . . . . .	25
Exemple 13	. . . . .	29
Exemple 14	. . . . .	36
Exemple 15	. . . . .	43
Exemple 16	. . . . .	44
Exemple 17	. . . . .	46
Exemple 18	. . . . .	47

## Environnements algorithmiques

Algorithme 2.2.1	Appartenance d'un mot à un langage défini par un automate . . . . .	13
Complexité 2.2.1.	Lecture d'un mot par un automate . . . . .	14
Complexité 2.2.2.1	. . . . .	16
Complexité 2.2.3.1	. . . . .	20
Complexité 2.2.4.	Conversion ANF vers ADF . . . . .	22
Complexité 2.2.4.	Conversion ADF vers ANF . . . . .	23
Complexité 2.3.1.1	. . . . .	27
Algorithme 2.3.2	Équivalence entre deux automates . . . . .	28
Complexité 2.3.2.1	. . . . .	29
Algorithme 2.3.3	Minimisation . . . . .	29
Algorithme 2.4.1	Algorithme d'Angluin $L^*$ . . . . .	36
Algorithme 2.4.2	<i>corriger</i> ( $O$ ) . . . . .	37
Algorithme 7.2.1	Appartenance à $AL(F)$ . . . . .	57

# Chapitre 1

## Introduction

Septième version du document.

Le but de ce mémoire est de comprendre et implémenter l'article "Actively learning to verify safety for FIFO automata" [8].

Pour ce faire, plusieurs étapes sont nécessaires. Dans le chapitre 2, les bases théoriques et leurs notations sont rappelées. Celles-ci concernent les automates, les langages et l'algorithme d'Angluin.

Dans le chapitre ??, l'article en question est discuté. La technique choisie est expliquée et les concepts spécifiques et ceux introduits par l'article sont définis. Ceux-ci concernent les automates FIFO, la notion de sécurité, et des notations propres à cet article. La section se finit par une explication de l'algorithme obtenu.

Ensuite, le chapitre 5 mentionne les choix techniques faits pour l'implémentation avant de présenter et discuter les résultats obtenus.

Finalement, le chapitre 6 résume l'apport et les conséquences de ce travail avant de proposer des pistes d'amélioration.

# Chapitre 2

## Bases théoriques

Dans la section 2.1, les notions de langage sont posées. Elles sont ensuite utilisées dans la section 2.2 sur les automates. L'algorithme "Table Filling" de la section 2.3 se base sur ces automates et permet de minimiser et répondre à la requête d'équivalence. Cette requête d'équivalence est une des deux requêtes nécessaire au fonctionnement de l'algorithme d'angluin de la section 2.4.

Tous ces éléments combinés permettent la compréhension de l'article [8].

### 2.1 Langage

Cette section pose les différents concepts et notations pour arriver à la notion de langage. Celles-ci reprennent les notations proposées par Hopcroft et al. [4]. Un sous-ensemble de ces langages correspond à des automates, sujet central de ce document.

#### 2.1.1 Définitions

Un *alphabet*  $\Sigma$  est un ensemble fini et non vide de *symboles*. Un *mot* sur cet alphabet  $\Sigma$  est une suite finie de  $k$  éléments de  $\Sigma$  notée  $w = a_1 a_2 \dots a_k$  où  $k$  est un nombre naturel.  $k$  est la *longueur* de ce mot aussi notée  $|w| = k$ . Le *mot vide* est un mot de taille  $k = 0$  noté  $w = \epsilon$ .

La *concaténation* de deux mots  $w = a_1 a_2 \dots a_k$  et  $x = b_1 b_2 \dots b_j$  est l'opération consistant à créer un nouveau mot  $wx = a_1 a_2 \dots a_k b_1 b_2 \dots b_j$  de longueur  $i = k + j$ .

**Proposition 2.1.1 ( $\epsilon$  et la concaténation)**  $\epsilon$  est l'identité pour la concaténation, à savoir pour tout mot  $w$ ,  $w\epsilon = \epsilon w = w$ .

Cette proposition est triviale par la définition de la concaténation.

L'*exponentiation* d'un symbole  $a$  à la puissance  $k$ , notée  $a^k$ , retourne un mot de longueur  $k$  obtenu par la concaténation de  $k$  copies du symbole  $a$ . Noter que  $a^0 = \epsilon$ .  $\Sigma^k$  est l'ensemble des mots sur  $\Sigma$  de longueur  $k$ . L'ensemble de *tous les mots possibles sur  $\Sigma$*  est noté  $\Sigma^* = \bigcup_{k=0}^{\infty} \Sigma^k$ .

Un ensemble quelconque de mots sur  $\Sigma$  est un *langage*, noté  $L \subseteq \Sigma^*$ . Étant donné que  $\Sigma^*$  est infini,  $L$  peut l'être également.

**Exemple 1 (Définition d'un langage)**

Voici des exemples utilisant plusieurs modes de définition.  $\Sigma$  y est implicite mais peut être donné explicitement.

- $L = \{12, 35, 42, 7, 0\}$ , un langage défini explicitement
- $L = \{0^k 1^j \mid k + j = 7\}$ , les mots de 7 symboles sur  $\Sigma = \{0, 1\}$  commençant par zéro, un ou plusieurs 0 et finissant par zéro, un ou plusieurs 1. Ici,  $L$  est donné par notation ensembliste
- $L$  contient tous les noms de villes belges. Ici  $L$  est défini en langage courant.
- $\emptyset$  est un langage pour tout alphabet.
- $L = \{\epsilon\}$  ne contient que le mot vide, et est un langage sur tout alphabet.

**2.1.2 Opérations sur les langages**

Soient  $L$  et  $M$  deux langages. Le langage  $L \cup M = \{w \mid w \in L \vee w \in M\}$  est l'*union* de ces deux langages. Il est composé des mots venant d'un des deux langages.

Le langage composé de tous les mots produits par la concaténation d'un mot de  $L$  avec un mot de  $M$  est une *concaténation* de ces deux langages et s'écrit  $LM = \{vw \mid v \in L \wedge w \in M\}$ .

La *fermeture* de  $L$  est un langage constitué de tous les mots qui peuvent être construits par une concaténation d'un nombre arbitraire de mots de  $L$ , noté  $L^* = \{w_1 w_2 \dots w_n \mid n \in \mathbb{N}, \forall i \in \{1, 2, \dots, n\}, w_i \in L\}$ .

**2.1.3 Expressions régulières**

Certains langages peuvent être exprimés par une *expression régulière*.

Les expressions régulières suivent un algèbre avec ses opérations et leur priorités. Une expression régulière est définie de façon récursive, étant elle-même composée d'expressions régulières ou de symboles. Les différentes opérations décrivent comment une expression plus complexe est construite à partir de ses composants. Pour une expression régulière  $E$ , le langage décrit est noté  $L(E)$ . Un langage qui peut être décrit par une expression régulière est dit *langage régulier*.

**Cas de base** Certains langages peuvent être construits directement sans passer par l'induction :

- $\epsilon$  est une expression régulière. Elle décrit le langage  $L(\epsilon) = \{\epsilon\}$
- $\emptyset$  est une expression régulière décrivant  $L(\emptyset) = \emptyset$
- Si  $a$  est un symbole, alors  $a$  est une expression régulière décrivant le langage  $L(a) = \{a\}$ .

**Induction** Les autres langages réguliers sont construits suivant différentes règles d'induction présentées par ordre décroissant de priorité :

- Si  $E$  est une expression régulière, alors  $(E)$  est une expression régulière et  $L((E)) = L(E)$ .
- Si  $E$  est une expression régulière, alors  $E^*$  est une expression régulière représentant la fermeture de  $L(E)$ , à savoir  $L(E^*) = L(E)^*$ .
- Si  $E$  et  $F$  sont des expressions régulières, alors  $EF$  est une expression régulière décrivant la concaténation des deux langages représentés, à savoir  $L(EF) = L(E)L(F)$ .



- Si  $E$  et  $F$  sont des expressions régulières, alors  $E + F$  est une expression régulière donnant l'union des deux langages représentés, à savoir  $L(E + F) = L(E) \cup L(F)$ . Ici encore, l'opération est associative et la priorité est à gauche.

### Exemple 2 (Expression régulière)

Soit l'expression  $E = (b + ab)b^*a(a + b)^*$  qui décrit le langage  $L = L(E)$ .

- Le mot  $ba$  fait partie de  $L$ . En effet,  $ba = b\epsilon a\epsilon = (b)b^0a(a + b)^0$ , ce qui respecte bien la définition de  $E$ .
- Le mot  $ababbab$  fait partie de  $L$ . A nouveau,  $ababbab = ab\epsilon a(a + b)(a + b)(a + b)(a + b) = (ab)b^0a(a + b)^4$ .
- Le mot  $aa$  ne fait **pas** partie de  $L$ . Supposons par l'absurde que  $aa \in L$ . Alors il existerait une façon de décomposer  $E$  en  $aa$ . Or, les premiers symboles doivent être soit  $b$ , soit  $ab$ . Il y a contradiction. Donc,  $aa \notin L$ .

Un autre exemple d'expression régulière est  $E = 01^*0$ .  $E$  décrit le langage  $L(E)$  constitué de tous les mots commençant et finissant par 0 avec uniquement des 1 entre les deux.

## 2.2 Automate Fini

Cette section décrit les automates finis, fait le lien avec la notion de langage régulier et propose une représentation visuelle de ces automates. La notation suivie dans cette section s'appuie principalement sur [5], [4] et [6].

### 2.2.1 Définitions

Un *automate fini*  $A = (Q, \Sigma, q_0, \delta, F)$  est défini comme suit :

- $Q$  est un ensemble fini d'états
- $\Sigma$  est un alphabet
- $q_0 \in Q$  est l'état initial
- $\delta$  est la fonction de transition
- $F \subseteq Q$  est un ensemble d'états acceptants.

La fonction de transition  $\delta$  est définie différemment en fonction du type d'automate souhaité :

- **Automate Déterministe Fini (ADF)**  $\delta : Q \times \Sigma \rightarrow Q$ . Soit un état  $q$  et un symbole  $a$ . Alors la transition  $\delta(q, a)$  retourne un état  $p$ .  $\delta(q, a)$  doit être définie pour tout état et tout symbole.
- **Automate Non-déterministe Fini (ANF)**  $\delta : Q \times \Sigma \rightarrow 2^Q$ . Soit un état  $q$  et un symbole  $a$ . Alors la transition  $\delta(q, a)$  retourne un ensemble d'états  $P = \{p_1, p_2, \dots, p_n\} \subseteq Q$ .
- **Automate Non-déterministe Fini avec des transitions sur  $\epsilon$  ( $\epsilon$ -ANF)**  $\delta : Q \times \Sigma \cup \{\epsilon\} \rightarrow 2^Q$ . Pareil que précédemment mais une transition peut exister sans symbole : elle se fait alors sur  $\epsilon$ .

Lorsqu'un automate est mentionné dans ce document, il s'agit implicitement d'un  $\epsilon$ -ANF, sauf mention contraire. En effet, c'est la forme la plus générale. Cependant, ces trois types d'automates ont la même puissance expressive, ce qui est prouvé dans la section 2.2.6.

Soit la transition  $\delta(q, a) = p$  (dans un ADF). Pour  $q$ , c'est une *transition sortante sur  $a$* . Pour  $p$ , c'est une *transition entrante sur  $a$* . On peut aussi dire que  $p$  est *atteignable*. Si au contraire aucune transition de la forme  $\delta(q, a) = p$  n'existe et que  $p$  n'est pas l'état initial, alors  $p$  est *inatteignable*.

Si  $\delta(q, a) = P = \{p_1, p_2, \dots, p_n\}$  dans un ANF, alors les états  $\{p_1, p_2, \dots, p_n\}$  auront une transition entrante sur  $a$ .

Dans le cas des ANF et  $\epsilon$ -ANF, il peut être pratique d'utiliser  $\delta$  sur un ensemble d'états  $S$ . A ce moment,  $\delta(S, a) = \bigcup_{q \in S} \delta(q, a)$  avec  $a \in \Sigma$ .

### Exemple 3 (Automate déterministe fini)

On considère l'automate  $A = (Q, \Sigma, q_0, \delta, F)$  défini comme suit :

- $Q = \{q_0, q_1, q_2, q_3, q_4, q_5, q_6\}$
- $\Sigma = \{a, b\}$
- $q_0$  est l'état du même nom
- La fonction de transition  $\delta$  est décrite par la table 2.1. L'intersection d'une ligne reprenant un élément  $q \in Q$  et d'une colonne  $a \in \Sigma$  donne l'état  $\delta(q, a)$ .
- $F = \{q_3\}$

	a	b
$\rightarrow q_0$	$q_2$	$q_1$
$q_1$	$q_3$	$q_5$
$q_2$	$q_4$	$q_5$
$q_3^*$	$q_3$	$q_3$
$q_4$	$q_4$	$q_4$
$q_5$	$q_3$	$q_1$
$q_6$	$q_4$	$q_5$

TABLE 2.1: La *table de transitions*  $\delta$  d'un ANF

Cette table de transitions est construite comme suit :

- Les en-têtes de colonnes sont des symboles appartenant à  $\Sigma$ .
- Les en-têtes de lignes sont des états  $q \in Q$ .
- Un cellule à la croisée de la ligne  $q$  et du symbole  $a$  contient un état  $p$  avec  $p = \delta(q, a)$ .

Via la notation de la table 2.1,  $Q$  et  $\Sigma$  sont explicites. En dénotant l'état initial par  $\rightarrow$  et les états acceptants par  $*$  en exposant, on obtient une définition complète d'un automate :  $(Q, \Sigma, q_0, \delta, F)$ .

### Exemple 4 (Automate non-déterministe fini avec transitions sur $\epsilon$ )

De la même façon que pour l'exemple précédent, considérons un automate  $A = (Q, \Sigma, q_0, \delta, F)$  défini comme suit :

- $Q = \{q_0, q_1, q_2\}$
- $\Sigma = \{a, b, c\}$

- $q_0$  est l'état du même nom
- $\delta$  est donnée par la table 2.2.
- $F = \{q_2\}$

$A$  est un  $\epsilon$ -ANF; une colonne supplémentaire sert à représenter la transition sur  $\epsilon$ .

	$\epsilon$	a	b	c
$\rightarrow q_0$	$\{q_1, q_2\}$	$\emptyset$	$\{q_1\}$	$\{q_2\}$
$q_1$	$\emptyset$	$\{q_0\}$	$\{q_2\}$	$\{q_0, q_1\}$
$q_2^*$	$\emptyset$	$\emptyset$	$\emptyset$	$\emptyset$

TABLE 2.2: La table de transitions  $\delta$  d'un  $\Sigma$ -ANF

Une table similaire sans la colonne  $\epsilon$  représenterait un  $ANF$  au sens strict. Celui-ci ne serait pas pour autant équivalent à l' $\epsilon$ -ANF de la table 2.2.

## 2.2.2 Représentation graphique

Le graphe d'un automate fini  $A = (Q, \Sigma, q_0, \delta, F)$  est un graphe dirigé construit comme suit :

- Chaque état de  $Q$  est représenté par un nœud.
- Chaque transition  $\delta(q, a)$  est représenté par un arc étiqueté  $a$ . Dans le cas d'un automate non-déterministe, un arc existe pour chacun des états obtenus en suivant la transition. Si il y a plusieurs transitions sortant d'un même état et entrant dans un même autre état, les arcs peuvent être fusionnés en listant les étiquettes.
- L'état initial est mis en évidence par une flèche entrante.
- Les états acceptants sont représentés par un double cercle, en opposition au simple cercle des autres nœuds.

### Exemple 5 (Graphe d'automate)

Voici les graphes représentant les automates définis dans les tables 2.1 et 2.2 :




FIGURE 2.1: Graphe de l'ADF de la table 2.1




FIGURE 2.2: Graphe du  $\Sigma$ -ANF de la table 2.2

Cette représentation a l'avantage d'être plus visuelle, alors que la table de transition est plus structurée.

### 2.2.3 ECLOSE

Cette sous-section introduit l'algorithme ECLOSE. Cet algorithme concerne les  $\epsilon$ -ANF. Il permet, à partir d'un état spécifique, de calculer l'ensemble des états atteignables uniquement par des transitions sur  $\epsilon$ . Ce calcul sert notamment au test d'appartenance d'un mot à un  $\epsilon$ -ANF.

Soit un  $\epsilon$ -ANF  $A = (Q, \Sigma, q_0, \delta, F)$ . Il est possible de construire une fonction retournant l'ensemble des états atteints uniquement en suivant des transitions sur  $\epsilon$  pour un état  $q$  donné. Cette fonction est la *fermeture sur epsilon*  $ECLOSE : Q \rightarrow 2^Q$ . Sa définition est inductive.

Soit  $q$  un état dans  $Q$ .

**Cas de base**  $q$  est dans  $ECLOSE(q)$

**Pas de récurrence** Si  $p$  est dans  $ECLOSE(q)$  et qu'il existe un état  $r$  tel que  $r \in \delta(p, \epsilon)$ , alors  $r$  est dans  $ECLOSE(q)$

ECLOSE peut être utilisé indifféremment sur un ensemble d'états  $S$  ( $ECLOSE : 2^Q \rightarrow 2^Q$ ). Alors,  $ECLOSE(S) = \bigcup_{q \in S} ECLOSE(q)$

#### Exemple 6 (ECLOSE)

Considérons l'automate  $A$  de l'exemple 4. Les différentes fermetures peuvent être calculées :

- $ECLOSE(q_0) = \{q_0, q_1, q_2\}$ . En effet,  $q_0$  appartient à sa fermeture, selon le cas de base. Aussi,  $q_1, q_2 \in \delta(q_0, \epsilon)$
- $ECLOSE(q_1) = \{q_1\}$  par le cas de base.
- $ECLOSE(q_2) = \{q_2\}$  par le cas de base.

### 2.2.4 Langage

Un automate représente un langage. Cette section explique comment il le fait pour les 3 catégories d'automates.

#### Fonction de transition étendue

La *fonction de transition étendue*  $\hat{\delta}$  est une extension de la fonction de transition, acceptant plusieurs symboles de façon consécutive. Intuitivement, il s'agit de suivre plusieurs arcs sur le graphe.

Comme  $\delta$  est différente en fonction du type d'automate considéré,  $\hat{\delta}$  l'est aussi.

- **ADF** :  $\hat{\delta} : Q \times \Sigma^* \rightarrow Q$ .  $\hat{\delta}$  prend en entrée un état de  $Q$  et un mot  $w$  sur  $\Sigma$  et retourne un état de  $Q$ .
- **ANF et  $\epsilon$ -ANF** :  $\hat{\delta} : Q \times \Sigma^* \rightarrow 2^Q$ .  $\hat{\delta}$  prend en entrée un état de  $Q$  et un mot  $w$  sur  $\Sigma$  et retourne un ensemble d'états de  $Q$ .

Soit un état  $q \in Q$  et un mot  $w \in \Sigma^*$ . Alors  $\hat{\delta}$  est définie par :

**Cas de base**  $w$  est un mot vide :

- Pour un ADF ou ANF :  $\hat{\delta}(q, \epsilon) = q$ .
- Pour un  $\epsilon$ -ANF :  $\hat{\delta}(q, \epsilon) = ECLOSE(q)$ .

**Pas de récurrence** Si  $|w| \geq 1$ , alors  $w = xa$  avec  $x$  un mot sur  $\Sigma$  et  $a$  un symbole de  $\Sigma$ .

- Pour un ADF ou ANF :  $\hat{\delta}(q, w) = \hat{\delta}(q, xa) = \delta(\hat{\delta}(q, x), a)$
- Pour un  $\epsilon$ -ANF :  $\hat{\delta}(q, w) = \hat{\delta}(q, xa) = ECLOSE(\delta(\hat{\delta}(q, x), a))$ .

Dans le cas particulier où  $|w| = 1$ ,  $w = xa = \epsilon a$ , ce qui mène au cas de base.

Il se peut que la fonction de transition  $\delta$  ne soit pas définie pour une paire d'arguments. Auquel cas,  $\hat{\delta}$  ne l'est pas non plus.

## Chemin

Un *chemin* est une suite d'états d'un automate. Chaque état de cette suite doit être atteignable par une transition depuis l'état précédent dans cette suite.

### Exemple 7 (Chemin)

Considérons l'automate  $A$  de la figure 2.1. Il existe un chemin de  $q_0$  à  $q_5$  :  $(q_0, q_2, q_5)$ . En effet, les transitions sont définies :  $\delta(q_0, a) = q_2$  et  $\delta(q_2, b) = q_5$ . Un mot représenté par ce chemin est  $ab$ .

Dans le cas où plusieurs transitions mènent d'un état à un autre, plusieurs mots peuvent être représentés par un même chemin. Chaque état d'un chemin entre deux états  $p$  et  $q$  et distinct de ceux-ci est dit *état intermédiaire*.

## Langage

Le langage représenté par un automate  $A = (Q, \Sigma, q_0, \delta, F)$  peut alors se définir comme les mots qui, par l'application de  $\hat{\delta}$  sur l'état initial, donnent un état acceptant. Si deux automates représentent le même langage, ils sont dit *équivalents*. Voici les définitions ensemblistes, respectivement pour un ADF et pour un  $(\epsilon)$ -ANF

$$L(A) = \{w \in \Sigma^* \mid \hat{\delta}(q_0, w) \in F\} \quad L(A) = \{w \in \Sigma^* \mid \exists q \in \hat{\delta}(q_0, w), q \in F\}$$

Ainsi, un mot  $w$  appartient à un langage  $L$  représenté par l'automate  $A$  si  $\hat{\delta}(q_0, w) \in F$ .

**Exemple 8**

Soit  $A$  l'ADF de la figure 2.1. Alors  $abaa$  est un exemple de mot appartenant à  $L(A)$ . En effet :

$$\begin{aligned}
 \hat{\delta}(q_0, abaa) &= \\
 \delta(\hat{\delta}(q_0, aba), a) &= \\
 \delta(\delta(\hat{\delta}(q_0, ab), a), a) &= \\
 \delta(\delta(\delta(\hat{\delta}(q_0, a), b), a), a) &= \\
 \delta(\delta(\delta(\delta(q_0, a), b), a), a) &= \\
 \delta(\delta(\delta(q_2, b), a), a) &= \\
 \delta(\delta(q_5, a), a) &= \\
 \delta(q_3, a) &= \\
 q_3 &\in F
 \end{aligned}$$

**Exemple 9**

Soit  $A$  le  $\Sigma$ -ANF de la figure 2.2. Alors  $cb$  est un exemple de mot appartenant à  $L(A)$ . En effet :

$$\begin{aligned}
 \hat{\delta}(q_0, cb) &= \\
 ECLOSE(\delta(\hat{\delta}(q_0, c), b)) &= \\
 ECLOSE(\delta(ECLOSE(\delta(\hat{\delta}(q_0, \epsilon), c), b)) &= \\
 ECLOSE(\delta(ECLOSE(\delta(ECLOSE(q_0, c), b)) &= \\
 ECLOSE(\delta(ECLOSE(\delta(\{q_0, q_1, q_2\}, c), b)) &= \\
 ECLOSE(\delta(ECLOSE(\{q_0, q_1, q_2\}, b)) &= \\
 ECLOSE(\delta(\{q_0, q_1, q_2\}, b)) &= \\
 ECLOSE(\{q_1, q_2\}) &= \\
 \{q_1, q_2\} &
 \end{aligned}$$

On a bien l'ensemble d'états  $\{q_1, q_2\}$  avec  $q_2 \in F$ .

L'algorithme 2.2.1 représente cette appartenance pour un mot.

**Algorithme 2.2.1 (Appartenance d'un mot à un langage défini par un automate)**

**Requis:** un mot  $w$ , un automate  $A = (Q, \Sigma, q_0, \delta, F)$  représentant  $L$

**Promet:** si  $w$  appartient à  $L = L(A)$

- 1:  $C \leftarrow \{q_0\}$   $\{C$  est l'ensemble des états courants}
- 2: **si**  $A$  est un  $\Sigma$ -ANF **alors**
- 3:  $C \leftarrow ECLOSE(C)$
- 4: **fin si**
- 5: **tant que**  $|w| > 0$  **faire**
- 6: décomposer  $w$  en  $ax$  avec  $a \in \Sigma$  et  $x$  le reste du mot
- 7:  $C \leftarrow \delta(C, a)$   $\{\text{passage à l'ensemble des états suivants}\}$
- 8:  $\{\text{Si l'automate est un ADF, } C \text{ ne contient toujours qu'un seul état}\}$

```

9:   $w \leftarrow x$ 
10: si  $A$  est un  $\Sigma$ -ANF alors
11:    $C \leftarrow ECLOSE(C)$ 
12: fin si
13: fin tant que
14: retourner s'il existe un état  $q \in C$  appartenant à  $F$ 

```

### Complexité 2.2.1.1 (Lecture d'un mot par un automate)

La complexité de l'algorithme 2.2.1 dépend du type d'automate considéré. Considérons que  $|w| = n$ .

L'opération 1 est en temps constant. Les opérations 2 à 4 ont la complexité d'ECLOSE. Pour un ADF ou ANF, cette opération est triviale ( $\mathcal{O}(1)$ ). Pour un  $\epsilon$ -ANF, cette opération est en  $\mathcal{O}(n)$ . En effet,  $n$  états au plus peuvent être ajoutés à l'ensemble.

Les opération 6 et 9 sont en temps constant. L'opération 7 à la complexité de  $\delta$ . Cette fonction est triviale pour un ADF. Si celui-ci est stocké dans un tableau, l'opération est en temps constant. Pour un ANF ou  $\Sigma$ -ANF, comme  $\delta$  porte sur un sous-ensemble de  $Q$ , l'opération est en  $\mathcal{O}(n)$ . Le pire des cas étant  $C = Q$  avant ou après l'application de  $\delta$ . Les opérations 10 à 12 sont à nouveau une application de ECLOSE.

Dès lors, le pire des cas du corps de la boucle de l'opération 5 est le maximum entre le pire des cas de ECLOSE et de  $\delta$ . Cette boucle s'effectue au plus  $n$  fois. Une lettre est enlevée à chaque itération.

L'opération 14 se fait en  $\mathcal{O}(\log_2(n))$  pour un ADF et  $\mathcal{O}(n \log_2(n))$  pour un ANF ou  $\Sigma$ -ANF. Cette valeur suppose une recherche efficace dans  $F$  (en  $\mathcal{O}(\log_2(n))$ ).

En conclusion :

ADF	ANF	$\Sigma$ -ANF
$\mathcal{O}(1) + n(\mathcal{O}(1) + \mathcal{O}(1)) + \mathcal{O}(\log_2(n))$	$\mathcal{O}(1) + n(\mathcal{O}(1) + \mathcal{O}(n)) + \mathcal{O}(n \log_2(n))$	$\mathcal{O}(n) + n(\mathcal{O}(n) + \mathcal{O}(n)) + \mathcal{O}(n \log_2(n))$
$\mathcal{O}(n)$	$\mathcal{O}(n^2)$	$\mathcal{O}(n^2)$

## 2.2.5 Équivalence entre expression régulière et automate

Certains problèmes peuvent être exprimés sous forme d'appartenance à un langage régulier, et par extension à une expression régulière. Pouvoir convertir une expression régulière en automate permet d'exécuter cet automate sur une machine pour tester l'appartenance. Ainsi, grâce à cette méthode, une grande classe de problèmes peut être résolue.

**Théorème 2.2.1 (ADF et expression régulière)** *Un langage peut être exprimé par un automate déterministe fini si et seulement si il peut être décrit par une expression régulière.*

Ce théorème étant une double implication, il est vrai si les deux implications le sont. Étudions celles-ci séparément.

**Théorème 2.2.2 (ADF  $\implies$  expression régulière)** *Soit un langage  $L$ . Il existe un automate déterministe  $A$  tel que  $L(A) = L \implies$  il existe une expression régulière  $E$  telle que  $L(E) = L$ .*

**Preuve 2.2.2.1**

Supposons qu'il existe un ADF  $A = (Q, \Sigma, q_0, \delta, F)$  tel que  $L(A) = L$ .  $Q$  étant un ensemble fini, on peut définir sa cardinalité :  $|Q| = n$ . Supposons que ses états soient nommés  $\{1, 2, \dots, n\}$ . Il est possible de construire des expressions régulières par induction sur le nombre d'états considérés. De plus, un tel automate est aisément représenté dans un ordre séquentiel, de gauche à droite. Ceci permet de séparer visuellement les  $k$  premiers états du reste.

Soient  $i, j, k \in Q$ , tous équivalents à des nombres inférieurs ou égaux à  $n$ . Définissons  $E_{i,j}^k$  comme étant l'expression régulière décrivant un langage constitué des mots  $w$  tels que  $\delta^*(i, w) = j$  et qu'aucun état intermédiaire n'ait un nombre strictement supérieur à  $k$ .




FIGURE 2.3: Exemple : automate mettant  $E_{1,3}^3$  en évidence. Les mots représentés par un chemin passant par un arc discontinu n'appartiennent pas à  $E_{1,3}^3$  : un des états intermédiaires est dénommé par un nombre supérieur à  $k = 3$ .

L'exemple ci-dessus illustre ce fait qu'aucun état supérieur à  $k$  ne peut faire partie des états intermédiaires. Intuitivement, il s'agit d'un automate auquel on a enlevé les transitions :

- Allant de  $i$  à un nombre supérieur à  $k$  (sauf  $j$ )
- Entre deux nombres supérieurs à  $k$
- Allant d'un nombre supérieur à  $k$  (sauf  $i$ ) à  $j$

En pratiques, celles-ci ne sont juste pas considérées lors de l'application de  $\delta$ .

**Cas de base**  $k = 0$ . Comme tout état est numéroté 1 ou plus, aucun intermédiaire n'est accepté.

Une possibilité est  $i \neq j$ . Alors les chemins possibles ne se composent que d'un arc allant directement de  $i$  à  $j$ . Pour les construire :

Pour chaque paire  $i, j$  :

- Il n'existe pas de symbole  $a$  tel que  $\delta(i, a) = j$ . Alors,  $R_{ij}^0 = \emptyset$
- Il existe un unique symbole  $a$  tel que  $\delta(i, a) = j$ . Alors,  $R_{ij}^0 = a$
- Il existe des symboles  $a_1, a_2, \dots, a_k$  tels que  $\forall l \in \{1, \dots, k\}, \delta(i, a_l) = j$ . Alors,  $R_{ij}^0 = a_1 + a_2 + \dots + a_k$

Une autre possibilité est  $i = j$  et indique un chemin de longueur 0. Auquel cas l'expression régulière représentant un chemin sans symbole est  $\epsilon$ . Ce chemin doit être ajouté au langage décrit par  $E_{i,j}^k$  si  $i = j$ .

**Pas de récurrence** Supposons qu'il existe un chemin allant de  $i$  à  $j$  ne passant par aucun état ayant un numéro supérieur à  $k$ . La première possibilité est que le-dit chemin ne passe pas par



$k$ . Alors, le mot représenté par ce chemin fait partie du langage de  $E_{ij}^{k-1}$ . Seconde possibilité, le chemin passe par  $k$  une ou plusieurs fois comme représenté à la figure 2.4.




FIGURE 2.4: Un chemin de  $i$  à  $j$  peut être découpé en différents segments en fonction de  $k$

Auquel cas, ces chemins sont composés d'un sous-chemin donnant un mot dans  $E_{ik}^{k-1}$ , suivi d'un sous-chemin donnant un ou plusieurs mots dans  $E_{kk}^{k-1}$  et finalement un mot dans  $E_{kj}^{k-1}$ .

En combinant les expressions des deux types, on obtient :

$$E_{ij}^k = E_{ij}^{k-1} + E_{ik}^{k-1}(E_{kk}^{k-1})^*E_{kj}^{k-1}$$

En commençant cette construction sur  $E_{ij}^n$ , comme l'appel se fait toujours à des chaînes plus courtes, éventuellement on retombe sur le cas de base. Si l'état initial est numéroté 1, alors l'expression régulière  $E$  exprimant  $L$  est l'union (+) des  $E_{1j}^n$  tel que  $j$  est un état acceptant.  $\square$

### Complexité 2.2.2.1

Soit un ADF  $A = (Q, \Sigma, q_0, \delta, F)$  comportant  $n$  états. Pour connaître la complexité totale de cet algorithme, il faut connaître le nombre total d'expressions régulières construites et la longueur de chacune de celles-ci.

A chacune des  $n$  itérations (ajoutant progressivement des nouveaux états admis pour état intermédiaire), la longueur de l'expression peut quadrupler : elle est exprimée par 4 facteurs. Ainsi, après  $n$  étapes, cette expression peut être de taille  $\mathcal{O}(4^n)$ .

Le nombre d'expressions à construire, lui, est décomposable en deux facteurs également : le nombre d'itérations et celui de paires  $i, j$  possibles. Le premier facteur est  $n$ , quand aux paires, leur nombre s'exprime par  $n^2$ .  $n^3$  expressions sont construites.

En regroupant ces deux facteurs, on obtient  $n^3\mathcal{O}(4^n) = \mathcal{O}(n^34^n) = \mathcal{O}(n^2)$ . Comme  $n$  correspond au nombre d'états, si la transformation se fait depuis un ANF, via un ADF, vers une expression régulière, la complexité devient doublement exponentielle. La première transformation étant elle-même exponentielle en le nombre d'états de l'ANF.

### Exemple 10 (Construction d'une expression régulière)

Construction d'une expression régulière à partir de l'automate de la figure suivante :




FIGURE 2.5: Un automate acceptant tout mot ayant un nombre impair de 0

La construction par récurrence commençant avec  $k = 0$  le processus peut être représenté par des tableaux correspondant à différents  $k$  de façon croissante.

**Première itération** Dans la première itération, chaque expression se résume à un des trois cas de base, avec éventuellement  $\epsilon$  si  $i = j$  pour l'expression analysée.

	Cas de base
$E_{11}^0$	$1 + \epsilon$
$E_{12}^0$	$0$
$E_{21}^0$	$0$
$E_{22}^0$	$1 + \epsilon$

**Seconde itération** Ensuite, l'état 1 est autorisé comme état intermédiaire :  $k = 1$ . Ayant potentiellement un état intermédiaire, la formule de récurrence est utilisée.

	Formule de récurrence	Détail	Simplification
$E_{11}^1$	$E_{11}^0 + E_{11}^0 (E_{11}^0)^* E_{11}^0$	$(1 + \epsilon) + (1 + \epsilon)(1 + \epsilon)^*(1 + \epsilon)$	$1^*$
$E_{12}^1$	$E_{12}^0 + E_{11}^0 (E_{11}^0)^* E_{12}^0$	$0 + (1 + \epsilon)(1 + \epsilon)^* 0$	$1^* 0$
$E_{21}^1$	$E_{21}^0 + E_{21}^0 (E_{11}^0)^* E_{11}^0$	$0 + 0(1 + \epsilon)^*(1 + \epsilon)$	$0 1^*$
$E_{22}^1$	$E_{22}^0 + E_{21}^0 (E_{11}^0)^* E_{12}^0$	$(1 + \epsilon) + 0(1 + \epsilon)^* 0$	$\epsilon + 1 + 0 1^* 0$

**Troisième itération** A la troisième itération, l'état 2 est autorisé comme état intermédiaire.

	Résultat
$E_{11}^2$	$1^* + 1^* 0(1 + 0 1^* 0)^* 0 1^*$
$E_{12}^2$	$1^* 0(1 + 0 1^* 0)^*$
$E_{21}^2$	$(1 + 0 1^* 0)^* 0 1^*$
$E_{22}^2$	$(1 + 0 1^* 0)^*$

Pour obtenir une expression régulière correspondant à l'automate, on s'intéresse à celle qui décrit un chemin entre l'état initial (1) et les états acceptants (uniquement 2 ici). Dès lors,  $E_{12}^2 = 1^* 0(1 + 0 1^* 0)^* = L$ .

Cette expression régulière  $1^* 0(1 + 0 1^* 0)^*$  décrit bien un nombre impair de 0. Il en faut absolument un, et tout ajout supplémentaire se fait par paire.

**Théorème 2.2.3 (Expression régulière  $\implies$  ADF) ( $\Leftarrow$ )** Soit un langage  $L$ . Il existe une expression régulière  $E$  telle que  $L(E) = L \implies$  il existe un automate déterministe  $A$  tel que  $L(A) = L$ .

### Preuve 2.2.3.1

Comme tout  $\epsilon$ -ANF a un ADF équivalent (théorème 2.2.4), montrer qu'une expression régulière  $E$  a un ANF équivalent est suffisant pour obtenir cet ADF.

Soit un langage  $L$ . Soit  $E$  une expression régulière telle que  $L(E) = L$ . On peut construire l'automate récursivement sur la définition des expressions régulières à la section 2.1.3. Cette preuve par récurrence repose sur trois invariants portant sur chaque ANF construit :

1. Il y a un unique état acceptant
2. Aucune transition ne mène à l'état initial
3. Aucune transition ne part de l'état acceptant

Intuitivement, ces invariants servent à assurer que l'automate ainsi créé est lu de gauche à droite tel une expression régulière.

**Cas de base** Les ANF de la figure 2.6 représentent les automates correspondant aux trois cas de base.




FIGURE 2.6: Blocs de base pour la construction d'un automate à partir d'une expression régulière

En effet, l'automate (a) représente le langage  $\{\epsilon\}$  égal à  $L(E)$  : le seul arc de l'état initial à un état final est  $\epsilon$ . L'automate (b) ne propose pas d'arc atteignant l'état final. Aucun mot n'appartient au langage représenté par cet automate qui vaut donc  $\emptyset = L(\emptyset)$ . Finalement, (c) propose un arc pour  $a$ . Dès lors, il existe un unique chemin de longueur 1 correspondant au mot  $a$ . Ainsi, le langage exprimé par cet automate  $\{a\}$  est bien égal à  $L(E) = L(a)$ . De plus, ces automates respectent bien l'invariant de récurrence proposé.

**Pas de récurrence** Les ANF *abstraits* de la figure 2.7 représentent la façon dont un automate peut être construit récursivement en fonction des règles de récurrence des expressions régulières. Ces ANF sont abstraits car le contenu d'un bloc  $E$  ou  $F$  n'est pas représenté explicitement. Cependant, celui-ci respecte les invariants de récurrence.


(a)  $L = L(E)^*$ (b)  $L = L(E)L(F)$ (c)  $L = L(E) + L(F)$ 

FIGURE 2.7: Enchaînement de blocs pour une construction récursive

Les quatre règles de récurrence sur une expression régulière permettent de construire les automates :

- Pour une expression régulière de forme  $(E)$ , le langage  $L(E)$  étant équivalent à  $L((E))$ , l'automate construit pour  $E$  reste valable.
- L'expression régulière est de forme  $E^*$ . Par induction, il existe un automate exprimant le même langage que celui exprimé par  $E$ . L'automate pour  $E^*$  est construit comme en (a). Un arc  $\epsilon$  entrant en  $E$  permet de concaténer plusieurs chemins dans  $E$ , donnant des mots des langages décrits par  $E^1, E^2, E^3, \dots$ . Le tout étant l'ensemble des mots possibles  $L(E)^*$ . On a bien  $L(E^*) = L(E)^*$ .
- L'expression régulière est de forme  $EF$ . Par induction, il existe des automates représentant les mêmes langages que  $E$  et  $F$  et respectant notre invariant. L'automate abstrait (b) représente cette concaténation. En effet, un mot de cet automate doit se composer d'un mot  $v \in L(E)$  et d'un mot  $w \in L(F)$ . Les mots possibles sont alors de la forme  $vew$ . Donc (b) construit bien une expression régulière  $L(EF) = L(E)L(F)$ .
- L'expression régulière est de forme  $E + F$ . Alors, comme mis en évidence par l'automate abstrait (c), il existe des automates correspondants aux expressions  $E$  et  $F$ . Cette construction, en particulier les transitions sur  $\epsilon$ , permet à (c) de représenter tout mot de  $L(E)$  ou  $L(F)$ . Le langage est alors en concordance avec la définition d'une expression régulière  $L(E + F) = L(E) \cup L(F)$ .

Les automates (a), (b) et (c) respectent bien l'invariant de récurrence : pas de transition vers l'état initial, un seul état acceptant n'ayant pas de transition sortante. Chaque automate abstrait pour  $E$  ou  $F$  peut lui même être construit récursivement jusqu'au cas de base. □

### Complexité 2.2.3.1

Soit une expression régulière  $E$  contenant  $n$  symboles (alphabet et opérations comprises) représentant un langage  $L$ . Si un arbre syntaxique est créé pour  $E$ , il est possible de construire un ANF pour  $L$  en  $\mathcal{O}(n)$ . En effet :

- Cas de base :  $n$  ANFs sont créés. Cependant, chacun est constitué de 2 états et au plus 1 transition. Ceux-ci correspondent à des feuilles de l'arbre syntaxique. Ces nombres sont des constantes. Ce cas de base est effectué en  $\mathcal{O}(n * 3) = \mathcal{O}(n)$
- Récurrence : L'arbre syntaxique requiert au plus  $n$  lectures d'opération de récurrence pour fusionner les  $n$  ANF en un seul. En effet, chaque lecture consomme au moins deux expressions que ça soit par concaténation, fermeture ou union. Cependant, chacune des opérations implique au plus la création de 2 états et 4 arcs au plus. La récurrence s'effectue en  $\mathcal{O}(n * 6) = \mathcal{O}(n)$

La complexité totale de cette conversion est en  $\mathcal{O}(n)$  vers un ANF. La conversion vers un ADF, comme mentionné dans la section ci-après peut quand à elle être exponentielle.

## 2.2.6 Équivalence entre un automate déterministe fini et un automate non-déterministe fini

Cette section présente une méthode permettant de créer un ADF à partir d'un ANF et réciproquement. Ici, ANF est considéré au sens-large et peut tout aussi bien être un ANF normal qu'un  $\Sigma$ -ANF. Ceci permet de justifier l'abstraction faite entre les différents types d'automates finis et l'utilisation du même terme pour tous ceux-ci.

Soit un ANF  $A = (Q, \Sigma, q_0, \delta, F)$ . Alors l'ADF équivalent

$$D = (Q_D, \Sigma, \delta_D, q_D, F_D)$$

est défini par :

- $Q_D = \{S \mid S \subseteq Q \text{ et } S \text{ est fermé sur epsilon}\}$ . Concrètement,  $Q_D$  est l'ensemble des parties des  $Q$  fermées sur  $\epsilon$ . Cette fermeture s'écrit  $S = \text{ECLOSE}(S)$ , ce qui signifie que chaque transition sur  $\epsilon$  depuis un état de  $S$  mène à un état également dans  $S$ . L'ensemble  $\emptyset$  est fermé sur  $\epsilon$ .
- $q_D = \text{ECLOSE}(q_0)$ . L'état initial de  $D$  est l'ensemble des états dans la fermeture sur  $\epsilon$  des états de  $A$ .
- $F_D = \{S \mid S \in Q_D \text{ et } S \cap F \neq \emptyset\}$  contient les ensembles dont au moins un état est acceptant pour  $A$ .
- $\delta_D(S, a)$  est construit,  $\forall a \in \Sigma, \forall S \in Q_D$  par :
  1. Soit  $S = \{p_1, p_2, \dots, p_k\}$ .
  2. Calculer  $\bigcup_{i=1}^k \delta(p_i, a)$ . Renommer cet ensemble en  $\{r_1, r_2, \dots, r_m\}$ .
  3. Alors  $\delta_D(S, a) = \bigcup_{j=1}^m \text{ECLOSE}(r_j)$ .

**Exemple 11 (Transformation ANF vers ADF)**

Considérons l'automate  $A = (Q, \Sigma, q_0, \delta, F)$  de l'exemple 4 et les fermetures calculées dans l'exemple 6.

Alors, l'automate  $D = (Q_D, \Sigma, \delta_D, q_D, F_D)$  est donné par :

- $Q_D = \{\emptyset, \{q_1\}, \{q_2\}, \{q_1, q_2\}, \{q_0, q_1, q_2\}\}$ . Les ensembles  $\{q_0, q_1\}$  et  $\{q_0, q_2\}$  sont des sous-ensembles de  $Q$  mais ne sont pas fermés sur  $\epsilon$ .
- $q_D = \{q_0, q_1, q_2\} = \text{ECLOSE}(q_0)$ .
- $F_D = \{\{q_2\}, \{q_1, q_2\}, \{q_0, q_1, q_2\}\}$ , les ensembles contenant  $q_2$ , étant acceptant de  $A$ .
- $\delta_D$  est exprimé sur le graphe de la figure 2.8.




FIGURE 2.8: Automate  $D$ . De par la construction de  $Q$ , le nombre d'états de  $D$  est exponentiel. Les états inatteignables et  $\emptyset$  sont souvent omis pour clarifier la représentation.

**Théorème 2.2.4 (ANF  $\Leftrightarrow$  ADF)** *Un langage  $L$  peut être représenté par un ANF si et seulement si il peut l'être par un ADF.*

**Preuve 2.2.4.1**

Soit  $L$  un langage. Cette preuve étant une double implication, chacune peut être prouvée séparément.

( $\Leftarrow$ )  $L$  peut être représenté par un ADF  $\Rightarrow L$  peut être représenté par un ANF. Supposons qu'un automate  $D = (Q_D, \Sigma, \delta_D, q_D, F_D)$  représente  $L : L(D) = L$ . L'ANF  $A = (Q, \Sigma, q_0, \delta, F)$  correspondant est construit comme suit :

- $Q = \{\{q\} | q \in Q_D\} \cup \emptyset$
- $\delta$  contient les transitions de  $D$  modifiées. Les objets retournés deviennent des ensembles d'états. C'est-à-dire, si  $\delta_D(q, a) = p$  alors  $\delta(\{q\}, a) = \{p\}$ . De plus, pour chaque état  $q \in Q_D$ ,  $\delta(\{q\}, \epsilon) = \emptyset$ .
- $q_0 = \{q_D\}$
- $F = \{\{q\} | q \in F_D\}$

Dès lors, les transitions sont les mêmes entre  $D$  et  $A$ , mais  $A$  précise explicitement qu'il n'y a pas de transition sur  $\epsilon$ . Comme  $A$  représente le même langage, il existe donc bien un ANF qui représente  $L$ .

( $\Rightarrow$ )  $L$  peut être représenté par un ANF  $\Rightarrow L$  peut être représenté par un ADF. Soit l'automate  $A = (Q, \Sigma, q_0, \delta, F)$ . Supposons qu'il représente  $L$  ( $L = L(A)$ ). Considérons l'automate obtenu par la transformation détaillée à la section précédente (page 21) :

$$D = (Q_D, \Sigma, \delta_D, q_D, F_D)$$

Montrons que  $L(D) = L(A)$ . Pour ce faire, montrons que les fonctions de transition étendues sont équivalentes. Auquel cas, les chemins sont équivalents et donc les langages sont égaux. Montrons que  $\hat{\delta}(q_0, w) = \hat{\delta}_D(q_D, w)$  pour tout mot  $w$ , par récurrence sur  $w$ .

**Cas de base** Si  $|w| = 0$ , alors  $w = \epsilon$ .  $\hat{\delta}(q_0, \epsilon) = \text{ECLOSE}(q_0)$ , par définition de la fonction de transition étendue.  $q_D = \text{ECLOSE}(q_0)$  par la construction de  $q_D$ . Pour un ADF (ici,  $D$ ),  $\hat{\delta}_D(p, \epsilon) = p$ , pour tout état  $p$ . Par conséquent,  $\hat{\delta}_D(q_D, \epsilon) = q_D = \text{ECLOSE}(q_0) = \hat{\delta}(q_0, \epsilon)$ .

**Pas de récurrence** Supposons  $w = xa$  avec  $a$  le dernier symbole de  $w$ . Notre hypothèse de récurrence est que  $\hat{\delta}_D(q_D, x) = \hat{\delta}(q_0, x)$ . Ce sont bien les mêmes objets car  $\hat{\delta}_D$  retourne un état de  $D$  qui correspond à un ensemble d'états de  $A$ . Notons celui-ci  $\{p_1, p_2, \dots, p_k\}$ . Par définition de  $\hat{\delta}$  pour un ANF,  $\hat{\delta}(q_0, w)$  est obtenu en :

1. Construisant  $\{r_1, r_2, \dots, r_m\} = \bigcup_{i=1}^k \delta(p_i, a)$ . Cet ensemble correspond aux états obtenus par la lecture du symbole  $a$  à partir de  $\{p_1, p_2, \dots, p_k\}$ .
2. Calculant  $\hat{\delta}(q_0, w) = \bigcup_{j=1}^m \text{ECLOSE}(r_j)$ . Un état atteint par la lecture de  $a$  l'est aussi par  $a\epsilon$ .

$D$  a été construit avec ces deux mêmes étapes pour  $\delta_D(\{p_1, p_2, \dots, p_k\}, a)$ . Dès lors,  $\hat{\delta}_D(q_D, w) = \delta_D(\{p_1, p_2, \dots, p_k\}, a) = \bigcup_{j=1}^k \text{ECLOSE}(p_j) = \hat{\delta}(q_0, w)$ .

On a bien  $\hat{\delta}_D(q_D, w) = \hat{\delta}(q_0, w)$ .

Les langages sont donc bien égaux.

□

#### Complexité 2.2.4.1 (Conversion ANF vers ADF)

La complexité d'une conversion ANF vers ADF peut être exprimée en fonction de  $n$  le nombre d'états de l'ANF. La taille de l'alphabet  $\Sigma$  est ici comptée comme une constante  $k$ . Elle est ignorée dans l'analyse grand-O. L'algorithme de conversion se fait en deux étapes. Le calcul de ECLOSE et la construction à proprement parler. Ici, l'automate est stocké sous forme d'une table de transitions. Cette solution est plus facile à manipuler mais peut engendrer un surcoût en mémoire, qui n'est pas analysé ici.

- ECLOSE : Chacun des  $n$  états ayant une entrée pour  $\epsilon$  dans la fonction  $\delta$ , le temps de calcul sur chaque nœud ajouté est en temps constant. Chacune des  $n$  fermetures pour chacun des  $n$  états  $q \in Q$  pouvant au plus compter les  $n$  états, le temps total de cette opération est en  $n * \mathcal{O}(n) = \mathcal{O}(n^2)$ .
- Construction : Posons  $s$  le nombre d'états dans l'ADF (qui, dans le pire des cas vaut  $s = 2^n$  par la construction des sous-ensembles). La création d'un état de l'ADF est en  $\mathcal{O}(n)$ . En effet, il faut garder des références vers les états de l'ANF concernés. Ceux-ci sont au plus  $n$ .

Comme il y a  $s$  états dans l'ADF, il y a  $ks$  transitions. Chacune de celle-ci peut être construite en  $\mathcal{O}(n)$ . En effet, chaque état de l'ADF étant constitué d'au plus  $n$  états de l'ANF, il y a au plus  $n$  transitions à suivre pour obtenir l'ensemble d'états résultant dans l'ANF et faire correspondre un état de l'ADF obtenu. Les transitions sont donc construites en  $\mathcal{O}(nks) = \mathcal{O}(nks)$ .  $k$  est toujours considéré comme une constante.

La complexité dans le pire des cas est  $\mathcal{O}(n^2) + \mathcal{O}(sn) + \mathcal{O}(sn) = \mathcal{O}(sn) = \mathcal{O}(n2^n)$ . Le détail est donné sur  $s$  car, comme prouvé dans [4], en pratique le nombre d'états dans l'ADF obtenu est rarement de l'ordre de  $2^n$ , typiquement de l'ordre de  $n$ . Dans ce cas là, la complexité devient  $\mathcal{O}(n^2)$ .

#### Complexité 2.2.4.2 (Conversion ADF vers ANF)

La conversion d'un ADF  $A = (Q, \Sigma, q_0, \delta, F)$  vers un ANF consiste au remplacement de  $n$  états par  $n$  ensembles d'un seul état. Chaque copie individuelle étant en temps constant, cette opération est en  $\mathcal{O}(n)$ . Ensuite, une nouvelle table de transition doit être créée. Si l'alphabet  $\Sigma$  est de taille  $k$ , celle-ci a toujours  $n$  lignes mais  $k + 1$  colonnes. En effet, une colonne est ajoutée pour  $\epsilon$ . La création de cette nouvelle table se fait alors en  $\mathcal{O}(kn)$ . La complexité totale d'une conversion d'un ADF vers un ANF est en  $\mathcal{O}(kn)$ .

## 2.3 Table Filling Algorithm

Cette section décrit le *Table Filling Algorithm*, algorithme permettant de minimiser un automate déterministe mais aussi de tester l'équivalence entre deux de ceux-ci. C'est un élément important pour l'algorithme d'Angluin, sujet principal de ce mémoire.

### 2.3.1 Relation $R_E$

Soit un ADF  $A = (Q, \Sigma, q_0, \delta, F)$ . Définissons la relation  $R_E$  entre deux états :

$$xR_E y \iff (\forall w \in \Sigma^*, \hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F)$$

Intuitivement, ces deux états sont en relation si tout mot lu à partir de ceux-ci mène à des états étant simultanément acceptants ou non.

**Proposition 2.3.1 ( $R_E$ )**  $R_E$  est une relation d'équivalence.



**Preuve 2.3.1.1 ( $R_E$  est une relation d'équivalence)**

Montrer que  $R_E$  est une relation d'équivalence revient à montrer qu'elle est réflexive, transitive et symétrique.

- **Réflexive** : Soient un état  $x \in Q_M$  et un mot  $w \in \Sigma^*$ . Alors,  $\hat{\delta}(x, w) \in F \iff \hat{\delta}(x, w) \in F$  et par définition,  $xR_Ex$ .
- **Transitive** : Soient les états  $x, y, z \in Q_M$  tels que  $xR_Ey$  et  $yR_Ez$  ainsi que  $w \in \Sigma^*$ . Par hypothèse,  $\hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$  et  $\hat{\delta}(y, w) \in F \iff \hat{\delta}(z, w) \in F$ . Par transitivité de l'implication, on obtient  $\hat{\delta}(x, w) \in F \iff \hat{\delta}(z, w) \in F$ . On a donc  $xR_Ez$ .
- **Symétrique** : Soient les états  $x, y \in Q_M$  tels que  $xR_Ey$  et un mot  $w \in \Sigma^*$ . Par hypothèse,  $\hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$ . En lisant la double implication depuis la droite, on a bien  $\hat{\delta}(y, w) \in F \iff \hat{\delta}(x, w) \in F$  et donc  $yR_Ex$ .

□

**Corollaire 2.3.1.1**

$R_E$  répartit les états de  $Q$  en classes d'équivalence.

La classe d'équivalence de tous les états en relation  $R_E$  avec  $q$  (qui sert alors de *représentant*) se note  $[[q]]$  ou par une lettre majuscule, typiquement  $S$  ou  $T$ .

**Corollaire 2.3.1.2**

Si  $Q$  est fini, alors le nombre de classe d'équivalences est fini aussi. Chaque classe d'équivalence  $[[q]]$  contient un nombre d'états fini.

**Proposition 2.3.2 (Congruence de  $R_E$ )**  $R_E$  est congruente à droite, c'est-à-dire

$$xR_Ey \implies \forall a \in \Sigma, \delta(x, a)R_E\delta(y, a)$$

**Preuve 2.3.2.1 (Congruence de  $R_E$ )**

Montrons que si la relation est vraie pour deux états, elle reste valable pour les états atteints par la lecture d'un symbole quelconque. Soient les états  $x, y \in Q_M$  tels que  $xR_Ey$ . Soit un symbole  $a \in \Sigma$ . Par hypothèse,

$$\forall w \in \Sigma^*, \hat{\delta}(x, w) \in F \iff \hat{\delta}(y, w) \in F$$

C'est donc vrai en particulier pour  $w = au, u \in \Sigma^*$ . Dès lors,

$$\hat{\delta}(x, au) \in F \iff \hat{\delta}(y, au) \in F$$

$$\hat{\delta}(\delta(x, a), u) \in F \iff \hat{\delta}(\delta(y, a), u) \in F$$

$$\hat{\delta}(p, u) \in F \iff \hat{\delta}(q, u) \in F$$

□

**Corollaire 2.3.2.1**

Toutes les transitions étiquetées par un symbole  $a$  sortant d'une classe d'équivalence mènent à une même classe d'équivalence :  $\forall$  classe d'équivalence  $S, \forall a \in \Sigma, \exists$  une classe d'équivalence  $T, \forall q \in S, \delta(q, a) \in T$ .

### 2.3.2 Algorithme

Certains états d'un automate peuvent être *équivalents* selon la relation  $R_E$ . L'information que ceux-ci proposent est alors redondante. Dès lors, l'automate peut être simplifié pour offrir la même information de façon plus compacte. Une façon de détecter ces équivalences est de construire un tableau via le *table filling algorithm*. Le tableau obtenu est la *table de différenciation*.

Celui-ci détecte les paires *différenciables* (cochées dans le tableau construit par l'algorithme) récursivement sur un automate  $A = (Q, \Sigma, q_0, \delta, F)$ . Une paire  $\{p, q\}$  est différenciable s'il existe un mot  $w$  tel que  $\hat{\delta}(p, w)$  est un état acceptant et  $\hat{\delta}(q, w)$  ne l'est pas ou vice-versa.  $w$  sert alors de *mot témoin*. L'algorithme procède récursivement comme suit :

**Cas de base :** Si  $p$  est un état acceptant et que  $q$  ne l'est pas, alors la paire  $\{p, q\}$  est différenciable. Le mot témoin est  $\epsilon$ . La cellule correspondante dans le tableau est cochée.

**Pas de récurrence :** Soient  $p, q, r, s$  des états de  $Q$  et un symbole  $a \in \Sigma$  tel que  $\delta(p, a) = r$  et  $\delta(q, a) = s$ . Si  $r$  et  $s$  sont différenciables (les cellules sont cochées dans le tableau) alors  $p$  et  $q$  le sont aussi. En effet, il existe un mot *témoin*  $w$  qui permet de différencier  $r$  et  $s$ . Alors le mot  $aw$  est le mot témoin qui permet de différencier  $p$  et  $q$ . Les cellules de ces états sont cochées.

**Théorème 2.3.3 (Table de différenciation)** *Si deux états ne sont pas différenciés par le table filling algorithm, les états sont équivalents (ils respectent la relation  $R_E$ ).*

#### Exemple 12 (Table de différenciation)

Voici une application du table filling algorithm sur l'automate  $A_2$ , version réduite de l'automate  $A_1$  de la figure 2.1.




FIGURE 2.9: Automate  $A_2$

La première étape est de remplir la table de différenciation avec l'algorithme précédent. Tout état est différenciable de  $q_3$  : il est le seul état acceptant et tous les autres ne le sont pas. 5 cases peuvent déjà être cochées. Le reste de la table est remplie par induction comme représenté dans la table 2.3.

$q_1$					
$q_2$					
$q_3$	X	X	X		
$q_4$				X	
$q_5$				X	
	$q_0$	$q_1$	$q_2$	$q_3$	$q_4$

(a) Cas de base : tous les états sont différents de  $q_3$ 

$q_1$	X				
$q_2$		X			
$q_3$	X	X	X		
$q_4$		X		X	
$q_5$	X		X	X	X
	$q_0$	$q_1$	$q_2$	$q_3$	$q_4$

(b) Première itération : Les nouvelles paires d'états différenciables mènent, via un symbole  $a \in \Sigma$  à deux autres états différenciables.

$q_1$	X				
$q_2$		X			
$q_3$	X	X	X		
$q_4$	X	X	X	X	
$q_5$	X		X	X	X
	$q_0$	$q_1$	$q_2$	$q_3$	$q_4$

(c) Deuxième itération

$q_1$	X				
$q_2$	X	X			
$q_3$	X	X	X		
$q_4$	X	X	X	X	
$q_5$	X		X	X	X
	$q_0$	$q_1$	$q_2$	$q_3$	$q_4$

(d) Troisième itération :  $q_1$  et  $q_5$  ne sont pas différenciés.TABLE 2.3: Table de différenciation de l'automate  $A_2$  2.9

D'après le théorème, comme  $q_1$  et  $q_5$  ne sont pas différenciés, on a  $q_1 R_E q_5$ .

### Preuve 2.3.3.1

Considérons un automate déterministe fini quelconque  $A = (Q, \Sigma, q_0, \delta, F)$ . Supposons par l'absurde qu'il existe une paire d'états  $\{p, q\}$  telle que :

1.  $p$  et  $q$  ne sont pas différenciés par l'algorithme de remplissage de table.
2. Les états ne sont pas équivalents :  $\neg(p R_E q)$ . Par extension, il existe un mot témoin  $w$  différenciant  $p$  et  $q$ .

Une telle paire est une *mauvaise paire*. Si il y a des mauvaises paires, chacune associée à un mot témoin, il doit exister un paire distinguée par un mot témoin le plus court. Posons  $\{p, q\}$  comme étant cette paire et  $w = a_1 a_2 \dots a_n$  le mot témoin le plus court montrant que  $\neg(p R_E q)$ . Dès lors, soit  $\hat{\delta}(p, w)$  est acceptant, soit  $\hat{\delta}(q, w)$  l'est, mais pas les deux.

Ce mot  $w$  ne peut pas être  $\epsilon$ . Auquel cas, la table aurait été remplie dès le cas de base de l'algorithme avec la paire différenciable  $\{p, q\}$ . La paire  $\{p, q\}$  ne serait pas une mauvaise paire.

$w$  n'étant pas  $\epsilon$ ,  $|w| \geq 1$ . Considérons les états  $r = \delta(p, a_1)$  et  $s = \delta(q, a_1)$ . Ces états sont différenciés par  $a_2 a_3 \dots a_n$  car  $\hat{\delta}(p, w) = \hat{\delta}(r, a_2 a_3 \dots a_n)$  et  $\hat{\delta}(q, w) = \hat{\delta}(s, a_2 a_3 \dots a_n)$  et  $p$  et  $q$  sont différenciables.

Cela signifie qu'il existe un mot plus petit que  $w$  qui différencie deux états : le mot  $a_2 a_3 \dots a_n$ . Comme on a supposé que  $w$  est le mot le plus petit qui différencie une mauvaise paire,  $r$  et  $s$  ne peuvent pas être une mauvaise paire. Donc, l'algorithme a du découvrir qu'ils sont différenciables.

Cependant, le pas de récurrence impose que  $\delta(p, a_1)$  et  $\delta(q, a_1)$  mènent à deux états différenciables implique que  $p$  et  $q$  le sont aussi. On a une contradiction de notre hypothèse :  $\{p, q\}$  n'est pas une mauvaise paire.

Ainsi, s'il n'existe pas de mauvaise paire, c'est que chaque paire différenciable est reconnue par l'algorithme. □

### Complexité 2.3.1.1

Considérons  $n$  le nombre d'états d'un automate, et  $k$  la taille de l'alphabet  $\Sigma$  supporté.

Considérons aussi une version optimisée de l'algorithme. Une optimisation simple est de construire pour chaque paire  $\{r, s\}$  une liste des paires *dépendantes*  $\{p, q\}$  telles que, pour un même symbole  $a$ ,  $\delta(p, a) = r$  et  $\delta(q, a) = s$ .

Cette liste peut être construite en considérant chaque symbole  $a \in \Sigma$  et ajoutant les paires  $\{p, q\}$  à chacune de leur dépendance  $\{\delta(p, a), \delta(q, a)\}$ . Cette étape prend au plus  $k \cdot \mathcal{O}(n^2) = \mathcal{O}(kn^2)$ . (Le nombre de symboles multiplié par le nombre de paires à considérer).

Dès lors, on peut prendre la récurrence et la propager en ajoutant les paires dépendantes de celles différenciées au cas de base. Celui-ci s'effectue en  $\mathcal{O}(n^2)$  opérations, cochant au plus la moitié des paires ( $\frac{n(n-1)}{2}$ ). Ayant au plus  $\frac{n(n-1)}{2}$  paires à atteindre, il y a au plus de l'ordre de  $\mathcal{O}(n^2)$  opérations.

La complexité totale alors revient à  $\mathcal{O}(kn^2)$ .

### 2.3.3 Appartenance et équivalence

Comme mentionné en début de section, le test d'équivalence entre deux automates est un des piliers de l'algorithme d'Angluin. Comparer des langages représentés au complet n'est pas toujours possible et rarement efficace. Grâce à de légères modifications à l'algorithme de minimisation 2.3.3, il est possible de comparer deux automates déterministes finis et déterminer si ceux-ci sont équivalents. L'algorithme obtenu est seulement en temps quadratique par rapport au nombre d'états de l'ADF.

Considérons les ADF  $A_H$  et  $A_I$  donnés dans les figures 2.10 et 2.11




FIGURE 2.10: Automate  $A_H$ , du livre [5] (Fig3.2)

Il est possible de remplir un tableau via le table filling algorithm. Pour ce faire, les deux ADFs sont considérés comme un seul dont les états sont disjoints.

$q_1$								
$q_2$	x	x						
$q_3$	x	x						
$q_4$	x	x						
$q_5$	x	x	x	x	x			
$q_6$			x	x	x	x		
$q_7$	x	x				x	x	
$q_8$	x	x	x	x	x		x	x
	$q_0$	$q_1$	$q_2$	$q_3$	$q_4$	$q_5$	$q_6$	$q_7$

FIGURE 2.12: Tableau généré par l'application de l'algorithme sur  $A_H$  et  $A_I$

De cette table, toujours grâce aux conclusions précédentes, il est possible d'extraire des classes d'équivalences :

- $C_0 = \{q_0, q_1, q_6\}$
- $C_1 = \{q_2, q_3, q_4, q_7\}$
- $C_2 = \{q_5, q_8\}$

En particulier, la classe  $C_0$  souligne que les états initiaux sont équivalents. Cela signifie, par définition, que tout mot  $w$  lu en partant d'un de ces états sera soit accepté dans les deux automates, soit refusé dans les deux.  $A_H$  et  $A_I$  définissent donc le même langage.

Écrivons concrètement l'algorithme de test d'équivalence entre deux automates déterministes finis.

### Algorithme 2.3.2 (Équivalence entre deux automates)

Soient les ADFs  $A = (Q, \Sigma, q_0, \delta, F)$  et  $B = (Q_B, \Sigma_b, q_b, \delta_b, F_b)$ . Des automates utilisant des alphabets différents représenteront probablement des langages différents mais pas nécessairement.




FIGURE 2.11: Automate  $A_I$ , provenant également de [5]. Les états ont été renommés.

1. Considérer les deux automates comme un seul automate disjoint. Le choix de l'état initial de l'automate ainsi construit n'a pas d'importance, qu'il soit  $q_0$  ou  $q_b$ .
2. Construire la table de différenciation par le table filling algorithm.
3. Si  $q_0$  et  $q_b$  sont équivalents (non différenciés par la table), alors  $A$  et  $B$  sont équivalents.

### Complexité 2.3.2.1

Reposant sur la construction de la table d'équivalence d'états, la complexité est en  $\mathcal{O}(kn^2)$ , avec  $k$  la taille de l'alphabet et  $n$  le nombre d'états. L'étape supplémentaire, la lecture de cette table, est en temps constant et n'impacte pas la complexité.

Les différentes notions liées à l'égalité : les propriétés de réflexivité, transitivité et symétrie ont été démontrées dans la section 2.3.1.

## 2.3.4 Minimisation

Plusieurs automates peuvent représenter un même langage. Parmi ceux-ci, l'*automate minimal* est celui comportant le moins d'états.

La minimisation d'automate se fait en deux étapes :

1. Se débarrasser de tous les états inatteignables : ils ne participent pas à la construction du langage représenté
2. Grâce aux équivalences d'états trouvées grâce au table filling algorithm défini au point 2.3.2, construire un nouvel automate.

Décrivons en détail cette minimisation dans l'algorithme 2.3.3.

### Algorithme 2.3.3 (Minimisation)

Soit un automate déterministe fini  $A = (Q, \Sigma, q_0, \delta, F)$ . Les états inatteignables peuvent être supprimés de  $Q$  et de  $\delta$ .

Pour minimiser cet automate, il faut :

1. Construire la table de différenciation.
2. Séparer  $Q$  en classes d'équivalences.
3. Construire l'automate minimal  $C = (Q_C, \Sigma, \delta_C, q_C, F_C)$  :
  - (a) Soit  $S$  une des classes d'équivalence obtenues par la table de différenciation.
  - (b) Ajouter  $S$  à  $Q_C$  ainsi qu'à  $F_C$  si  $S$  contient un état acceptant  $q \in F$ . Cette opération est valide, comme mentionné dans le corollaire 2.3.2.1.
  - (c) Si  $S$  contient  $q_0$  l'état initial de  $A$ , alors  $S$  est  $q_C$  l'état initial de  $C$ .
  - (d) Pour un symbole  $a \in \Sigma$ , alors il doit exister une classe d'équivalence  $T$  tel que pour chaque état  $\forall q \in S, \delta(q, a) \in T$  par le corollaire 2.3.2.1. On définit alors  $\delta_C(S, a) = T$ .

### Exemple 13

Considérons l'automate  $A_1$  représenté à la figure 2.1. En supprimant l'état  $q_6$  qui n'est pas atteignable, on obtient l'automate  $A_2$  de la figure 2.9.

Le tableau 2.3 sert d'exemple pour l'algorithme de remplissage de tableau, sur  $A_2$ .

En appliquant l'algorithme de minimisation ci-dessus, qui peut se résumer intuitivement à fusionner les états équivalents  $q_1$  et  $q_5$ , on obtient l'automate  $A_3$  de la figure 2.13.



FIGURE 2.13: Automate  $A_3$

Une expression régulière  $((b + ab)b^*a(a + b)^*)$  peut être déduite pour  $L = L(A_3)$  grâce à cet automate  $A_3$ . Cette expression régulière est celle de l'exemple 2

**Théorème 2.3.4 (Minimalité de l'automate réduit)** *Soit un ADF  $A$  et soit  $C$  l'automate construit par cet algorithme de minimisation. Aucun automate équivalent à  $A$  n'a moins d'états que  $C$ . De plus, chaque automate ayant autant d'états que  $C$  lui est homomorphique.*

#### Preuve 2.3.4.1

Prouvons que l'algorithme de minimisation fournit un automate minimum (il n'en existe aucun comportant moins d'états pour un même langage). Soient un ADF  $A$  et  $C$  l'automate obtenu par l'algorithme de minimisation. Posons que  $C$  comporte  $k$  états.

Par l'absurde, supposons qu'il existe  $M$  un ADF minimisé équivalent à  $A$  mais comptant moins d'états que  $C$ . Posons qu'il en comporte  $l < k$ . Appliquons le table filling algorithm sur  $C$  et  $M$ , comme s'ils étaient un seul ADF, comme proposé dans la section 2.3.3. Les états initiaux sont équivalents puisque  $L(C) = L(M)$ . Dès lors, les successeurs pour chaque symbole sont eux aussi équivalents. Le cas contraire impliquerait que les états initiaux sont différenciables, ce qui n'est pas le cas. De plus, ni  $C$  ni  $M$  n'ont un état inaccessible, sinon il pourrait être éliminé, résultant en un automate comportant moins d'états pour un même langage.

Soit  $p$  un état de  $C$ . Soit un mot  $a_1a_2 \dots a_i$ , qui mène de l'état initial de  $C$  à  $p$ . Alors, il existe un état  $q$  de  $M$  équivalent à  $p$ . Puisque les états initiaux sont équivalents et que, par induction, les états obtenus par la lecture d'un symbole le sont aussi, l'état  $q$  dans  $M$  obtenu par la lecture du mot  $a_1a_2 \dots a_i$  est équivalent à  $p$ . Ceci signifie que tout état de  $C$  est équivalent à au moins un état de  $M$ . Or,  $k > l$ . Cela signifie qu'il doit exister au moins deux états de  $C$  équivalents à un même état de  $M$  et donc équivalents entre eux. Il y a la contradiction : par construction, les états de  $C$  sont tous différenciables les uns des autres. La supposition de l'existence de  $M$  est fausse. Il n'existe pas d'automate équivalent à  $A$  comportant moins d'états que  $C$ .

□

**Preuve 2.3.4.2**

Prouvons que tout automate minimal pour un langage est  $C$ , à un isomorphisme sur les noms des états près.

Soit  $A$  un ADF pour un langage  $L$ . Soient  $C$  un ADF obtenu par l'algorithme de minimisation et  $M$  un automate minimal comportant autant d'états que  $C$ .

Comme mentionné dans la preuve précédente, il doit y avoir une équivalence 1 à 1 entre chaque état de  $C$  et de  $M$ . (Au minimum 1 et au plus 1). De plus, aucun état de  $M$  ne peut être équivalent à 2 états de  $C$ , selon le même argument.

Dès lors, l'automate minimisé, dit *canonique* est unique à l'exception du renommage des différents états.

□

## 2.4 Algorithme d'Angluin

L'algorithme d'Angluin[1] est un algorithme d'apprentissage actif d'automate. Il prend la forme d'un couple professeur/élève où l'élève applique l'algorithme d'Angluin  $L^*$  en temps que tel pour apprendre l'automate et le professeur qui a accès au langage que l'élève veut apprendre.

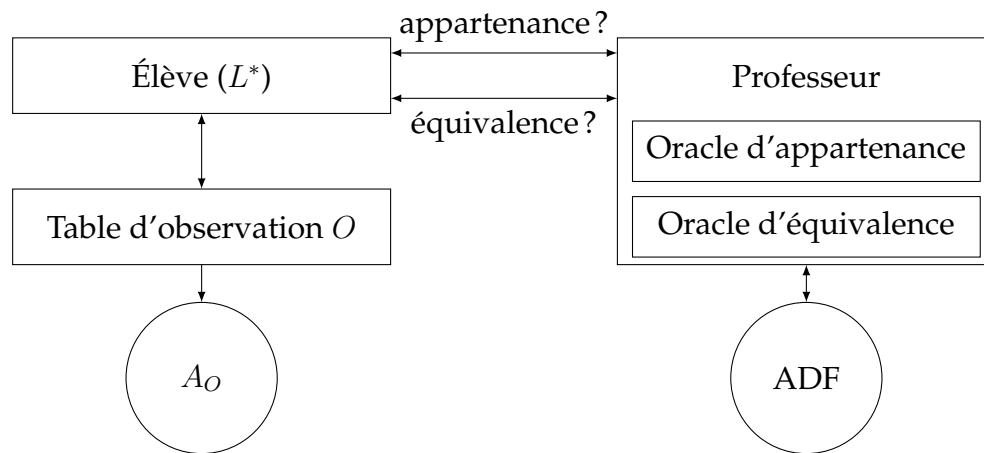


FIGURE 2.14: Vue schématique de l'algorithme d'Angluin

L'algorithme d'Angluin est nommé  $L^*$  et est exécuté par l'élève. Par abus de langage, il peut aussi désigner l'environnement complet dont il a besoin pour être fonctionnel.

Celui-ci consiste, côté élève, d'une table d'observation définie à la section 2.4.3, et d'un automate  $A_O$  construit à partir de cette table.

Côté professeur, il faut un langage régulier  $L$  à apprendre, souvent représenté par un ADF. De plus, ce professeur contient deux oracles :

- L'oracle d'appartenance. Soit un mot  $w$ . Appartient-il à  $L$ ?
- L'oracle d'équivalence. Soit un automate  $A_O$ . Représente-t-il  $L$ ? Si non, fournir un contre-exemple  $w$ .



**Théorème 2.4.1** *S'appuyant sur un professeur pour un langage régulier  $L \subseteq \Sigma^*$ , un élève peut utiliser l'algorithme d'Angluin  $L^*$  pour apprendre l'ADF canonique  $A$  représentant  $L$  en un temps polynomial à  $n$  le nombre d'états de  $A$  et  $m$  le nombre de contre-exemples reçus du professeur. Il effectue  $\mathcal{O}(n)$  requêtes d'équivalence et  $\mathcal{O}(mn^2)$  requêtes d'appartenance.[1]*

#### Corollaire 2.4.1.1

Si les requêtes d'appartenance et d'équivalence se font en temps polynomial en la taille de  $A$ ,  $L^*$  est en temps polynomial.

Attention cependant : cet algorithme part du postulat que le langage étudié est régulier.

Les prochaines section introduisent les différentes notion notemment nécessaires à la compréhension du fonctionnement de la table d'observation.

### 2.4.1 La relation $R_L$

Soit un langage  $L$  sur un alphabet  $\Sigma$ .

Soit la relation  $R_L \subseteq \Sigma^* \times \Sigma^*$ . Deux mots  $x$  et  $y$  respectent la *relation de Myhill-Nérode*  $R_L$  si

$$\forall z \in \Sigma^*, xz \in L \Leftrightarrow yz \in L$$

Intuitivement, deux mots sont en relation si pour tout mot qu'on leur concatène, les deux mots résultants sont tous deux dans le langage  $L$  ou non.

**Lemme 2.4.2** *Cette relation est une relation d'équivalence. De plus, elle est congruente à droite. C'est à dire que si  $xR_Ly$ , alors pour tout symbole  $a \in \Sigma$ ,  $xaR_Lya$*

#### Preuve 2.4.2.1 (Equivalence et Congruence à droite)

Dire d'une relation qu'elle décrit une équivalence, revient à dire qu'elle est réflexive, transitive et symétrique

- **Réflexive** : Soit  $x \in \Sigma^*$ . Soit  $z \in \Sigma^*$ . Montrer que  $xR_Lx$  est vrai revient à montrer que  $xz \in L \Leftrightarrow xz \in L$  est vrai.  $R_L$  est donc réflexive.
- **Symétrique** : Soient  $x, y \in \Sigma^*$  tels que  $xR_Ly$ . Soit  $w \in \Sigma^*$ . Montrer que  $yR_Lx$  revient à montrer que  $yw \in L \Leftrightarrow xw \in L$ . Or, par hypothèse,  $xz \in L \Leftrightarrow yz \in L$ , qui peut s'écrire aussi  $yz \in L \Leftrightarrow xz \in L$  pour tout  $z \in \Sigma^*$ , et en particulier  $z = w$ .
- **Transitive** : Soient  $x, y, u \in \Sigma^*$  tels que  $xR_Ly$  et  $yR_Lu$ . Soit  $w \in \Sigma^*$ . Comme  $xz \in L \Leftrightarrow yz \in L$  et  $yz \in L \Leftrightarrow uz \in L$  pour tout  $z \in \Sigma^*$  (par hypothèse), c'est vrai en particulier pour  $z = w$ . Dès lors,  $xw \in L \Leftrightarrow yw \in L$  et  $yw \in L \Leftrightarrow uw \in L$ . Par transitivité de l'implication, on obtient  $xw \in L \Leftrightarrow uw \in L$ , à savoir  $xR_Lu$ .

$R_L$  est congruente à droite. Soient  $x, y \in \Sigma^*$  tels que  $xR_Ly$ . Soit  $a \in \Sigma$ . Par hypothèse,  $xz \in L \Leftrightarrow yz \in L$  pour tout  $z \in \Sigma^*$ . Cela doit donc être vrai en particulier pour le mot  $z = aw$  avec  $w$  quelconque. En remplaçant dans l'hypothèse, on obtient  $xaw \in L \Leftrightarrow yaw \in L$ . Ce qui montre que  $xaR_Lya$ .

□

## 2.4.2 Théorème de Myhill-Nerode

Avant d'introduire la théorie de Myhill-Nérode, il faut s'intéresser à la relation d'équivalence  $R_B$ , qui facilite l'écriture de la preuve du théorème.

**Definition 1 (Relation  $R_B$ )** Soit un automate  $A = (Q, \Sigma, q_0, \delta, F)$ . Soient deux mots  $x, y \in \Sigma^*$ . Alors la relation  $xR_By$  est vraie si et seulement si  $\hat{\delta}(q_0, x) = \hat{\delta}(q_0, y)$ .  $\square$

Intuitivement, deux mots sont en relation  $R_B$  par rapport à un automate s'ils mènent à un même état dans celui-ci.

**Lemme 2.4.3**  $R_B$  est une relation d'équivalence congruente à droite.

### Preuve 2.4.3.1

Prouver qu'une relation est dite d'équivalence, il faut prouver que celle-ci est transitive, réflexive et symétrique. Soit un automate  $A = (Q, \Sigma, q_0, \delta, F)$ .

- $R_B$  est transitive. Soient  $x, y, z \in \Sigma^*$ . Supposons que  $xR_By$  et  $yR_Bz$ . On a bien  $\hat{\delta}(q_0, x) = \hat{\delta}(q_0, y) = \hat{\delta}(q_0, z)$  par la transitivité de l'équivalence entre deux états.
- $R_B$  est réflexive. Soit  $y \in \Sigma^*$ . On a bien  $\hat{\delta}(q_0, y) = \hat{\delta}(q_0, y)$  par réflexivité de l'équivalence sur un état.
- $R_B$  est symétrique. Soient  $x, y \in \Sigma^*$ . Supposons que  $xR_By$ . On a bien  $\hat{\delta}(q_0, y) = \hat{\delta}(q_0, x)$  par symétrie de l'équivalence entre deux états.

$R_B$  est congruente à droite. Soient  $x, y \in \Sigma^*$  tels que  $xR_By$ . Soit  $z \in \Sigma^*$ . Montrons que  $xzR_Byz$ .  $\hat{\delta}(q_0, xz) = \hat{\delta}(\hat{\delta}(q_0, x), z) = \hat{\delta}(\hat{\delta}(q_0, y), z) = \hat{\delta}(q_0, yz)$ .  $\square$

**Théorème 2.4.4** Les trois énoncés suivants sont équivalents :

1. Un langage  $L \subseteq \Sigma^*$  est accepté par un DFA.
2. Il existe une congruence à droite sur  $\Sigma^*$  d'index fini telle que  $L$  est l'union de certaines classes d'équivalence.
3. La relation d'équivalence  $R_L$  est d'index fini.

### Preuve 2.4.4.1

La preuve d'équivalence se fait en prouvant chaque implication de façon cyclique :

(1)  $\rightarrow$  (2) Supposons que (1) soit vrai, c'est-à-dire que le langage  $L$  est accepté par un automate déterministe  $A = (Q, \Sigma, q_0, \delta, F)$ . Considérons la relation d'équivalence congruente à droite  $R_B$ . Soit un mot  $w \in \Sigma^*$ . Alors tout mot  $x \in \Sigma^*$  tel que  $\hat{\delta}(q_0, x) = \hat{\delta}(q_0, w)$  appartient à la même classe d'équivalence  $[w]$ . Or, la fonction  $\hat{\delta}$  retourne un état  $q \in Q$ . Chaque classe d'équivalence sur  $\Sigma$  correspond alors à un état de l'automate. Comme  $Q$  est fini,  $R_B$  est d'index fini. De plus, un sous-ensemble des classes d'équivalences doit correspondre aux états acceptants  $q \in F$ . Alors,  $L$  est l'union de ces classes d'équivalence.

(2)  $\rightarrow$  (3) Supposons qu'il existe une relation  $E$  satisfaisant (2). Montrons que chaque classe de celle-ci est intégralement contenue dans une seule classe de  $R_L$ . Puisque  $E$  est d'index fini,

c'est un argument suffisant pour montrer que  $R_L$  est d'index fini. Soit  $x, y$  tels que  $xEy$ . Comme  $E$  est congruente à droite, pour tout mot  $z \in \Sigma^*$ , on sait que  $xzEyz$ . Comme  $L$  est un union de ces classes d'équivalence,  $xzEyz$  implique que  $xz \in L \Leftrightarrow yz \in L$ , ce qui revient à  $xR_L y$ . Cela signifie que tout mot dans la classe d'équivalence de  $x$  définie par  $E$  se retrouve dans la même classe d'équivalence que  $x$  cette fois définie par  $R_L$ . Ceci permet de conclure que chaque classe d'équivalence de  $E$  est contenue dans une classe d'équivalence de  $R_L$  et donc que  $R_L$  est d'index fini.

(3)  $\rightarrow$  (1) Considérons la relation  $R_L$  définie précédemment. Soit un automate  $A = (Q, \Sigma, q_0, \delta, F)$  défini comme suit :

- Chaque état  $q \in Q$  correspond à une classe d'équivalence de  $R_L$ .
- Comme  $R_L$  porte sur un langage, l'alphabet  $\Sigma$  de celui-ci est déjà défini.
- Si  $[[\epsilon]]$  est la classe d'équivalence de  $\epsilon$  sur  $R_L$ ,  $q_0$  correspond à cette classe.
- Si  $q$  représente  $[[x]]$  et  $q_1$  représente  $[[xa]]$ , alors  $\delta(q, a) = q_1$ . Cette définition est cohérente car  $R_L$  est congruente à droite.
- $F = \{[[x]] \mid x \in L\}$ .

Cet automate est déterministe par la définition de  $\delta$  et fini car  $Q$  l'est, le nombre de classes de  $R_L$  étant fini par hypothèse. De plus, cet automate accepte tout mot  $x \in L$  puisque  $\delta(q_0, x) = [[x]] \in F$  (par définition, puisque  $x \in L$ ).  $\square$

#### Corollaire 2.4.4.1

La partie (3)  $\rightarrow$  (1) de la preuve 2.4.4.1 donne une méthode permettant de construire un ADF à partir des classes d'équivalences de la relation  $R_L$ .

On peut prouver que l'automate obtenu de cette façon est l'automate minimal de  $L$ . Une preuve est disponible dans l'ouvrage [5] en lien avec le théorème 3.10.

### 2.4.3 La table d'observation

Une *table d'observation* est un tableau défini par  $O = (R, S, T)$  avec  $R \subseteq \Sigma^*$  un ensemble de mots *représentants*,  $S \subseteq \Sigma^*$  un ensemble de mots *séparateurs* et  $T : (R \cup R.\Sigma) \rightarrow \{0, 1\}$  un mapping représentant le contenu de la table.[7] Soit un langage  $L$  qui est en train d'être appris par l'algorithme d'Angluin. Soit un mot  $w \in L$ . Alors,  $w$  appartient à une classe d'équivalence  $[[u]]$  avec  $u \in L$ . Dans ce cas,  $T(w) = 1$ . Au contraire, si  $w \notin L$ , alors  $T(w) = 0$ .

Pour une table d'observation  $O$ , deux mots  $u, v$  peuvent être *équivalents sur  $O$* , c'est-à-dire  $uR_O v$ .  $u$  et  $v$  sont équivalents sur  $O$  si et seulement si  $\forall w \in S, T(uw) = T(vw)$ . Intuitivement,  $uR_O v$  si les lignes correspondant à leur classe d'équivalence ont la même séquence de 0 et de 1.

**Proposition 2.4.5** Soient  $u, v \in \Sigma^*$ , un langage  $L$  et une table d'observation  $O$  associée à ce langage. Si  $uR_L v$ , alors  $uR_O v$ .

#### Preuve 2.4.5.1

Soient un langage  $L$ ,  $u, v \in \Sigma^*$  tels que  $uR_L v$  et une table d'observation  $O$  associée à  $L$ . Comme  $uR_L v$ , alors pour tout mot  $w \in \Sigma^*$ ,  $uw \in L \iff vw \in L$ . C'est donc vrai en particulier pour tout  $w \in S$ . Dès lors,  $\forall w \in S, T(uw) = T(vw)$ .  $\square$

**Corollaire 2.4.5.1**

Le nombre de classes d'équivalence sur  $R_O$  est inférieur ou égal à celui de classes d'équivalence sur  $R_L$ .

Cette table  $O$  représente la compréhension actuelle de l'élève du langage  $L$ . D'itération en itération,  $R_O$  représente de mieux en mieux  $R_L$  jusqu'à ce que l'automate induit de cette table soit jugé équivalent par le professeur. **TODO** : *mentionner comment est construit l'automate en question ?*

**2.4.4 Fermeture et cohérence****Fermeture**

La propriété de *fermeture* s'exprime mathématiquement par

$$\forall u \in R, \forall a \in \Sigma, \exists v \in R, uaR_Ov$$

Cette propriété peut être vérifiée par cet algorithme, expliqué de façon visuelle sur la table O :

**Algorithme 1** Vérification de la fermeture

**Promet:** si la fermeture est respectée ou non

```

1: pour chaque élément  $w$  de la section  $R$  faire
2:   pour chaque symbole  $a$  dans  $\Sigma$  faire
3:     si  $wa$  est dans  $R$  alors
4:       continuer
5:     sinon
6:        $\{wa \text{ est dans } R.\Sigma \text{ par construction}\}$ 
7:       si La ligne de  $wa$  dans  $T$  est différente de celle de  $w$  alors
8:         retourner Faux
9:       fin si
10:    fin si
11:  fin pour
12: fin pour
13: retourner Vrai

```

**Cohérence**

La propriété de *cohérence* se définit mathématiquement comme

$$\forall u, v \in R, uR_Ov \Rightarrow \forall a \in \Sigma, uaR_Ova$$

Concrètement, il s'agit de prendre deux mots  $(u, v)$  dans  $R$  ayant la même ligne dans  $T$  et vérifier, pour chaque symbole  $(a)$ , s'ils  $(ua, va)$  ont la même ligne dans  $T$ .

**Exemple 14**

Soit la table d'observation  $O$  de la table 2.4 :

$O$	$\epsilon$	$a$
$\epsilon$	0	0
$a$	0	0
$aa$	0	1

TABLE 2.4: Table d'observation  $O$ 

Cette table n'est pas cohérente. En effet,  $\epsilon R_O a$  mais en ajoutant le symbole  $a \in \Sigma$ , on obtient  $\neg(a R_O aa)$ . Les lignes ont les mêmes valeurs, mais les lignes obtenues par la concaténation du symbole  $a$  ont des valeurs différentes.

**2.4.5 L'algorithme**

Le pseudocode de l'algorithme d'Angluin est fourni par l'algorithme 2.4.1[7]. Celui-ci repose sur les oracles du professeur et l'algorithme 2.4.2, remplissant les lignes de  $T$  encore vides. Le code est suivi d'un exemple d'exécution.

**Algorithme 2.4.1 (Algorithme d'Angluin  $L^*$ )**

**Requis:** Un professeur pour le langage régulier  $L \subseteq \Sigma^*$

**Promet:** Un automate canonique décrivant  $L$

```

1: Initialiser la table d'observation  $O = (R, S, T)$  avec  $R = S = \epsilon$ 
2: corriger( $O$ )
3: répéter
4:   tant que  $O$  n'est pas fermée ou pas cohérente faire
5:     si  $O$  n'est pas fermée alors
6:       Choisir  $r \in R$  et  $a \in \Sigma$  tels que  $[[ua]]_O \cap R = \emptyset$ 
7:        $R \leftarrow R \cup ua$ 
8:       corriger( $O$ )
9:     fin si
10:    si  $O$  n'est pas cohérente alors
11:      Choisir  $u R_L v \in R, a \in \Sigma$  et  $w \in S$  tels que  $T(uaw) \neq T(vaw)$ 
12:       $S \leftarrow S \cup aw$ 
13:      corriger( $O$ )
14:    fin si
15:  fin tant que
16:  Construire  $A_O$ 
17:  Soumettre  $A_O$  à l'oracle d'équivalence
18:  si le professeur retourne un contre-exemple  $u$  alors
19:     $R \leftarrow R \cup \text{Pref}(u)$ 
20:    corriger( $O$ )

```

21: **fin si**  
 22: **jusqu'à** ce que le professeur réponde "oui" à l'équivalence  
 23: **retourner**  $A_O$

#### Algorithme 2.4.2 (*corriger*( $O$ ))

**Requis:** une table d'observation  $O$ , un professeur pour le langage régulier  $L \subseteq \Sigma^*$

**Promet:** les entrées de  $O$  sont valide dans  $L$


1: **pour chaque** entrée  $u \in (R \cup R\Sigma)$  pour laquelle  $T(u)$  n'est pas encore définie **faire**  
 2:   **si**  $u \in L$  par le test d'appartenance **alors**  
 3:      $T(u) \leftarrow 1$   
 4:   **sinon**  
 5:      $T(u) \leftarrow 0$   
 6:   **fin si**  
 7: **fin pour**

Considérons l'automate  $A_3$  de la figure 2.13 construit à la section 2.3.4 sur la minimisation.

#### Première itération

L'algorithme d'Angluin précise, pour son cas de base, une initialisation de la table  $T$  avec les ensembles  $R$  et  $S$  contenant uniquement  $\epsilon$ . Le champ  $R.\{a, b\}$  ( $R.\Sigma$ ) est rempli via des requêtes d'appartenance sur les mots  $a$  et  $b$ .

$O_0$	$\epsilon$
$\epsilon$	0
$a$	0
$b$	0



Automate  $O_0$

L'étape suivante consiste à vérifier la fermeture de la table d'observation  $O_0$ . Pour rappel :

$$\forall u \in R, \forall a \in \Sigma, \exists v \in R, uaR_Ov$$

Intuitivement, pour chaque symbole (ici,  $\{a, b\}$ , et ce sera vrai jusqu'à la dernière itération), tout mot candidat (dans  $R$ , la partie supérieure de la table) doit se retrouver, complété de ce symbole, dans une classe d'équivalence d'un autre candidat de  $R$ . Ici, de toute évidence, les mots  $a$  et  $b$  sont dans la même classe d'équivalence que  $\epsilon$ . Dès lors, la propriété de fermeture est respectée.

Si la fermeture est respectée, alors la question de la cohérence se pose. Pour rappel :

$$\forall u, v \in R, uR_Ov \Rightarrow \forall a \in \Sigma, uaR_Ova$$

Intuitivement, si deux candidats semblent être dans la même classe d'équivalence (leur lignes dans la table supérieure sont identiques), alors pour n'importe quel symbole, les deux

nouveaux mots sont également dans une même classe d'équivalence (leur lignes, potentiellement dans la partie inférieure de la table, sont identiques). N'ayant qu'un seul candidat, cette propriété est forcément respectée ( $R_L$  est réflexive).

Les deux propriétés étant respectées, les classes d'équivalences sont calculées (trivialement ici), et un automate  $O_0$  est proposé à l'enseignant pour vérification.


Sur cette itération, un automate initial a été proposé, et aucun état final ne pouvant être atteint avec un seul symbole, la version est minime.

## Seconde itération

L'enseignant répond que non, les automates ne sont pas équivalents. Il fournit le contre-exemple  $ba$ . Comme il est rejeté par  $O_0$ , cela signifie qu'il est accepté par  $A_3$ . Une nouvelle table est alors construite, en ajoutant  $ba$  et ses préfixes (ici, juste  $b$ ) à  $R$ .  $R.\Sigma$  est calculé et les mots n'ayant pas encore reçu une valeur dans  $T$  sont soumis à l'enseignant pour un test d'appartenance. Les valeurs ajoutées ou modifiées dans la table d'observation sont mises en évidence **en rouge**.

$O_1$	$\epsilon$
$\epsilon$	0
$b$	0
$ba$	1
$a$	0
$bb$	0
$baa$	1
$bab$	1

$O_2$	$\epsilon$	$a$
$\epsilon$	0	0
$b$	0	1
$ba$	1	1
$a$	0	0
$bb$	0	1
$baa$	1	1
$bab$	1	1



Comme pour la première itération, la fermeture est testée, suivie de la cohérence. Celle-ci n'est pas respectée : si on considère les mots  $\epsilon$  et  $b$ , qui ont la même ligne dans la table  $T$  ( $\epsilon R_O b$ ), le symbole  $a$ , on obtient les mots  $a$  et  $ba$  qui n'ont pas la même ligne : ( $\neg a R_O ba$ ). Le symbole  $a$  est alors ajouté à  $S$  et une nouvelle table  $O_2$  est calculée.

La fermeture étant déjà vérifiée, la question de la cohérence est reposée, et cette fois-ci elle est vérifiée ; l'automate est construit et proposé à l'enseignant.

Sur cette itération, l'algorithme a reçu le mot  $ba$  comme étant accepté. Il a du ajouter  $a$  à  $S$  pour permettre de différencier certains états. L'automate se voit ajouter les états  $[[b]]$  et  $[[ba]]$ .

## Troisième itération


Suivant toujours l'algorithme de comparaison d'automates détaillé dans la section 2.3.3, l'enseignant découvre qu'ils sont différents.

Il sort le contre-exemple  $aaba$ . Si c'est un contre-exemple et qu'il est accepté par  $O_2$ , c'est qu'il ne l'est pas (0) par  $A_4$ . Une nouvelle table  $O_3$  doit être construite.

$O_3$	$\epsilon$	$a$
$\epsilon$	0	0
$a$	0	0
$b$	0	1
$aa$	0	0
$ba$	1	1
$aab$	0	0
$aaba$	0	0
$ab$	0	1
$bb$	0	1
$aaa$	0	0
$baa$	1	1
$bab$	1	1
$aabb$	0	0
$aabaa$	0	0
$aabab$	0	0

$O_4$	$\epsilon$	$a$
$\epsilon$	0	0
$a$	0	0
$b$	0	1
$aa$	0	0
$ab$	0	1
$ba$	1	1
$aab$	0	0
$aaba$	0	0
$bb$	0	1
$aaa$	0	0
$aba$	1	1
$abb$	0	1
$baa$	1	1
$bab$	1	1
$aabb$	0	0
$aabaa$	0	0
$aabab$	0	0

$O_7$	$\epsilon$	$a$	$b$	$ab$	$ba$
$\epsilon$	0	0	0	1	1
$a$	0	0	0	0	1
$b$	0	1	0	1	1
$aa$	0	0	0	0	0
$ab$	0	1	0	1	1
$ba$	1	1	1	1	1
$aab$	0	0	0	0	0
$aaba$	0	0	0	0	0
$bb$	0	1	0	1	1
$aaa$	0	0	0	0	0
$aba$	1	1	1	1	1
$abb$	0	1	0	1	1
$baa$	1	1	1	1	1
$bab$	1	1	1	1	1
$aabb$	0	0	0	0	0
$aabaa$	0	0	0	0	0
$aabab$	0	0	0	0	0

Automate  $O_7$ 

Ayant reçu  $aaba$ , ce mot et tous ses préfixes sont ajoutés à la table. L'extension  $R.\Sigma$  est recalculée et la table  $O_3$  est construite.

Un manquement à la fermeture est détecté : le mot  $a$ . En effet, en lui ajoutant le symbole  $b$ , on obtient  $ab$  qui n'est ni dans  $R$  ni en relation  $R_O$  avec  $a$ .  $ab$  est alors ajouté à  $R$ , et  $R.\Sigma$  est étendu. La nouvelle table,  $O_4$  est de nouveau testée.

$O_4$  ne respecte pas la cohérence. Les mots  $\epsilon$  et  $aa$  respectent  $R_O$  (leur ligne a la même valeur dans la table) mais  $\neg bR_Oaab$ .  $b$  est alors ajouté à  $S$  et une nouvelle colonne associée est ajoutée à la table, donnant le table  $O_5$ . Celle-ci a toujours un soucis de cohérence entre  $\epsilon$  et  $aa$ , menant à l'ajout de  $ab$  à  $S$  et à la création de  $O_6$ . Finalement, pour régler le soucis de cohérence dans



$O_6$  entre  $a$  et  $aa$ , le mot  $ba$  est ajouté à  $S$  et une table  $O_7$  est ainsi créée avec la nouvelle colonne associée.

Cette table  $O_7$  respectant la fermeture et la cohérence, l'automate associé  $O_7$  est construit et soumis à l'enseignant pour être comparé à  $A_3$ . Celui-ci valide l'égalité et l'algorithme s'arrête : l'automate a été construit.

# Chapitre 3

## Notions spécifiques à LeVer

La section 3.1 définit plus clairement la problématique à l'aide des éléments du chapitre précédent. Elle explique comment les différentes sections de ce chapitre confluent vers une solution à la problématique en question.

Ensuite, la section 3.2 étend le concept des automates aux automates FIFO et définit une nouvelle opération. Une forme de langage sur ces nouveaux automates est proposée à la section 3.3.

Finalement, la notion de sécurité est définie dans la section 3.4 avec une formule permettant de calculer les états concernés avant que l'algorithme final ne soit présenté dans la section ??.

Tous ces éléments combinés reprennent la technique proposée par [8] et permet l'implémentation de l'algorithme dans le chapitre 5.

### 3.1 Problème

Cette section décrit le problème rencontré par [8] et la technique générale utilisée pour proposer une solution à ce problème.

Les automates FIFO définis à la section 3.2 sont plus puissants que les ADF définis dans le chapitre 2. Contrairement, à ceux-ci, les automates FIFO ont possiblement une infinité d'états. Dans ces conditions, il n'est pas possible d'en faire une exploration exhaustive pour trouver tous les états acceptants.

À la place, une propriété dite de sécurité est définie. Si un état respecte cette propriété, il est sûr. Si il y a moyen de prouver que la totalité des états de l'automate respectent cette propriété, l'automate est considéré comme sûr. Si au contraire, un exemple de violation de la propriété est trouvé, l'automate peut être déclaré comme insûr.

Les sections suivantes donnent les différents éléments utilisés par [8] pour répondre à cette question. Un langage proxy est donné pour représenter les différents états d'un automate FIFO. Celui-ci est construit pour être régulier. De la sorte, il est possible d'appliquer l'algorithme d'Angluin pour apprendre ce langage proxy.

Celui-ci n'étant qu'une approximation du langage de l'automate FIFO, certaines incertitudes peuvent apparaître. Cependant, l'article justifie ces différents cas en ramenant la question à la sécurité, qui peut être répondue en un temps polynomial.

Dès lors, les différentes section permettent de construire ce langage, de se prononcer sur l'appartenance et l'équivalence avec ce langage et d'arrêter l'apprentissage s'il est possible de se prononcer sur la propriété de sécurité pour l'automate FIFO considéré.

## 3.2 Automate FIFO

L'article [8] se concentre sur un automate plus général : l'automate FIFO. Celui-ci est Turing Complete. De la sorte, l'équipe propose une réponse pour un ensemble plus large de langage. Cette section décrit les automates FIFO.

### 3.2.1 Définitions

**Definition 2** Un *automate FIFO*  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$  est défini comme suit :

- $Q$  est un ensemble fini d'états de contrôle
- $C$  est un ensemble fini de noms de canaux
- $\Sigma$  est un alphabet
- $q_0 \in Q$  est l'état de contrôle initial
- $\Theta$  est un ensemble fini de noms de transitions
- $\delta$  est la fonction nommante.  $\delta : \Theta \rightarrow Q \times ((C \times \{?, !\} \times \Sigma) \cup \{\tau\}) \times Q$ . Un nom de transition  $\theta$  correspond à une transition de la forme  $\delta(\theta) = (p, \text{"action"}, q)$ . Cette action a une des trois formes suivantes :
  - $c!m$  : C'est une action d'envoi. Le symbole  $m$  est ajouté en fin de canal  $c$ .
  - $c?m$  : C'est une action de réception. Le symbole  $m$  est consommé en début de canal  $c$ .
  - $\tau$  : C'est une action interne. Aucun canal n'est manipulé.  $\square$

Un automate  $F$  définit un système de transitions  $\mathcal{T} = (S, \Theta, \rightarrow)$ .  $\mathcal{T}$  est l'objet qui permet de passer d'un état à un autre.

En effet, il existe les états de contrôles  $q \in Q$ , mais les états au sens d'un automate FIFO sont de forme  $s \in S = Q \times (\Sigma^*)^C$ . En particulier, un état  $s = (q, w)$  avec  $q \in Q$  un état de contrôle et  $w \in (\Sigma^*)^C$  est un vecteur qui fait correspondre à chaque canal  $c \in C$  un mot  $w[c] \in \Sigma^*$  représentant le contenu de ce canal.

Dès lors, un état  $s$  peut être compris comme étant composé d'un état et du contenu des différents canaux.


De plus, la fonction de transition  $\rightarrow : S \times \Theta \rightarrow S$  associe un état  $s$  et un nom de transition  $\theta$  à un état  $s'$ .

$\mathcal{T}$  respecte trois règles, correspondants chacune à un des types d'actions mentionnés précédemment. En plus de la notation  $w[c]$ , celles-ci utilisent la notation  $w[c \mapsto c']$  signifiant  $w$  à l'exception du canal  $c$  dont le contenu a été remplacé par le mot  $c'$ .

- Si  $\delta(\theta) = (p, c?m, q)$  alors  $(p, w) \xrightarrow{\theta} (q, w')$  si et seulement si  $w = w'[c \mapsto mw'[c]]$
- Si  $\delta(\theta) = (p, c!m, q)$  alors  $(p, w) \xrightarrow{\theta} (q, w')$  si et seulement si  $w' = w[c \mapsto mw[c]]$
- Si  $\delta(\theta) = (p, \tau, q)$  alors  $(p, w) \xrightarrow{\theta} (q, w')$  si et seulement si  $w = w'$

**Exemple 15**

Soit un automate FIFO  $F$  tel que son système de transitions corresponde à la figure 3.1. Chaque état de l'automate correspondant à un couple état de contrôle/mot, il est imprécis de référer au système de transitions comme étant l'automate. Cependant, par abus de langage, ceux-ci seront souvent confondus dans ce document.

FIGURE 3.1: Système de transitions de l'automate FIFO  $F$ 

On retrouve bien la définition d'un automate fifo  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$  avec :

- $Q = \{q_0, q_1, q_2, q_3\}$
- $C = \{a, b\}$
- $\Sigma = \{0, 1\}$
- $q_0 \in Q$
- $\Theta = \{\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6\}$
- $\delta$  associant à chaque  $\theta_i$  un triplet état/action/état. Celui-ci est représenté entre parenthèses à côté du nom de transition associé

De plus, on peut déduire le système de transition  $\mathcal{T}$  défini par  $F$ . Considérons le mot  $w = [\epsilon, \epsilon]$  où le premier élément du vecteur est le contenu du canal  $a$  et le second celui du canal  $b$ . Dans cet exemple, comme  $\delta(\theta_1) = (q_0, a!0, q_1)$ , alors  $(q_0, w) \xrightarrow{\theta_1} (q_1, w')$ . Dans ce cas,  $w' = [0, \epsilon]$ . A ce moment, on a bien  $w' = w[a \mapsto 0w[a]]$ . En utilisant ce nouveau mot  $w'$ , un nouvel état est atteignable :  $q_3$ . En effet, comme  $\delta(\theta_4) = (q_1, a?0, q_3)$ , alors  $(q_1, w') \xrightarrow{\theta_4} (q_3, w'')$ . Dans ce cas,  $w'' = [\epsilon, \epsilon]$ . A ce moment, on a bien  $w' = w''[a \mapsto 0w''[a]]$ .

Intuitivement, la première transition  $\theta_1$  ajoute le symbole 0 en tête du canal  $a$  en passant de l'état  $q_0$  à l'état  $q_1$ . La transition  $\theta_4$ , elle, permet de passer de l'état  $q_1$  à  $q_3$  en consommant 0 en tête du canal  $a$ .

### 3.2.2 Produit cartésien

Par soucis de simplicité, un automate FIFO (et son système de transitions servant à le représenter) peut être représenté comme plusieurs systèmes de transitions utilisant les mêmes canaux. Le *produit cartésien* entre deux automates FIFO  $A$  et  $B$  retourne un nouvel automate FIFO  $F = A \times B$ . Dès lors, il est possible de représenter un automate FIFO en se concentrant sur ses parties et en les isolant [2]. Ce produit cartésien fonctionne comme suit.

Soient les automates FIFO  $A = (Q_A, C, \Sigma, q_{0A}, \Theta_A, \delta_A)$  et  $B = (Q_B, C, \Sigma, q_{0B}, \Theta_B, \delta_B)$ . Alors le système de transitions  $\mathcal{T} = (S, \Theta, \rightarrow)$  de l'automate FIFO  $F = A \times B$  est composé de :

- $S \subseteq (Q_A \times Q_B) \times (\Sigma^*)^C$  composé d'un couple d'états de contrôle de  $Q_A$  et  $Q_B$  et du contenu des différents canaux.
- $\Theta$  est un ensemble de noms de transitions.
- $\rightarrow$  est construit comme suit. Soit un état  $((q_A, q_B), w) \in S$ . Soit un triplet  $(p, a, q)$  avec  $p, q \in (Q_A \cup Q_B)$  et  $a \in ((C \times \{?, !\} \times \Sigma) \cup \{\tau\})$ .  $((q_A, q_B), w) \xrightarrow{\theta} ((q_A', q_B'), w')$  si et seulement si l'une des trois conditions suivantes est remplie.
  - $\exists \theta_A \in \Theta_A, \delta_A(\theta_A) = (q_A, a, q_{A'})$  et  $(q_A, w) \xrightarrow{\theta_A} (q_{A'}, w')$  dans l'automate  $A$  et  $\exists \theta_B \in \Theta_B, \delta_B(\theta_B) = (q_B, a, q_{B'})$  et  $(q_B, w) \xrightarrow{\theta_B} (q_{B'}, w')$  dans l'automate  $B$
  - $\exists \theta_A \in \Theta_A, \delta_A(\theta_A) = (q_A, a, q_{A'})$  et  $(q_A, w) \xrightarrow{\theta_A} (q_{A'}, w')$  dans l'automate  $A$ ,  $\forall \theta_B \in \Theta_B, \forall q \in Q_B, \delta_B(\theta_B) \neq (q_B, a, q)$  dans l'automate  $B$  et  $q_{B'} = q_B$
  - $\forall \theta_A \in \Theta_A, \forall q \in Q_A, \delta_A(\theta_A) \neq (q_A, a, q)$  dans l'automate  $A$  et  $q_{A'} = q_A$ ,  $\exists \theta_B \in \Theta_B, \delta_B(\theta_B) = (q_B, a, q_{B'})$  et  $(q_B, w) \xrightarrow{\theta_B} (q_{B'}, w')$  dans l'automate  $B$

Le produit cartésien est un nouvel automate représenté par son système de transitions. Celui-ci étant suffisant pour déduire le langage tracé, il n'est pas nécessaire de décrire formellement  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$ .

De plus, ce nouvel automate est différent des deux autres, il n'est alors pas pertinent de prouver une égalité. Il s'agit juste d'un autre mode de représentation.

#### Exemple 16

Soient deux automates FIFO  $A$  et  $B$  tels que représentés par leur systèmes de transitions donnés par la figure 3.2.





FIGURE 3.2: Automates FIFO A et B représentés par leur système de transitions

L'automate FIFO  $AB = A \times B$  est représenté par son système de transitions à la figure 3.3.

FIGURE 3.3: Automate FIFO AB résultant du produit cartésien  $A \times B$ 

L'exemple 3.2.2 suffit à se convaincre qu'on peut parler indistinctement de plusieurs systèmes de transition comme représentant un seul automate. Dans ce cas, il est sous-entendu que l'automate en question est celui obtenu par produit cartésien.

### 3.3 Trace d'automate

Cette section s'intéresse aux langages qui peuvent être associés à un automate. La section 3.3.1 définit le langage de trace d'un automate. Celui-ci n'est pas nécessairement régulier. Les sections suivantes s'appuyant sur [8] pour proposer un langage régulier qui représente ce langage de trace. Finalement, la section 3.3.4 définit une fonction  $\mathcal{F}$  qui étend une trace et explique en quoi cela aide à faciliter le processus d'apprentissage.

#### 3.3.1 Langage tracé

Une façon de définir un langage à partir d'un automate FIFO est de s'intéresser aux noms des transitions suivies lors de l'exécution. Cette section définit les éléments permettant d'arriver à la construction d'un tel langage.

Dans un système de transitions  $\mathcal{T} = (S, \Theta, \rightarrow)$ , la fonction de transition  $\rightarrow: S \times \Theta \rightarrow S$  permet de définir le passage d'un état à un autre.

La *fonction de transition étendue*  $\xrightarrow{*}$  est la fermeture transitive et réflexive de  $\rightarrow$ .

Pour une suite de noms de transitions  $\sigma = \theta_1\theta_2\dots\theta_n \in \Theta^*$ , on note  $(p, w) \xrightarrow{\sigma} (q, w')$  si il existe des états  $(p_1, w_1)(p_2, w_2)\dots(p_{n-1}, w_{n-1})$  tels que  $(p, w) \xrightarrow{\theta_1} (p_1, w_1) \xrightarrow{\theta_2} \dots \xrightarrow{\theta_{n-1}} (p_{n-1}, w_{n-1}) \xrightarrow{\theta_n} (q, w')$ . Dans ce cas,  $\sigma$  est une *trace de chemin*.

**Definition 3** Soit un automate FIFO  $F$  et l'état initial  $s_0 = (q_0, \epsilon^C)$ . Celui-ci est le couple état de contrôle initial  $q_0$  ainsi que des mots  $w[c] = \epsilon$  pour tout canal  $c \in C$ .

Le langage de trace d'un automate  $F$  est

$$L(F) = \{\sigma \in \Theta^* \mid \exists s = (p, w) \text{ tel quel } s_0 \xrightarrow{\sigma} s\}$$

### Exemple 17

Considérons l'automate FIFO  $F$  de la figure 3.1.

Pour celui-ci,  $\sigma = \theta_1\theta_4\theta_7$  n'est pas un chemin. En effet,

$$(q_0, [\epsilon, \epsilon]) \xrightarrow{\theta_1} (q_1, [0, \epsilon]) \xrightarrow{\theta_4} (q_3, [\epsilon, \epsilon])$$

Mais, il n'existe pas d'état  $s$  tel que  $(q_3, [\epsilon, \epsilon]) \xrightarrow{\theta_7} s$ . En effet, pour appliquer cette transition, il aurait fallu que le canal  $b$  contienne un symbole 0. Ce n'est pas le cas.

Par contre,  $\sigma = \theta_2\theta_3\theta_5\theta_6\theta_7\theta_1\theta_4\theta_7$  est un chemin dans  $F$  :

$$\begin{aligned} (q_0, [\epsilon, \epsilon]) &\xrightarrow{\theta_2} (q_0, [1, \epsilon]) \xrightarrow{\theta_3} (q_0, [1, 0]) \xrightarrow{\theta_5} (q_0, [1, 00]) \xrightarrow{\theta_6} (q_0, [\epsilon, 00]) \xrightarrow{\theta_7} \\ &(q_0, [\epsilon, 0]) \xrightarrow{\theta_1} (q_0, [0, 0]) \xrightarrow{\theta_4} (q_0, [\epsilon, 0]) \xrightarrow{\theta_7} (q_0, [\epsilon, \epsilon]) \end{aligned}$$

On a bien un état  $s$  (ici  $s = (q_0, [\epsilon, \epsilon]) = s_0$ ) tel que  $s_0 \xrightarrow{\sigma} s$ .

### 3.3.2 Alphabet d'annotation

Le langage de trace n'est pas nécessairement régulier. Pour permettre l'apprentissage par l'algorithme d'Angluin, il faut en construire un qui est régulier et qui permette de reconstruire le langage de trace. Pour ce faire, ce nouveau langage devrait pouvoir représenter tout état atteignable ainsi qu'un ou plusieurs chemins ou mots témoins permettant d'atteindre ceux-ci.

Pour ce faire, pour chaque nom de transition correspondant à une action d'envoi, un *co-nom* est défini :

$$\bar{\Theta} = \{\bar{\theta} \mid \theta \in \Theta \wedge \exists p, q \in Q, c \in C, a \in \Sigma, \text{ tels que } \delta(\theta) = (p, c!a, q)\}$$

De plus, un *symbole de contrôle* est créé pour chaque état de contrôle :  $T_Q = \{t_q \mid q \in Q\}$ .

En combinant les noms de transitions, les co-noms et les symboles de contrôlé, un nouvel alphabet peut-être défini, l'*alphabet d'annotation* :  $\Phi = (\Theta - \Theta_r) \cup \bar{\Theta} \cup T_Q$ .

Avec  $\Theta_r = \{\theta \mid \theta \in \Theta \wedge \exists p, q \in Q, c \in C, a \in \Sigma, \text{ tels que } \delta(\theta) = (p, c?a, q)\}$ , similaire à  $\bar{\Theta}$  mais avec un nom pour chaque transition pour les actions de réception.

### 3.3.3 Trace annotée

Soit  $\mathcal{A} : \Theta^* \rightarrow \Phi^*$  une fonction associant une *trace annotée* à une trace d'automate. Cette fonction est décrite par l'algorithme 2.

---

**Algorithme 2**  $\mathcal{A} : \Theta^* \rightarrow \Phi^*$ 


---

**Requis:** un automate FIFO  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$ , une suite de noms de transitions  $\sigma \in \Theta^*$

**Promet:** une trace annotée  $\gamma \in \Phi^*$  représentant  $\sigma$

```

1:  $\gamma \leftarrow \epsilon$ 
2: pour chaque transition  $\theta \in \sigma$  faire
3:   si  $\theta$  correspond à une action de réception alors
4:     trouver  $\theta_s \in \Theta$  correspondant à une action d'envoi antécédant dans  $\sigma$  tel que les actions
       s'appliquent sur le même canal et le même symbole
5:      $\gamma \leftarrow \gamma$  où  $\theta_s$  est remplacé par  $\bar{\theta}_s \in \bar{\Theta}$  { $\theta$  n'est pas ajouté à  $\gamma$ }
6:   sinon si  $\theta$  correspond à une action d'envoi alors
7:      $\gamma \leftarrow \gamma\theta$ 
8:   fin si
9: fin pour
10: trouver  $q$  l'état de contrôle tel que  $\delta(\theta) = (p, a, q)$  avec  $p \in Q, a \in ((C \times \{?, !\} \times \Sigma) \cup \{\tau\})$ 
11:  $\gamma \leftarrow \gamma t_q$  avec  $t_q \in T_Q$  le symbole de contrôle associé à  $q$ 
12: retourner  $\gamma$ 

```

---

Soit  $AL(F) = \{\mathcal{A}(\sigma) | \sigma \in L(F)\}$  le langage de traces annotées de l'automate  $F$ .  $AL(F)$  est un ensemble de traces annotées correspondant à des exécutions valides de l'automate  $F$ . Intuitivement,  $AL(F)$  contient l'ensemble des états atteignables par  $F$  ainsi que les traces annotées servant de témoins de cette atteignabilité des états.

Soit un mot  $\gamma \in \Phi^*$ .  $\gamma$  est *correctement formaté* si il fini par un symbole de  $T_Q$  qui qu'aucun autre symbole de cet ensemble n'apparaît dans le mot. Soit un langage arbitraire  $L$ .  $L$  est *correctement formaté* si tous les mots de  $L$  le sont.

#### Exemple 18

Soit l'automate  $F$  représenté par la figure 3.2. Soient les séquences  $\sigma_1 = \theta_2\theta_8$  et  $\sigma_2 = \theta_1\theta_3\theta_5\theta_2$ . Alors, les traces annotées de ces traces sont :  $\mathcal{A}(\sigma_1) = \theta_2\theta_8 t_{(q_1, q_B)} = \gamma_1$  et  $\mathcal{A}(\sigma_2) = \bar{\theta}_1\bar{\theta}_5 t_{(q_0, q_B)} = \gamma_2$ . Bien qu'elles soient toutes deux correctement formatées,  $\gamma_1$  ne correspond à aucune exécution valide de  $F$ . Dès lors,  $\gamma_1$  n'appartient pas au langage de traces annotées de  $AL(F)$  contrairement à  $\gamma_2$ .

Soit le mot  $\gamma_3 = t_{q_0, q_A} \theta_2 t_{q_0, q_B} \in \Phi^*$ .  $\gamma_3$  n'est pas correctement formaté : il est impossible que ce mot appartienne à  $AL(F)$ .

### 3.3.4 Fonction d'extension de trace

Cette section défini  $\mathcal{F}(L)$  pour un langage arbitraire et démontre que  $AL(F)$  en est un point fixe minimum. De la sorte, tout langage qui n'est pas un point fixe minimum de  $\mathcal{F}(L)$  ne peut



pas être  $AL(F)$ . Si c'est le cas, la question d'équivalence est répondue : les langages ne sont pas égaux. Il reste alors à générer un contre-exemple.

La fonction d'extension  $Post(L)$  permet d'étendre une trace annotée  $\gamma$  (ou tout autre mot mais cela n'est pas pertinent) avec le symbole  $\theta$ . Si  $\gamma$  est correctement formée,  $source(\theta)$  et  $cible(\theta)$  donnent respectivement la source et la cible d'une transition  $\delta$ .

$$Post(\gamma, \theta) = \begin{cases} \emptyset & \text{si } \gamma \text{ n'est pas correctement formé ou si } \mathcal{C}(\gamma) \neq source(\theta) \\ \{\mathcal{T}(\gamma)t_{cible(\theta)}\} & \text{sinon si } \delta(\theta) = (p, \tau, q) \text{ ou } \delta(\theta) = (p, c_i!a_j, q) \text{ avec } p, q \in Q \\ \{deriv(\mathcal{T}(\gamma), \theta)t_{cible(\theta)}\} & \text{sinon si } \delta(\theta) = (p, c_i?a_j, q) \text{ avec } p, q \in Q \end{cases}$$

Sachant que  $deriv(\mathcal{T}(\gamma), \theta)$  fonctionne comme l'algorithme  $\mathcal{A}$  si  $\theta$  est une action de réception. Elle le fait en remplaçant un  $\theta_e \in \Theta$  associé à une action d'envoi et le remplace par  $\bar{\theta}_e \in \bar{\Theta}$  si l'action porte sur le même canal et le même symbole que  $\theta$ .

Posons  $Post(\gamma) = \bigcup_{\theta \in \Theta} Post(\gamma, \theta)$  et  $Post(L) = \bigcup_{\gamma \in L} Post(\gamma)$ .

**Théorème 3.3.1** Soit  $\mathcal{F}(L) = Post(L) \cup \{t_{q_0}\}$  où  $q_0$  est l'état de contrôle initial.  $\mathcal{F}(L)$  est une opération monotone sur les ensemble c'est-à-dire qu'elle préserve l'inclusion d'ensembles. De plus,  $AL(F)$  est un point fixe minimal de  $\mathcal{F}(L)$ .

Les preuves sont en annexe de [8] mais peut-être est-il pertinent de les réécrire ici. **TODO : étudier les preuves des théorèmes 1 et 2 de vardhan et les réécrire**

Le théorème 3.3.1 donne bien une façon de répondre à la requête d'équivalence dans une direction. Alors, si  $A \oplus B$  donne la différence symétrique entre deux ensembles (l'union à l'exception de leur intersection), le contre-exemple à l'équivalence se trouve dans  $AL(F) \oplus L$ .

Plusieurs cas sont possibles :

1.  $\mathcal{F}(L) - L \neq \emptyset$ . Il existe un mot  $w \in \mathcal{F}(L)$  qui n'appartient pas à  $L$ .
  - Si  $w = t_{q_0}$ , alors il appartient à  $AL(F) \oplus L$
  - Sinon, il faut vérifier si  $w$  est correctement formaté.
    - Si c'est le cas, alors  $w \in (AL(F) \oplus L)$
    - Sinon, c'est qu'il existe  $w' \in L$  tel que  $w \in Post(w')$ .  $Post()$  d'une annotation valide retourne une annotation valide. Par contraposée, si  $w$  est invalide,  $w'$  l'est aussi. Dès lors,  $w' \notin AL(F)$  et donc  $w' \in (AL(F) \oplus L)$ .
2.  $\mathcal{F}(L) \subsetneq L$ . **TODO : expliquer la théorie des préfixpoints là**
3.  $\mathcal{F}(L) = L$ . Soit  $\mathcal{W}(L)$  l'ensemble des traces annotées menant à des états n'étant pas sûrs.  $\mathcal{W}(L)$  est défini et une formule est donnée pour le calculer dans la section 3.4.
  - Si  $\mathcal{W}(L)$  est vide, comme  $L$  est un point fixe (notre hypothèse pour ce point), le processus d'apprentissage peut être arrêté et la sécurité de l'automate est confirmée.
  - Sinon, soit  $\gamma$  une trace annotée dans cet ensemble  $\mathcal{W}(L)$ . Si  $\gamma$  est valide, il peut être retourné comme contre-exemple à la sécurité de  $F$ . Si  $\gamma$  est invalide,  $\gamma \in (AL(F) \oplus L)$

Attention. Le langage  $L$  n'est pas forcément  $AL(F)$  dû à cette équivalence limitée (à un sens). Ce pourrait très bien être un autre point fixe contenant  $AL(F)$  ou un autre ensemble contenant une trace annotée menant à un état qui n'est pas sûr. Cependant, ce n'est pas important tant que seule la propriété de sécurité est considérée.

### 3.4 Sécurité d'un automate FIFO

Comme mentionné au début du chapitre, ce travail s'intéresse à la propriété de unsafe dans les automates FIFO. Contrairement aux ADF construits dans le chapitre 2, les automates FIFO ont un nombre potentiellement infini d'états. Dans ces conditions, il n'est pas possible d'énumérer l'ensemble des états acceptants.

Au lieu de proposer un ensemble d'état acceptants, on va fixer une propriété. Si un état respecte cette propriété, il est dit safe. Il est donc unsafe s'il ne respecte pas cette propriété de safety. Par la suite, la section 3.4.2 propose une technique permettant de calculer les états unsafe pour un langage de traces annotées. Ceci permet de répondre à la question de safety directement depuis ce langage au lieu de devoir construire le langage de l'automate FIFO.

#### 3.4.1 Définitions

Dans un automate FIFO  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$ , chaque état de contrôle  $q \in Q$  est associé à un union finie de langage réguliers pour chacun des canaux  $c \in C$ .

$$\bigcup_{0 \leq i \leq n_q} \Pi_{0 \leq j \leq k} U_q(i, c_j)$$

Où  $U_q(i, c_j)$  est un langage régulier pour le contenu du canal  $c_j$  sur l'état  $q$ .  $n_q$  est le nombre de langages réguliers utilisés pour définir cette propriété par union.

Un état  $s = (q, [w_0, w_1, \dots, w_k])$  est *sûr* s'il n'existe pas  $i, j \in \mathbb{N}$  tels que  $w_j \in U_q(i, c_j)$ .

#### 3.4.2 Traces annotées menant à des états n'étant pas sûrs

Soit la fonction  $h_c : \Phi^* \rightarrow \Sigma^*$  qui, pour un trace annotée donnée, ne retourne que les messages envoyés mais non réceptionnés sur le canal  $c$ .

$h_c$  est l'unique homomorphisme qui étend la fonction suivante de  $\Phi$  à  $\Phi^*$  :

$$h_c(\theta) = \begin{cases} m & \text{si } \theta \in \Theta \text{ et } \delta(\theta) = (p, c!m, q) \\ \epsilon & \text{sinon} \end{cases}$$

Si  $L$  est le langage représenté par  $F$  alors  $L_q$  l'ensemble des mots correctement formés pour  $L$ .

Si il existe un état non sûr  $s$ , alors il existe une trace  $\sigma \in \Theta^*$  telle que  $s_0 \xrightarrow{\sigma} s$  où  $s_0$  est l'état initial. Si les transitions dénotant des actions d'envoi et de réception d'un même symbole sur un même canal sont enlevées par paire, il ne reste que les transitions participant au contenu final des différents canaux de  $s$ . Par définition de  $h_c$ , pour chaque contenu  $w_j$  de chaque canal  $c_j$ ,  $w_j = h_{c_j}(\mathcal{A}(\sigma))$ . Dès lors, pour que  $s$  soit atteignable, il faut qu'il existe une trace annotée  $\gamma \in AL(F)$  telle que  $s = (q_\gamma, [h_{c0}(\gamma), h_{c1}(\gamma), \dots, h_{ck}(\gamma)])$  où  $q_\gamma$  est l'état de contrôle désigné par le symbole de contrôle à la fin de  $\gamma$ .

Soit la fonction  $h_c^{-1} : \Sigma^* \rightarrow \Phi^*$  l'homomorphisme inverse de  $h_c$ . C'est-à-dire  $h_{c_j}^{-1}(U_q(i, c_j))$  retourne des traces annotées correspondant au contenu d'un canal. Dans ce cas particulier, un des langages réguliers servant à définir la propriété de sécurité. Comme un plusieurs traces

annotées peuvent correspondre au même contenu de canaux par  $h_c$ , un contenu de canal peut correspondre à plusieurs traces annotées via  $h_c^{-1}$ .

En calculant cette fonction pour l'ensemble des états, canaux et langages réguliers définissant la sécurité de  $F$ , et en s'assurant que ces traces sont correctement formées, on obtient un ensemble de traces menant à des états n'étant pas sûrs.

Cet ensemble est décrit mathématiquement par  $\mathcal{W}(L)$  :

$$\mathcal{W}(L) = \bigcup_{q \in Q} \left( \bigcup_{0 \leq i \leq n_q} \left( \bigcap_{0 \leq j \leq k} h_{c_j}^{-1}(U_q(i, c_j)) \right) \right)$$

C'est un résultat majeur. En l'exploitant sur un langage de trace appris via l'algorithme d'Angluin, il permet de se prononcer sur la sécurité d'états et a fortiori de l'automate  $F$  au complet, comme le détaille le théorème 3.4.1.

**Théorème 3.4.1** *Pour vérifier la propriété de safety des automates FIFO, l'algorithme LeVer respecte les propriétés suivantes :*

1. *Si l'algorithme retourne une réponse, celle-ci est correcte*
2. *Si  $AL(F)$  est régulier, la procédure s'arrête.*
3. *Le nombre de test d'appartenance et d'équivalence dépend principalement de l'algorithme d'Angluin. Le temps total est borné en temps polynomial du nombre d'états de l'automate minimal pour  $AL(F)$  et linéaire en le temps pris pour une requête d'appartenance à  $AL(F)$*

La preuve est disponible en annexe du document [8] mais c'est un résultat tellement important, il est peut-être pertinent que celle-ci soit rediscutée ici. **TODO : preuve ?**

# Chapitre 4

## LeVer

Dans les chapitres précédants, les bases théoriques sur les automates et langages ont été introduites. Celles-ci ont été suivies de concepts plus étroitement liés à LeVer tels que les automates à files, les traces, traces annotées et langages associés. Un dernier élément présenté dans la section 3.4 est la sécurité d'un état ou d'un automate.

En appliquant l'algorithme d'Angluin [1] selon la méthode LeVer [8], il est possible de se prononcer sur la sécurité pour toute une classe d'automates à files : ceux pour lesquels le langage de traces annotées est régulier.

L'objectif dès lors n'est pas d'apprendre le langage de l'automate à file mais le langage de trace associé, et d'adapter la méthode pour répondre à la question de sécurité. En formulant les bonnes propriétés, il est également possible d'interrompre l'algorithme d'apprentissage avant terme si l'on peut se prononcer sur la sécurité de façon certaine.

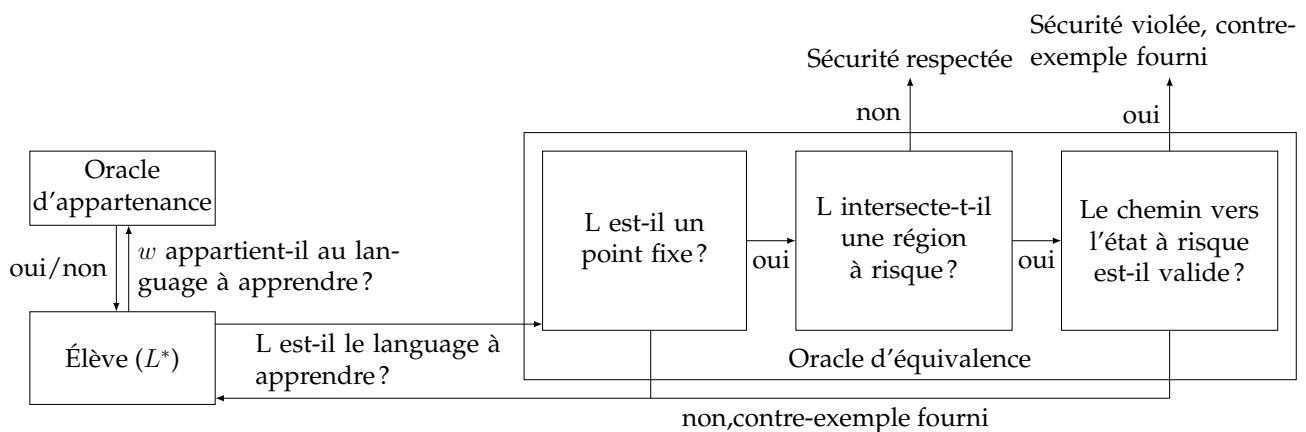


FIGURE 4.1: Vue schématique de l'algorithme d'Angluin pour LeVer[8]

Contrairement à la version proposée dans la section 2.4, ici il n'est pas possible de tester directement l'équivalence entre  $L$  et le langage à apprendre. En effet, ce dernier peut ne pas être régulier et de façon générale le professeur ne connaît justement pas l'automate permettant une telle comparaison si celle-ci existe.

Ici, le professeur passera par trois questions mais à aucun moment il saura dire si  $L$  est le

language à apprendre. Il pourra soit se prononcer sur la sécurité, soit dire avec certitude qu'il existe une meilleure approximation.

- *L est-il un point fixe ?* Cette question fait référence à l'application de la fonction d'extension de trace de la section 3.3.4.
- *L intersecte-t-il une région à risque ?* Si  $L$  est un point fixe de  $\mathcal{F}$ , il est soit le language à apprendre soit un point fixe le contenant. Si une surapproximation n'a pas d'intersection avec une région à risque,  $L$  n'en a pas non plus.
- *Le chemin vers l'état à risque est-il valide ?* Si un chemin à risque (menant à un état à risque) existe dans  $L$ , est-il valide ? C'est-à-dire, appartient-il au language visé et représente-t-il bien un chemin dans l'automate à file étudié ?

Les prochaines sections décrivent ce nouvel oracle d'appartenance, celui d'équivalence avec les trois questions posées avant de revenir sur une vue d'ensemble. De la sorte, la section 4.3 résume quand et pourquoi cette méthode fonctionne.

## 4.1 Appartenance

*TODO : Cette section explique comment l'appartenance est appliquée aux FIFO, et surtout ce que ça signifie dans notre contexte*

*TODO : Well formed, et trouver une trace depuis une exécution (membership.tex ?)*

## 4.2 Équivalence

*TODO : Cette section explique comment l'équivalence est appliquée aux FIFO, et surtout ce que ça signifie dans notre contexte*

*TODO : On revient sur la notion de fix-point, de l'intersection avec l'espace unsafe, de dire si une trace gamma est wellformed ou pas et les conséquences que ça a*

*TODO : Un beau schéma calqué sur celui du bouquin pour présenter la pensée derrière le système.*

## 4.3 Vue d'ensemble

*TODO : On fait un retour sur le schéma, on confirme avoir bien fait le tour et on explique pourquoi ça marche. Au besoin, on sort le théorème 2 et fourni une preuve.*

# Chapitre 5

## Implémentation

### 5.1 Choix

### 5.2 Résultats

## **Chapitre 6**

## **Conclusion**

# Chapitre 7

## Brouillon

### 7.1 Lost

#### 7.1.1 Construction d'un automate depuis un langage régulier

Comme vu dans la section 2.2.5, il est intéressant de pouvoir convertir un problème sur un langage régulier en test d'appartenance à un automate. Il est cependant possible de le faire directement depuis le langage régulier grâce au théorème de Myhill-Nérode et à la relation  $R_L$ .

Soit le langage  $A_N = \{w | w \text{ finit par } b \text{ et ne contient pas } bb\}$  défini sur  $\Sigma_N = a, b$ . Ce langage peut être écrit sous forme d'une expression régulière  $E = a^*(ba)^*b$ , ce qui confirme que le langage est régulier.

On peut diviser les mots de ce langage en 3 ensembles :

- $W_0$  le sous-ensemble des mots ne finissant pas le symbole  $b$
- $W_1$  celui des mots finissant par le symbole  $b$  mais ne contenant pas  $bb$
- $W_2$  celui des mots contenant au moins  $bb$

Il y a d'autres façons de construire des sous-ensembles, mais celle-ci à l'avantage de rendre la question de l'appartenance à  $L_N$  triviale : un mot appartient au second ensemble si et seulement si il fait partie du langage, par définition.

De plus, tous les éléments d'un sous-ensemble respectent la relation  $R_L$  entre eux. ( $R_L : xR_Ly \Leftrightarrow \forall z \in \Sigma^*, xz \in L \Leftrightarrow yz \in L$ ). Cela en fait des classes d'équivalence sur cette relation.

Cela peut être démontré pour chaque sous-ensemble :

- Soient  $x, y \in W_0$ . Soit  $z \in \Sigma^*$ . Dès lors, si  $xz \in L_N$ , c'est que  $z$  fini par  $b$  mais ne contient pas  $bb$ , et donc  $yz \in L_N$ . Si  $yz \in L_N$ , le même argument peut être appliqué.
- Soient  $x, y \in W_1$ . Soit  $z \in \Sigma^*$ . Dès lors, si  $xz \in L_N$ , c'est que  $z$  ne commençait pas le symbole  $b$  et ne contenait pas  $bb$ ,  $yz$  ne contiendra donc pas  $bb$ , puisque cette chaîne n'est ni dans  $z$  ni dans  $y$ , ni a cheval sur les deux,  $z$  ne commençant pas par  $b$ . Ainsi,  $yz \in L_N$ . Si  $yz \in L_N$ , le même argument peut être appliqué.
- Soient  $x, y \in W_2$ . Soit  $z \in \Sigma^*$ . Comme  $x$  contient déjà  $bb$ ,  $x \notin L_N$  et, a fortiori,  $xz \notin L_N$ . Comme la prémisse est fausse, l'implication  $xz \in L \Rightarrow yz \in L$  est vraie. La même logique peut être appliquée à partir de  $y$  pour justifier l'implication inverse.

De plus, ces sous-ensembles sont disjoints de par leur construction.



Ceci revient à démontrer que  $W_0, W_1, W_2$  sont des classes d'équivalence. De plus,  $R_L$  respecte la congruence à droite, comme démontré dans la preuve du théorème de Myhill-Nérode. Ce même théorème donne une méthode pour construire un automate : prendre un représentant pour chaque classe et en faire un état.

- $\Sigma = \{a, b\}$  est connu.
  - $Q = \{[\epsilon], [b], [bb]\} = \{q_\epsilon, q_b, q_{bb}\}$
  - $q_0 = q_\epsilon$
  - $F = \{q_b\}$  l'union des classes acceptant
  - $\delta$  défini en utilisant des exemples tirés des classes d'équivalence.
- Ce qui donne l'automate de la figure 7.1




FIGURE 7.1: Automate  $A_N$ , exemple issu de la thèse[7]

Cet automate est bien une représentation du langage  $L_N$ . Seul un mot finissant par  $b$  mais ne contenant pas  $bb$  se termine à l'état  $q_b$ .

### 7.1.2 Alternating Bit Protocol




FIGURE 7.2: Automate Fifo du ABP ([3], Fig.1.)

## 7.2 Algorithme de membership

### Algorithme 7.2.1 (Appartenance à $AL(F)$ )

**Requis:** une trace annotée  $t \in \Phi^*$  et un automate FIFO  $F = (Q, C, \Sigma, q_0, \Theta, \delta)$

**Promet:** si  $\gamma \in AL(F)$  ou non

```

1: si  $t$  est malformé alors
2:   retourner faux
3: fin si
4: candidats  $\leftarrow \{(q_0, \epsilon^c)\}$ 
5: pour chaque symbole  $\phi \in t$  faire
6:   si  $\phi \in T_Q$  alors
7:     {Fin du mot}
8:     pour chaque  $(q, w) \in$  candidats faire
9:       si  $\phi$  est un  $t_q$  correspondant à  $q$  alors
10:        retourner vrai
11:      fin si
12:    fin pour
13:    retourner faux
14: sinon
15:   {Exécution de l'automate}
16:   nouveau  $\leftarrow \emptyset$ 
17:   extension  $\leftarrow \emptyset$ 
18:   pour chaque  $(q, w) \in$  candidats faire
19:      $\phi' \leftarrow \phi$  sans l'éventuelle barre
20:     ajouter  $\delta(\phi', (q, w))$  à extension
21:   fin pour
22:   tant que extension est non vide faire
23:     {Créer les différents cas de consommation des canaux}
24:     prendre un élément  $(q, w) \in$  extension
25:     pour chaque canal non-nul  $c$  de  $w$  commençant par un symbole  $s$  faire
26:       si  $\exists \theta$  correspondant à l'action  $c?s$  sortant de  $q$  alors
27:        ajouter  $\delta(\theta, (q, w))$  à extension
28:       fin si
29:     fin pour
30:     ajouter  $(q, w)$  à nouveaux
31:   fin tant que
32:   candidats  $\leftarrow$  nouveaux
33: fin si
34: fin pour

```

# Bibliographie

- [1] D. ANGLUIN, *Learning regular sets from queries and counterexamples*, Information and Computation, 75 (1987), pp. 87 – 106.
- [2] B. BOLLIG, A. FINKEL, AND A. SURESH, *Bounded Reachability Problems Are Decidable in FIFO Machines*, in 31st International Conference on Concurrency Theory (CONCUR 2020), I. Konnov and L. Kovács, eds., vol. 171 of Leibniz International Proceedings in Informatics (LIPIcs), Dagstuhl, Germany, 2020, Schloss Dagstuhl–Leibniz-Zentrum für Informatik, pp. 49 :1–49 :17.
- [3] A. FINKEL, S. P. IYER, AND G. SUTRE, *Well-abstracted transition systems : Application to fifo automata*, Information and Computation, 181 (2003), pp. 1–31.
- [4] J. E. HOPCROFT, *Introduction to Automata Theory, Languages, and Computation (2nd Edition)*, Addison Wesley, nov 2000.
- [5] J. E. HOPCROFT AND J. D. ULLMAN, *Introduction to automata theory, languages and computation. adison-wesley*, Reading, Mass, (1979).
- [6] D. C. KOZEN, *Automata and computability*, Springer Science & Business Media, 1997.
- [7] D. NEIDER, *Applications of automata learning in verification and synthesis*, PhD thesis, Hochschulbibliothek der Rheinisch-Westfälischen Technischen Hochschule Aachen, 2014.
- [8] A. VARDHAN, K. SEN, M. VISWANATHAN, AND G. AGHA, *Actively learning to verify safety for fifo automata*, in International Conference on Foundations of Software Technology and Theoretical Computer Science, Springer, 2004, pp. 494–505.